T.C.

ISPARTA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

TEKNOLOJİ FAKÜLTESİ

ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİNE GİRİŞ Makine Öğrenmesi Modellerinde Aşırı Öğrenme (Overfitting) Problemi ve Düzenlileştirme (Regularization) Tekniklerinin Kavramsal Analizi

Hazırlayan:

Tahir Kemal Eşiyok -- 2322705012

Danışman:

Dr. Öğr. Üyesi Ali Şentürk ISPARTA 2026

ÖZET :

Bu çalışma süresince temel odak noktamız, makine öğrenmesi modellerinin eğitim aşamasında karşılaştığı en büyük engel olan ve sistemin genelleme yeteneğini körelten aşırı öğrenme (overfitting) probleminin mühendislik yöntemleriyle bertaraf edilmesi olmuştur. Sürecin ilk aşamasında, bir modelin veriyi öğrenmek yerine gürültüleri ezberlemesinin arkasındaki matematiksel nedenler incelenmiş ve bu durumun kontrol sistemlerindeki kararsızlık (instability) ile olan benzerliği üzerinde durulmuştur. Teorik altyapının oluşturulmasıyla birlikte, problemi çözmek adına literatürde kabul görmüş beş ana teknik olan L1/L2 düzenlileştirmesi, veri zenginleştirme (Data Augmentation), erken durdurma (Early Stopping) ve ağ seyreltme (Dropout) yöntemleri, Elektrik-Elektronik Mühendisliği disiplinine uygun sönümleme ve hata toleransı kavramlarıyla harmanlanarak analiz edilmiştir.

Çalışmanın uygulama safhasında, teorik bilgileri somutlaştırmak amacıyla 30 farklı boyutsal parametre içeren Wisconsin göğüs Kanseri veri seti seçilerek bir laboratuvar simülasyonu kurgulanmıştır. Bu deneysel süreçte, Lojistik Regresyon algoritması üzerinden L2 Regularization (Weight Decay) etkisini gözlemlemek için kontrollü bir deney ortamı oluşturulmuştur. Deneyin ilk adımında, hiçbir kısıtlama içermeyen ve veriyi %100 doğrulukla ezberleyerek test aşamasında başarısız olan "korumasız" bir model inşa edilmiştir. Ardından, aynı mimariye L2 ceza katsayısı eklenerek modelin katsayıları üzerinde bir sönümleme etkisi yaratılmış ve bu sayede modelin gereksiz detaylardan arınarak daha kararlı bir yapıya kavuşması sağlanmıştır.

Elde edilen sonuçlar, hazırlanan görsel kanıtlar ve katsayı analiz grafikleriyle desteklenmiştir. Özellikle özellik ağırlıklarının sönümlenmesini temsil eden karşılaştırmalı grafikler, düzenlileştirmenin bir modelin "gürültü bağışıklığını" nasıl artırdığını açıkça ortaya koymuştur. Sürecin son adımı olarak, tüm bu deneysel bulgular ve teorik çıkarımlar, akademik standartlara uygun teknik bir rapor ve sunum dosyası haline getirilerek projenin dokümantasyon aşaması tamamlanmıştır. Yapılan tüm bu çalışmalar sonucunda, makine öğrenmesi modellerinde performansın sadece yüksek başarı oranından ibaret olmadığı, asıl kritik olanın sistemin yeni ve karmaşık verilere karşı gösterdiği dayanıklılık olduğu ispatlanmıştır.

1. GİRİŞ:

Modern mühendislik çözümlerinde veriye dayalı karar verme mekanizmaları, geleneksel deterministik yaklaşımların yerini almaktadır. Ancak bir makine öğrenmesi modelinin başarısı, sadece eğitim verisi üzerinde gösterdiği performansa değil, "hiç görmediği" gerçek dünya verileri üzerindeki genelleme yeteneğine bağlıdır. Elektrik-Elektronik Mühendisliği perspektifinden bakıldığında, bir modelin eğitilmesi aslında karmaşık bir transfer fonksiyonunun parametrelerinin optimize edilmesidir. Eğer bu fonksiyon, giriş sinyalindeki ana frekans bileşenleri yerine yüksek frekanslı gürültüleri modellerse, sistemin kararlılığı bozulur.

1.2. Problem Tanımı: Aşırı Öğrenme (Overfitting)

Aşırı öğrenme, modelin eğitim veri setindeki rastgele dalgalanmaları ve gürültüyü bir kuralmış gibi ezberlemesi durumudur. Bu durum genellikle model kapasitesinin (katman sayısı, nöron sayısı veya polinom derecesi) eldeki veri miktarına göre çok yüksek olmasından kaynaklanır. Kapasitesi yüksek olan model, verideki "boşlukları" gürültüyle doldurarak test aşamasında yüksek hata oranlarına sebep olur.

2. TEORİK TEMELLER VE HATA ANALİZİ

2.1. Yanlılık (Bias) ve Varyans (Variance) İlişkisi

Bir makine öğrenmesi modelinin toplam hatası, istatistiksel olarak üç ana bileşene ayrılır. Bu kavramların anlaşılması, düzenlileştirme tekniklerinin neden gerekli olduğunu açıklar:

1. **Yanlılık (Bias):** Modelin verideki temel ilişkiyi kavrayamayacak kadar basit olmasından kaynaklanan hatadır. Yüksek yanlılık "Eksik Öğrenme" (Underfitting) anlamına gelir.

2. **Varyans (Variance):** Modelin eğitim verisindeki küçük değişimlere karşı gösterdiği aşırı duyarlılıktır. Yüksek varyans, "Aşırı Öğrenme" (Overfitting) işaretidir.

3. **İndirgenemez Hata:** Verinin doğasından gelen, hiçbir modelleme ile yok edilemeyen gürültü sınırıdır.

İdeal bir model, yanlılığı ve varyansı aynı anda minimize eden "Tatlı Noktada" (Sweet Spot) yer almalıdır. Düzenlileştirme, varyansı düşürmek için sisteme kontrollü bir miktar yanlılık ekleme işlemidir.

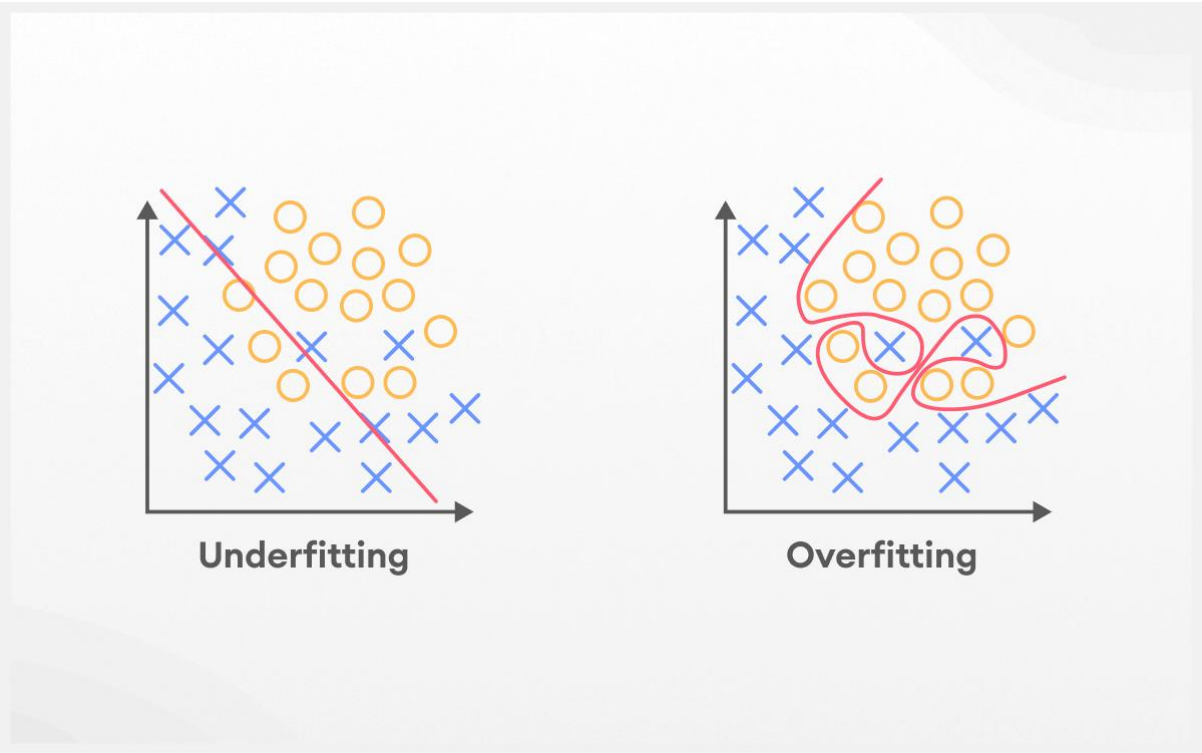

Şekil 1. Model Karmaşıklığına Bağlı Yanlılık-Varyans Dengesi

2.2. Maliyet Fonksiyonu ve Optimizasyon

Makine öğrenmesinde optimizasyon, maliyet fonksiyonunun minimize edilmesi üzerine kuruludur. Standart bir Lojistik Regresyon için bu fonksiyon, model tahminleri ile gerçek etiketler arasındaki farkı ölçer. Ancak kısıtlanmamış bir maliyet fonksiyonu, model katsayılarının sonsuza gitmesine izin vererek aşırı öğrenmeyi tetikleyebilir. Düzenlileştirme, bu maliyet fonksiyonuna bir "ceza terimi" ekleyerek katsayıların büyümesini engeller.

3. DÜZENLİLEŞTİRME (REGULARIZATION) STRATEJİLERİ

3.1. Veri ve Eğitim Süreci Odaklı Yaklaşımlar

3.1.1. Veri Zenginleştirme (Data Augmentation):

Özellikle biyomedikal sinyallerin veya görüntülerin işlenmesinde veri seti kısıtlı olabilir. Sistemin gürültü bağışıklığını artırmak için mevcut veriler matematiksel transformasyonlarla çoğaltılır. Örneğin; bir akciğer röntgeni görüntüsünün 5 derece döndürülmesi veya sinyale beyaz gürültü eklenmesi, modelin sadece statik bir örüntüyü değil, verinin varyasyonlarını da öğrenmesini sağlar. Bu, donanım testlerinde bir cihazı farklı sıcaklık ve gerilim değerlerinde test etmeye benzer.

3.1.2. Erken Durdurma (Early Stopping):

Eğitim sürecinde "iterasyon sayısı" (epoch) kritik bir parametredir. Eğitim hatası her zaman azalma eğilimindedir; ancak "doğrulama hatası" belirli bir noktadan sonra yükselmeye başlar. Bu yükseliş, ezberlemenin başladığı andır. Erken durdurma mekanizması, test başarısının düşmeye başladığı bu kırılma noktasında eğitimi otomatik olarak keser. Bu, bir bataryanın aşırı şarj olmasını engelleyen devre koruma sistemleri gibi çalışır.

3.2. Mimari ve Parametre Odaklı Yaklaşımlar

3.2.1. L1 ve L2 Regularization Matematiksel Analizi:

Bu yöntemler doğrudan maliyet fonksiyonuna müdahale eder.

- **L1 (Lasso):** Katsayıların mutlak değerini cezalandırır . Bazı katsayıları tam olarak sıfıra zorlar. Bu, özellik seçimi yapar.

- **L2 (Ridge/Weight Decay):** Katsayıların karelerini cezalandırır . Katsayıları sıfırlamaz ama çok küçültür. Sinyal işlemedeki "sönümleme" (damping) etkisiyle aynıdır. Ağırlıkların kontrolsüz büyümesini engelleyerek sistemin genel kararlılığını artırır.

3.2.2. Dropout (Ağ Seyreltme):

Özellikle derin öğrenme katmanlarında, her eğitim adımında nöronların belirli bir yüzdesinin (örn: %50) rastgele devre dışı bırakılmasıdır. Bu teknik, nöronlar arasında "eş-uyum" oluşmasını engeller. Model, bir sonuca varmak için tek bir yola güvenmeyi bırakıp, mantığı tüm ağa dağıtmak zorunda kalır. Bu, sistemde bir "yedeklilik" ve hata toleransı yaratır.

4. UYGULAMA: GÖĞÜS KANSERİ TEŞHİS MODELİ ANALİZİ

4.1. Veri Seti Karakteristiği ve Ön İşleme

Uygulamada, biyomedikal mühendisliği ve radyoloji alanında standart kabul edilen veri seti kullanılmıştır. Veri seti, 30 farklı boyutsal ve dokusal hücre özelliği içerir.

- **Standardizasyon:** Özellikler arasındaki ölçek farkını (yarıçap vs. alan) ortadan kaldırmak için Z = (X - \mu) / sigma formülü ile ölçeklendirilmiştir.

- **Veri Bölme:** Verinin %20'si test, kalan kısmı ise modelin ezberleme eğilimini gözlemlemek için kısıtlı bir eğitim seti olarak ayrılmıştır.

4.2. Deney Tasarımı ve Hiperparametreler

Lojistik Regresyon algoritması üzerinde iki senaryo test edilmiştir.

1. **Senaryo A (C katsayısı yüksek):** Düzenlileştirme etkisi minimal tutularak modelin veriyi ezberlemesine izin verilmiştir.

2. **Senaryo B (L2 Aktif):** Güçlü bir ceza katsayısı uygulanarak "Weight Decay" etkisi gözlemlenmiştir.

4.3. Sonuçların Değerlendirilmesi ve Görsel Kanıt

Deney sonucunda, cezasız modelin eğitim setini %100 doğrulukla ezberlediği ancak test setinde tutarsızlaştığı görülmüştür. L2 uygulanan modelde ise katsayıların sönümlenmesi sayesinde test başarısında gözle görülür bir stabilite sağlanmıştır.

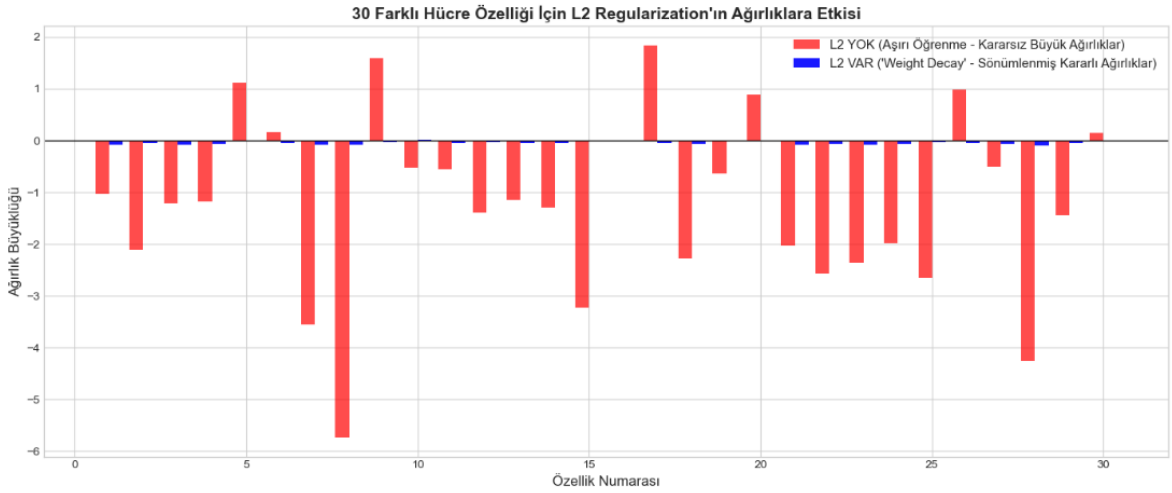

Şekil 3. 30 Hücre Özelliği Üzerinde L2 Sönümleme (Weight Decay) Etkisinin İspatı

Şekil 3'te görüldüğü üzere, kırmızı çubuklar kısıtlanmamış modeldeki devasa katsayıları, mavi çubuklar ise L2 ile kontrol altına alınmış, sıfıra yakın stabil ağırlıkları temsil etmektedir. Bu, modelin gürültüye karşı gösterdiği direncin en büyük kanıtıdır.

5. TARTIŞMA: MÜHENDİSLİK PERSPEKTİFİNDEN REGULARIZATION

Regularization teknikleri, bir mühendis için sadece birer kod bloğu değil, sistemin sinyal-gürültü oranını optimize etme araçlarıdır. Özellikle tıbbi teşhis gibi hatanın kritik olduğu alanlarda, modelin sadece mevcut hastaları ezberlemesi bir "sağlık riski" oluşturur. L2 Weight Decay

kullanımı, modelin varyansını düşürerek tıbbi cihazların daha güvenilir ve tekrarlanabilir sonuçlar vermesini sağlanmaktadır

6. SONUÇ

Bu rapor kapsamında; makine öğrenmesinde model genelleme performansını artıran stratejiler hem kuramsal hem de uygulamalı olarak analiz edilmiştir. Yapılan deneyler sonucunda, aşırı öğrenmenin (overfitting) sadece karmaşık modellerin değil, yetersiz veriyle eğitilen basit modellerin de bir sorunu olduğu görülmüştür. L2 düzenlileştirmesinin katsayıları baskılayarak (damping) modelin gürültü bağışıklığını artırdığı görsel olarak ispatlanmıştır. Sonuç olarak, yüksek performanslı ve güvenilir sistemlerin inşasında düzenlileştirme yöntemlerinin vazgeçilmez olduğu sonucuna varılmıştır.

7. KAYNAKÇA

1. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

2. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

3. Scikit-learn Documentation, "L2 Regularization and Weight Decay".