Makine Öğrenmesine Giriş

Regularization ve Model Genelleme

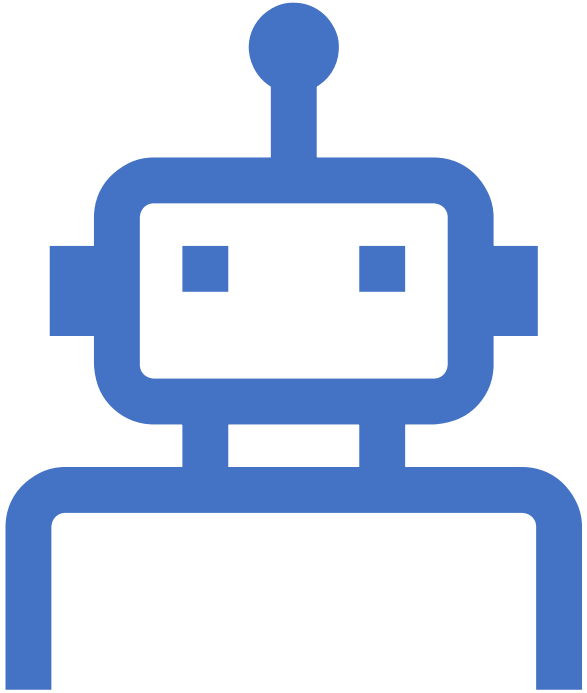

Temel Problem (Overfitting Nedir?)

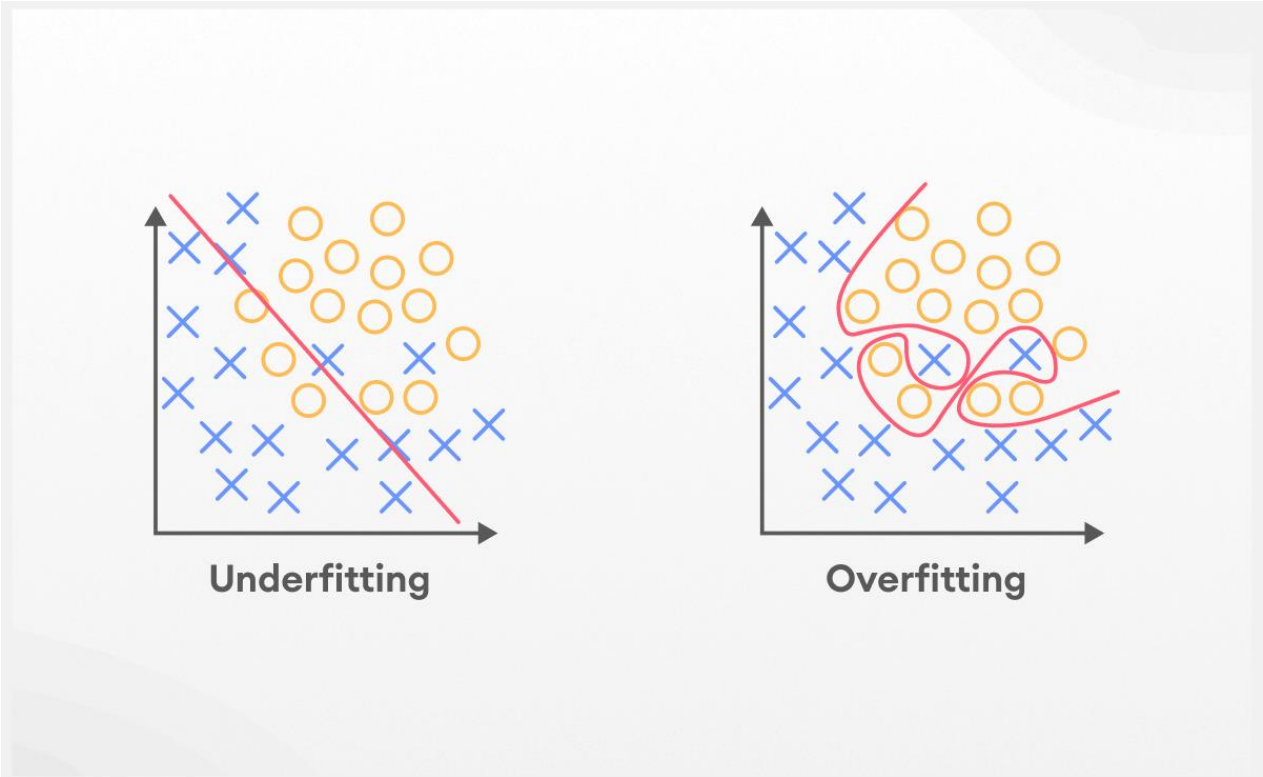

- Öğrenmek yerine "Ezberlemek"
- Eğitim verisinde yüksek, test verisinde düşük başarı
- Gürültüye (parazite) aldanmak

Neden Kaynaklanır?

•**Veri Yetersizliği:** Öğrenilecek örnek sayısının çok az olması.

- **Aşırı Kapasite:** Basit bir problem için çok karmaşık, milyarlarca parametreli model kullanmak.
- **Sonuç:** Boşta kalan işlem gücü, hataları (varyansı) öğrenmeye başlar.

Çözüm Yaklaşımı: Regularization

•Modelin serbestliğini ve karmaşıklığını kısıtlama işlemidir.

- Sisteme matematiksel "Cezalar" eklenir.
- Hedef: Kusursuz ezberi bozup, genelleme yeteneğini (test başarısını) artırmak.

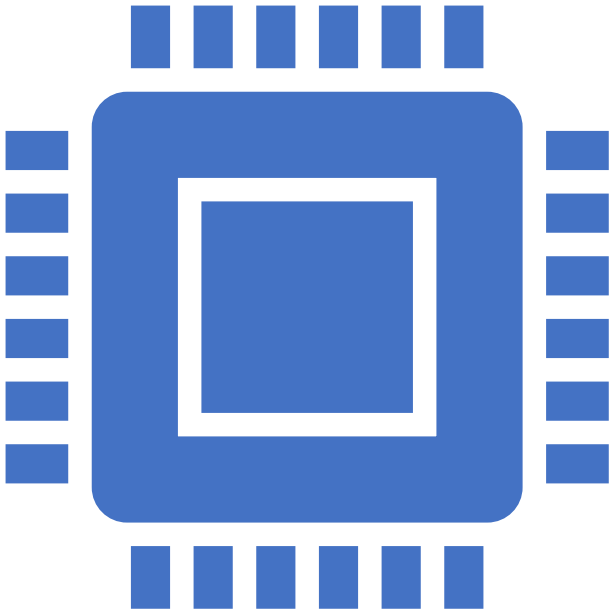

BÖLÜM A: Veri ve Süreç Odaklı Müdahaleler

- **Teknik 1 - Data Augmentation (Veri Zenginleştirme)**
- **Teknik 2 - Early Stopping (Erken Durdurma)**

Sentetik Gürültü Ekleme ve Veri Zenginleştirme (Data Augmentation)

Az olan veriyi sentetik olarak zenginleştirmek.

Döndürme, kırpma, aynalama veya gürültü (noise) ekleme.

Modeli farklı senaryolara ve zorlu şartlara hazırlamak.

Hata Kırılma Noktası ve Eğitimi Kesme (Early Stopping)

Eğitim ve Test hatalarının anlık takibi.

Eğitim hatası düşerken, Test hatasının artmaya başladığı kırılma noktasını bulmak.

Ezberleme başladığı an eğitime zorla son vermek.

BÖLÜM B: Mimari ve Katsayı Odaklı Müdahaleler

- **Teknik 3 - L1 ve L2 Regularization (Weight Decay)**
- **Teknik 4 - Dropout (Ağ Seyreltme)**

L1 ve L2 Regularization

Orijinal hata fonksiyonuna ağırlık cezası eklenir.

L2 (Weight Decay): Aşırı büyüyen katsayıları sönümler, sistemi dengeler.

L1 (Lasso): Tahminde gereksiz olan özellikleri doğrudan "Sıfırlar" (Devre dışı bırakır).

Ağ Seyreltme ile Hata Toleransı (Dropout)

HER EĞİTİM TURUNDA AĞDAKİ NÖRONLARIN BİR KISMINI (ÖRN: %50) RASTGELE KAPATMAK.

NÖRONLAR ARASI EZBERCİ YARDIMLAŞMAYI (CO-ADAPTATİON) KIRMAK.

SİSTEME HATA TOLERANSI (FAULT TOLERANCE) KAZANDIRMAK

Mini Proje (Laboratuvar Uygulaması)

Mini Proje: Kanser Hücresi Tespiti

Veri Seti: Breast Cancer (30 Özellik)

Hedef: İyi Huylu / Kötü Huylu ayrımı

Uygulama: Modeli bilerek ezberlemeye zorlamak

Kodlama Sonuçları

***Model 1 (Cezasız):** Eğitimde %100 (Ezber), Testte Başarısız.

***Model 2 (L2 Uygulanmış):** Test başarısında gözle görülür art

```
=== BAŞARI ORANLARI KARŞILAŞTIRMASI ===

1. Ceza Olmayan Model (Overfit):
   Eğitim Başarısı: %100.0 (Eğitim verisini kusursuz ezberledi)
   Test Başarısı  : %95.2 (Görmediği veride başarısız oldu)

2. L2 Regularization (Weight Decay) Uygulanmış Model:
   Eğitim Başarısı: %88.0 (Ezberleme engellendi, oran düştü)
   Test Başarısı  : %86.7 (Genelleme yeteneği arttı, testte DAHA BAŞARILI!)
```

Görsel Kanıt (Weight Decay)

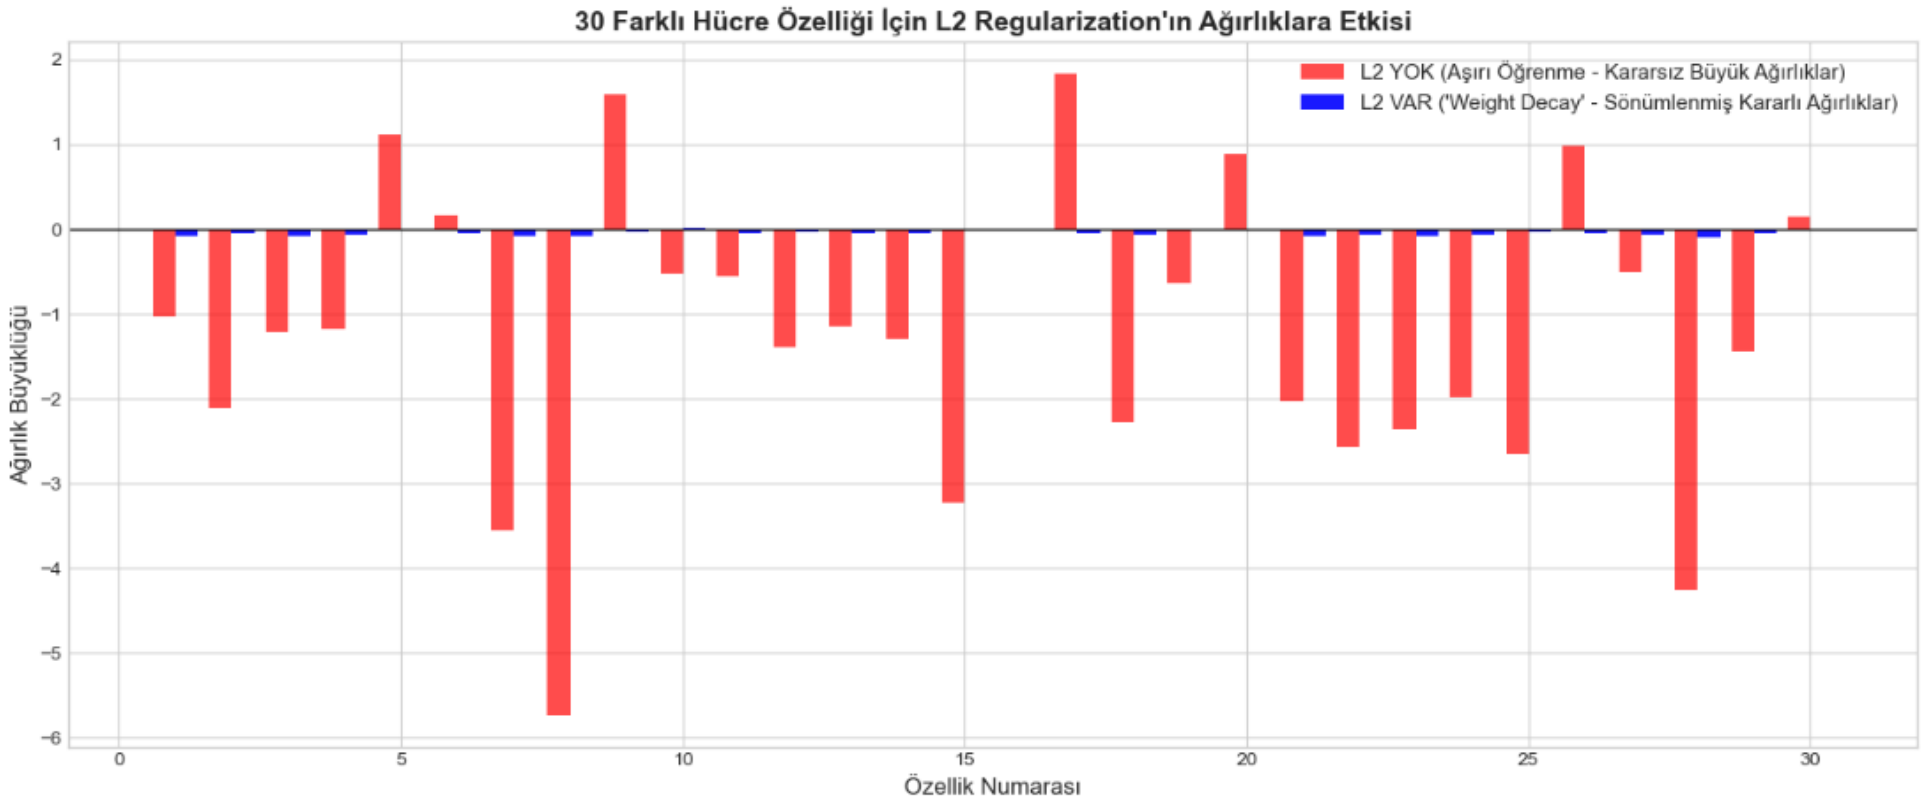

Gerçek Dünyada Ne İşe Yarar?

- Radar ve Sonarlarda parazit engelleme
- Tıbbi cihazlarda daha net teşhis
- Kontrol sistemlerinde kararlılık (Stability)

Tahir Kemal Eşiyok

Dinlediğiniz için teşekkürler