ISPARTA UYGULAMALI BİLİMLER ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ

MAKİNE ÖĞRENMESİNE GİRİŞ

Makine Öğrenmesi Modellerinde Aşırı Öğrenme (Overfitting) Problemi ve Düzenlileştirme (Regularization) Tekniklerinin Kavramsal Analizi

Dersin Öğretim Üyesi: Dr. Öğr. Üyesi Ali Şentürk

Hazırlayan
Deniz Çiyiltepe
2322705035

Nisan-2026

ŞEKİLLER LİSTESİ

Şekil 1. Aşırı Öğrenme/Eksik Öğrenme 2
Şekil 2. Eğitim ve doğrulama hata eğrilerinin analizi ve ideal erken durdurma noktasının tespiti 4
Şekil 3. Korumasız standart mimari (sol) ile eğitim sırasında nöronları kapatılmış Dropout mimarisinin (sağ) karşılaştırması 5
Şekil 4. Eğitim turları boyunca korumasız model (kırmızı kesikli çizgi) ile Dropout uygulanan Korumalı modelin (yeşil düz çizgi) performans analizi 6

İÇİNDEKİLER

ŞEKİLLER LİSTESİ i

1. GİRİŞ 1

2. TEMEL KAVRAMLAR 1

3. YÖNTEM VE MODEL AÇIKLAMASI: DÜZENLİLEŞTİRME (REGULARİZATİON) TEKNİKLERİ 2

3.1. L1 ve L2 Regularization 3

3.2. Data Augmentation (Veri Çoğaltma Tekniği) 3

3.3. Early Stopping (Erken Durdurma) 3

3.4. Dropout (Seyreltme Yöntemi) 4

4. UYGULAMA ALANLARI VE ENDÜSTRİYEL ÖNEMİ 5

5. YAPILAN MİNİ PROJE AÇIKLAMASI VE SİMÜLASYON 6

6. SONUÇ 7

7. KAYNAKÇA 7

1. GİRİŞ

Günümüzde makine öğrenmesi ve derin öğrenme sistemleri, karmaşık problemleri çözmek için muazzam bir potansiyel sunmaktadır. Bu sistemlerin temel amacı, eldeki eğitim verilerini analiz ederek arka planda yatan evrensel kuralları keşfetmek ve bu kuralları kullanarak daha önce hiç karşılaşmadığı yeni veriler üzerinde doğru ve güvenilir tahminler yapabilmektir. Literatürde bu yetenek "genelleme" olarak adlandırılır. Ancak, yapay sinir ağları gibi yüksek kapasiteli modellerin eğitimi sırasında karşılaşılan en kritik ve yıkıcı sorunların başında "Aşırı Öğrenme" gelmektedir.

Aşırı öğrenme, esnekliği çok yüksek olan bir modelin, verinin altındaki gerçek mantığı öğrenmek yerine, eğitim setindeki rastgele hataları, anormallikleri ve pürüzleri ezberlemesi durumudur. Bu durum, bir öğrencinin sınavdaki soruların mantığını kavramak yerine sadece cevap şıklarını ezberlemesine benzer. Laboratuvar ortamında, eğitim verileri üzerinde %100'e yakın, kusursuz bir başarı gösteren bu ezberci modeller, gerçek dünyanın kaotik ve değişken verileriyle karşılaştıklarında tamamen çuvallarlar.

Özellikle sensör verilerinin sürekli aktığı endüstriyel sistemlerde, otonom araçlarda veya giyilebilir sağlık cihazlarında, modelin gürültüyü ezberlemesi sadece performans düşüklüğüne değil, hayati güvenlik zafiyetlerine de yol açabilir. Bu raporun amacı; makine öğrenmesinde model esnekliği ile veri miktarı arasındaki hassas dengeyi incelemek, aşırı öğrenme krizini formüllere boğulmadan kavramsal bir çerçevede ele almak ve bu sorunu çözmek için geliştirilen "Düzenlileştirme" tekniklerinin işleyişini deneysel bir proje üzerinden detaylandırmaktır.

2. TEMEL KAVRAMLAR

Makine öğrenmesinde bir modelin başarısı ve güvenilirliği, veriyi anlama biçimini tanımlayan üç temel kavram üzerinden değerlendirilir. Bu kavramlar, modelin karmaşıklığı ile verinin içerdiği bilgi arasındaki ilişkiyi ifade eder.

- **Eksik Öğrenme:** Bu durum, kurulan yapay zeka modelinin kapasitesinin çözülmek istenen problem için yetersiz kalmasıdır. Model o kadar basittir ki, verinin içindeki karmaşık ilişkileri ve temel kuralları yakalayamaz. Sonuç olarak model, hem üzerine çalıştırıldığı eğitim verisinde hem de test verisinde yüksek oranda hata üretir. Sorunun

çözümü genellikle daha derin, daha fazla nöron içeren karmaşık mimariler kurmaktan geçer.

- **Aşırı Öğrenme (Overfitting):** Kapasitesi çok yüksek, devasa yapay sinir ağlarının küçük veri setleriyle eğitilmesi durumunda ortaya çıkar. Ağın işlem gücü o kadar fazladır ki, ana kuralları öğrenmekle yetinmez, veri setindeki sensör sapmalarını, ölçüm hatalarını ve arka plan gürültülerini de "kesin bir kuralmış gibi" hafızasına kazır. Bu durumda modelin eğitim hatası sıfıra doğru hızla düşerken, daha önce hiç görmediği bağımsız test verilerindeki hata oranı dramatik bir şekilde yükselir.
- **Genelleme Yeteneği (Generalization):** Her yapay zeka mühendisinin ulaşmayı hedeflediği ideal durumdur. Modelin veri setindeki gürültüleri görmezden gelerek, yalnızca genel geçer kuralları ve özellikleri öğrenmesidir. Genelleme yeteneği yüksek bir model, esnektir ve dış dünyadaki değişimlere karşı son derece dirençlidir.

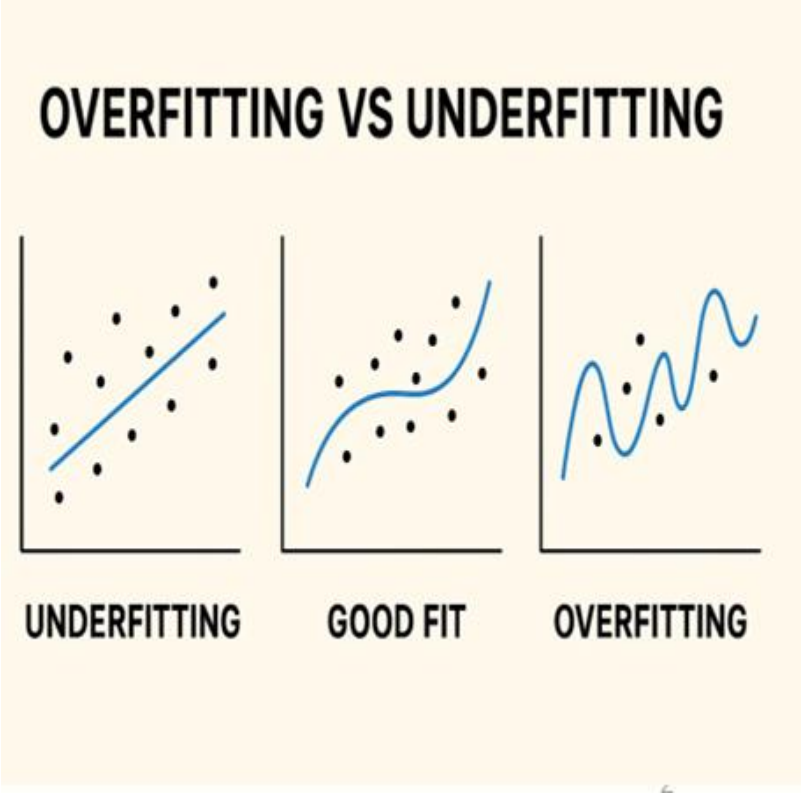

Şekil 1. Aşırı Öğrenme/Eksik Öğrenme

3. YÖNTEM VE MODEL AÇIKLAMASI: DÜZENLİLEŞTİRME (REGULARİZATİON) TEKNİKLERİ

Aşırı öğrenmeyi engellemenin en temel yolu, modeli zorlu koşullar altında çalışmaya mecbur bırakmak ve kapasitesini yapay kısıtlamalarla kontrol altına almaktır. Literatürde modeli

"terbiye etme" veya "cezalandırma" stratejileri olarak bilinen bu yöntemler bütününe Regularization denir. Başlıca yöntemler kavramsal olarak aşağıda incelenmiştir.

3.1. L1 ve L2 Regularization

Yapay sinir ağlarındaki nöronlar, veriden çıkardıkları anlamları "ağırlık" adı verilen bağlantı katsayıları aracılığıyla birbirlerine aktarırlar. Eğer bir ağ aşırı öğrenmeye girmişse, bazı nöronların ağırlıkları devasa boyutlara ulaşmış ve tüm sistemi domine etmeye başlamış demektir. L1 ve L2 teknikleri, ağın hata hesaplama mekanizmasına ekstra bir "ceza faturası" keserek bu büyümeyi engeller.

- **L1 Regularization:** Bu teknik acımasız bir yöneticisi gibidir. Ağdaki nöronların ağırlıklarını sürekli olarak küçültmeye çalışır. Önemsiz veya veriye az katkı sağlayan bağlantıları tespit ettiğinde onların ağırlığını tamamen sıfıra indirerek o nöronları sistemden siler. Bu özelliği sayesinde model, sadece en hayati özellikleri elinde tutar.
- **L2 Regularization:** L1'e kıyasla daha adaletli bir yaklaşım sergiler. Çok fazla güçlenen ağırlıklara çok büyük cezalar keserken, daha zayıf bağlantılara daha küçük cezalar uygular. Amacı hiçbir bağlantıyı tamamen sıfırlamak değil, hepsini dengeli bir şekilde küçülterek ağın kararlı ve pürüzsüz bir şekilde öğrenmesini sağlamaktır.

3.2. Data Augmentation (Veri Çoğaltma Tekniği)

Makine öğrenmesi modelleri veriye açtır. Eğer eldeki veri seti küçükse, ezberlemek kaçınılmazdır. Veri çoğaltma tekniği, eldeki sınırlı veriyi sentetik olarak manipüle ederek modelin aynı veriyi farklı açılardan görmesini sağlar. Örneğin, bir nesne tanıma algoritması eğitilirken, orijinal fotoğraflar rastgele döndürülür, yakınlaştırılır, parlaklıkları değiştirilir veya üzerlerine yapay piksel gürültüleri eklenir. Model, sürekli şekil değiştiren bu veriler karşısında belirli bir noktayı ezberleyemez; bunun yerine nesnenin asıl geometrisine ve değişmez karakteristik özelliklerine odaklanmak zorunda kalır.

3.3. Early Stopping (Erken Durdurma)

Ağın eğitim süreci zaman içinde ilerleyen bir yoldur. Model eğitim verisini tanıdıkça hata payı düşer. Erken durdurma yöntemi, bu süreci bir gözlemci gibi anlık olarak takip eder. Algoritma, ağa sürekli olarak daha önce hiç görmediği bir "doğrulama seti" sunar. Eğitim hatası düşmesine rağmen, doğrulama setindeki hata payının düşmeyi bırakıp aniden yükselişe geçtiği bir "kırılma noktası" vardır. Bu nokta, ağın öğrenmeyi bırakıp ezberlemeye başladığı andır. Early Stopping

algoritması, bu tehlikeyi sezdiği saniye eğitimin fişini çeker ve sürecin daha da kötüye gitmesini engeller.

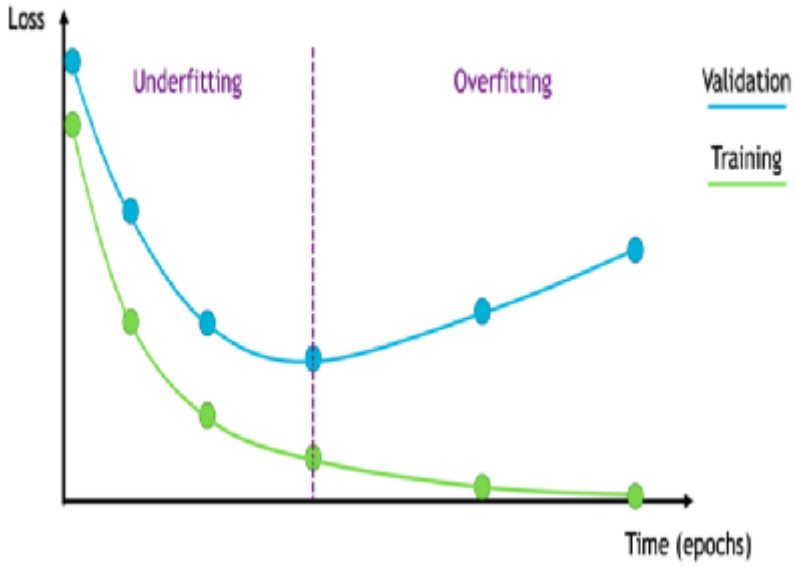

Şekil 2. Eğitim ve doğrulama hata eğrilerinin analizi ve ideal erken durdurma noktasının tespiti

3.4. Dropout (Seyreltme Yöntemi)

Derin öğrenme devriminin en kritik keşiflerinden biri olan Dropout, bu projede de ana odak noktası olarak kullanılmıştır. Dropout tekniği, bir takımın içindeki tembelleşme ve aşırı bağımlılık sorununu çözmeyi hedefler. Geleneksel bir sinir ağında bazı nöronlar çok güçlü özellikler öğrenirse, diğer nöronlar bu güçlü nöronlara bağımlı hale gelir ve çalışmayı bırakır.

Dropout, eğitim süreci boyunca ağın içindeki nöronların (örneğin %50'sini) tamamen rastgele bir şekilde devre dışı bırakır. Ağ içindeki bilgi akışı her adımda sürekli değişen, sakatlanmış ve eksik bırakılmış dar kanallardan geçmek zorunda kalır. Bugün aktif olan bir nöron, bir sonraki döngüde kapatılmış olabilir. Bu acımasız çalışma koşulu, ağdaki tüm nöronların hayatta kalabilmek için güçlü ve birbirinden bağımsız özellikler öğrenmesini zorunlu kılar. Test ve kullanım aşamasına geçildiğinde ise kısıtlamalar kaldırılır, tüm nöronlar aktif edilir ve ortaya son derece dirençli, dış etkenlerden etkilenmeyen güçlü bir model çıkar.

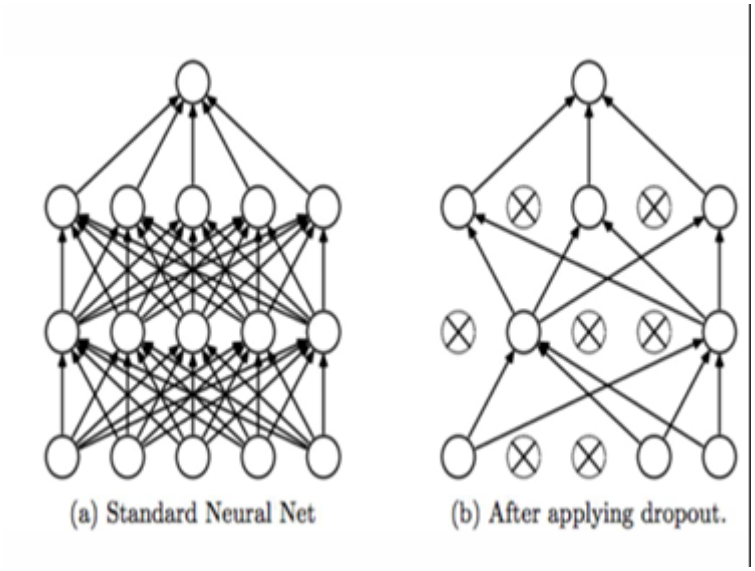

Şekil 3. Korumasız standart mimari (sol) ile eğitim sırasında nöronları kapatılmış Dropout mimarisinin (sağ) karşılaştırması

4. UYGULAMA ALANLARI VE ENDÜSTRİYEL ÖNEMİ

Düzenlileştirme teknikleri, akademik birer deney olmaktan çıkmış, günümüz endüstrisinde güvenlik açısından mecburi birer standart haline gelmiştir. Bu durumun en çarpıcı örnekleri, sensör verilerinin anlık olarak işlendiği gerçek zamanlı sistemlerde görülmektedir.

- **Otonom Sürüş Sistemleri:** Sürücüsüz bir aracın kamera tabanlı nesne tanıma modelini düşünelim. Eğer bu model, laboratuvar ortamında temiz hava koşullarında çekilmiş fotoğraflarla, hiçbir regularization kısıtlaması olmadan eğitilirse sistemi ezberler. Model, yoldaki bir yaya geçidini tanımak yerine, o yaya geçidinin yanındaki ağaç gölgesini ezberleyebilir. Araç karlı, yağmurlu veya ağaç olmayan farklı bir kavşağa girdiğinde sistemi tanıyamaz ve hayati kazalara sebep olur. Dropout ve Veri Çoğaltma teknikleri, modeli arka plandaki bu tehlikeli gürültüleri göz ardı etmeye ve doğrudan tabelanın veya yayanın ana geometrisine odaklanmaya zorlar.
- **Nesnelerin İnterneti ve Akıllı Panolar:** Akıllı elektrik panoları veya otonom erken uyarı cihazları gibi Edge Computing tabanlı sistemlerde sensörler (ark, ısı, akım sensörleri vb.) bulunur. Bu cihazlar elektromanyetik gürültünün yüksek olduğu sanayi ortamlarında çalışır. Kurulan yapay zeka algoritması bu gürültüleri "arıza" olarak ezberlerse sistem sürekli yanlış alarm (false-positive) üretir. L2 Regularization ve Dropout gibi yöntemler, modeli sensörlerin ürettiği anlık parazitlere karşı sağırlaştırarak, sadece gerçek ve sistemsel arıza sinyallerini tespit etmesini sağlar.

5. YAPILAN MİNİ PROJE AÇIKLAMASI VE SİMÜLASYON

Literatürde açıklanan aşırı öğrenme krizini ve Dropout kısıtlamasının model başarısı üzerindeki etkisini deneysel olarak ispatlamak amacıyla bir makine öğrenmesi projesi geliştirilmiştir.

- **Proje Amacı ve Veri Seti:** Çalışmanın amacı, korumasız bir ağ ile Dropout (%50 seyreltme) uygulanan bir ağın performans kıyaslamasını yapmaktır. Projede, endüstri standardı olan "Fashion MNIST" veri seti kullanılmıştır. Bu set, makine öğrenmesi algoritmalarını test etmek için özel olarak hazırlanmış; 10 farklı kıyafet türünü (tişört, pantolon, ayakkabı vb.) içeren, toplamda 60.000 eğitim ve 10.000 test görselinden oluşan yapılandırılmış bir görüntü kümesidir.
- **Uygulanan Yöntem ve Kodlama Mimarisi:** Python programlama dili ve modern derin öğrenme kütüphaneleri kullanılarak Jupyter Notebook ortamında iki simülasyon modeli inşa edilmiştir. Birinci mimari ("Korumasız Model"), veriyi hiçbir engele takılmadan işleyen saf bir çok katmanlı yapay sinir ağıdır. İkinci mimari ("Korumalı Model") ise, aynı nöron dizilimine sahip olmasına rağmen, her gizli katmanında bilgiyi %50 oranında bloke eden Dropout kısıtlayıcıları ile donatılmıştır. Her iki model de eşit şartlarda, aynı tur sayısı boyunca eğitilmiştir.
- **Elde Edilen Sonuçlar ve Program Çıktıları:** Eğitim döngüleri tamamlandıktan sonra, modellerin hiç görmedikleri test verileri üzerindeki başarı oranları grafiklere dökülmüş ve analiz edilmiştir.

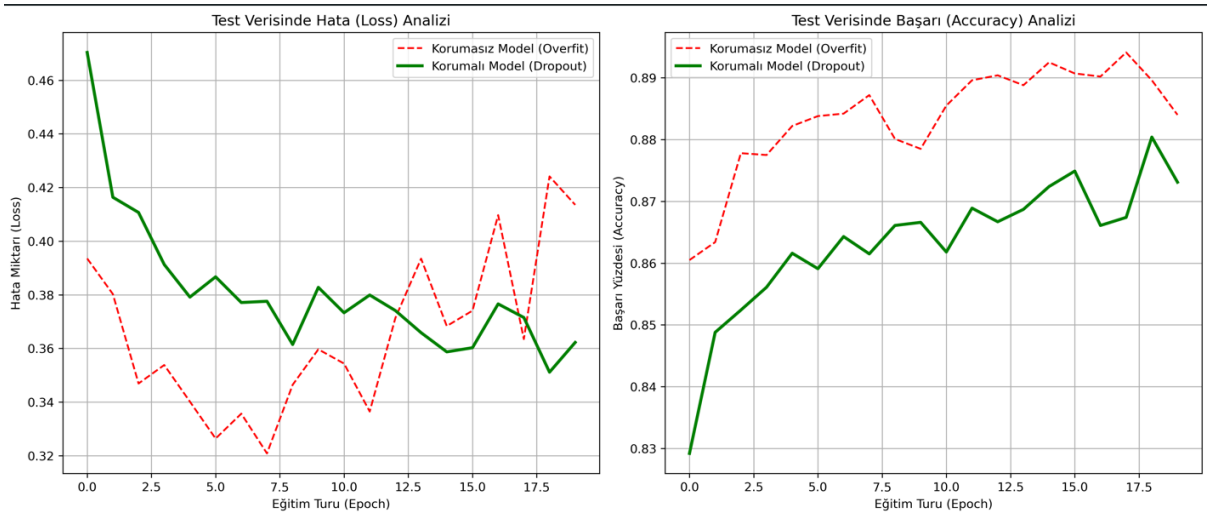

Şekil 4. Eğitim turları boyunca korumasız model (kırmızı kesikli çizgi) ile Dropout uygulanan Korumalı modelin (yeşil düz çizgi) performans analizi

Grafiksel analiz sonuçlarına bakıldığında, Korumasız Ağ'ın (kırmızı) test hatasının ilk birkaç turdan sonra dramatik şekilde fırladığı, başarısının ise istikrarsız dalgalanmalar gösterdiği saptanmıştır. Bu durum aşırı öğrenmenin tipik bir kanıtıdır; model eğitim verisinde kusursuzlaşırken gerçek dünyada körleşmiştir. Buna karşın, Dropout uygulanan Korumalı Ağ (yeşil), test hatasını eğitim boyunca dengeli bir şekilde aşağı çekmeyi başarmış ve grafiğin sağında görüldüğü üzere nihai başarı yüzdesini belirgin oranda maksimize etmiştir. Kısıtlamalar, modelin ezber yapmasını kesin olarak engellemiştir.

6. SONUÇ

Bu raporda detaylandırılan kavramsal incelemeler ve gerçekleştirilen pratik simülasyon projesi, makine öğrenmesi mühendisliğinde çok net bir gerçeği ortaya koymaktadır: Modellerin fiziksel donanım veya işlemci kapasitelerini artırmak tek başına başarı getirmez. Kontrolsüz bırakılan yüksek kapasite, daima verideki hataları ve gürültüleri ezberlemeye meyillidir. Gerçek dünyada sahaya sürülecek güvenilir otonom sistemler ve akıllı donanımlar tasarlayabilmek için L1/L2, Erken Durdurma ve özellikle Dropout gibi düzenlileştirme mekanizmaları vazgeçilmezdir. Proje çıktılarımız, eğitim sürecine bilinçli olarak dahil edilen kaosun (nöron kapatmanın), modelin genel zekasını ve test verilerindeki esnekliğini doğrudan artırdığını şüpheye yer bırakmayacak şekilde kanıtlamıştır.

7. KAYNAKÇA

[1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

[2] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *The Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929-1958, 2014.

[3] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.