**Makine Öğrenmesine Giriş**

Hafta 10, Sunum 3: Model Eğitimi ve Optimizasyon

Hazırlayan: Enes AÇAR, 2322705032

# Input Scaling (Ölçeklendirme)

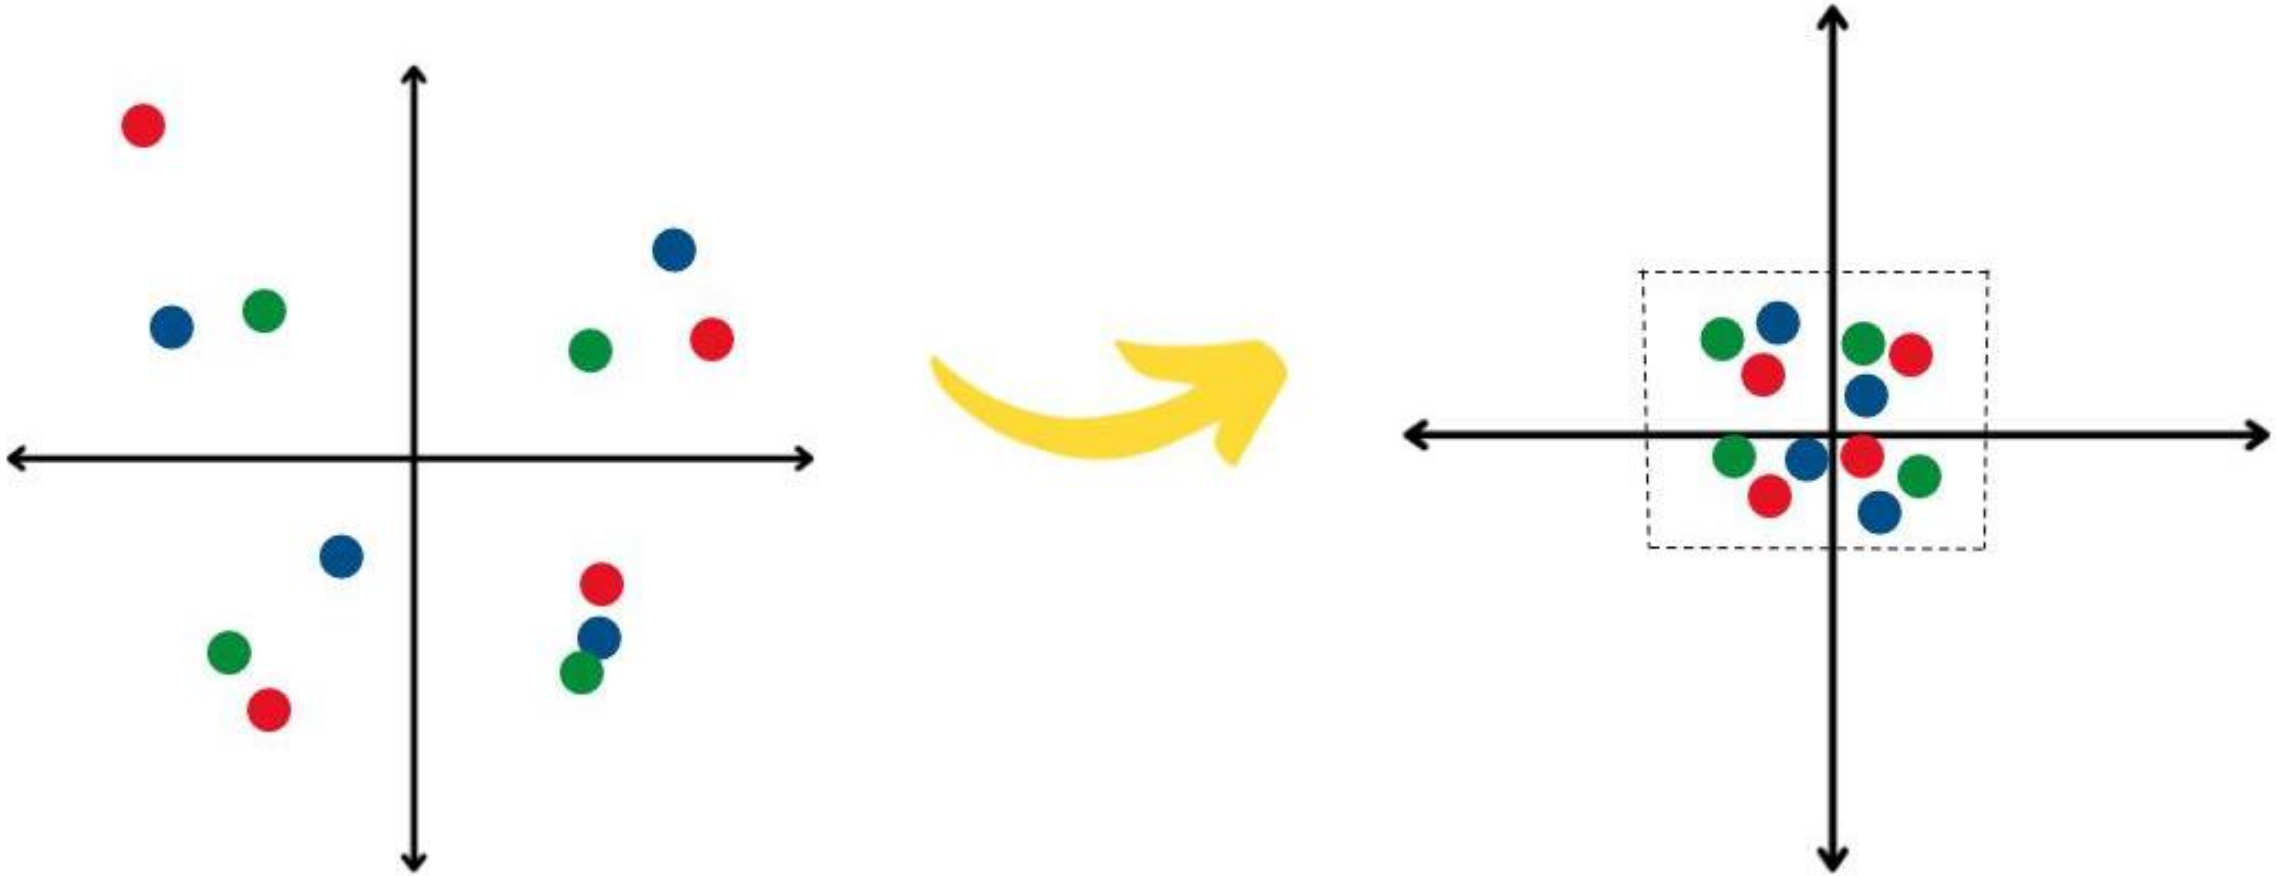

**Amaç:** en temelinde değişkenler arasındaki ölçüm farklılığını gidermektir. Yani kullanılacak olan modellerin ölçüm problemlerine maruz kalmadan, büyüklük/küçüklük algılarında yanılsamalara uğramadan, değişkenlere kendi içindeki dağılımlarını korunmakla birlikte eşit şartlarda yaklaşmasıdır.

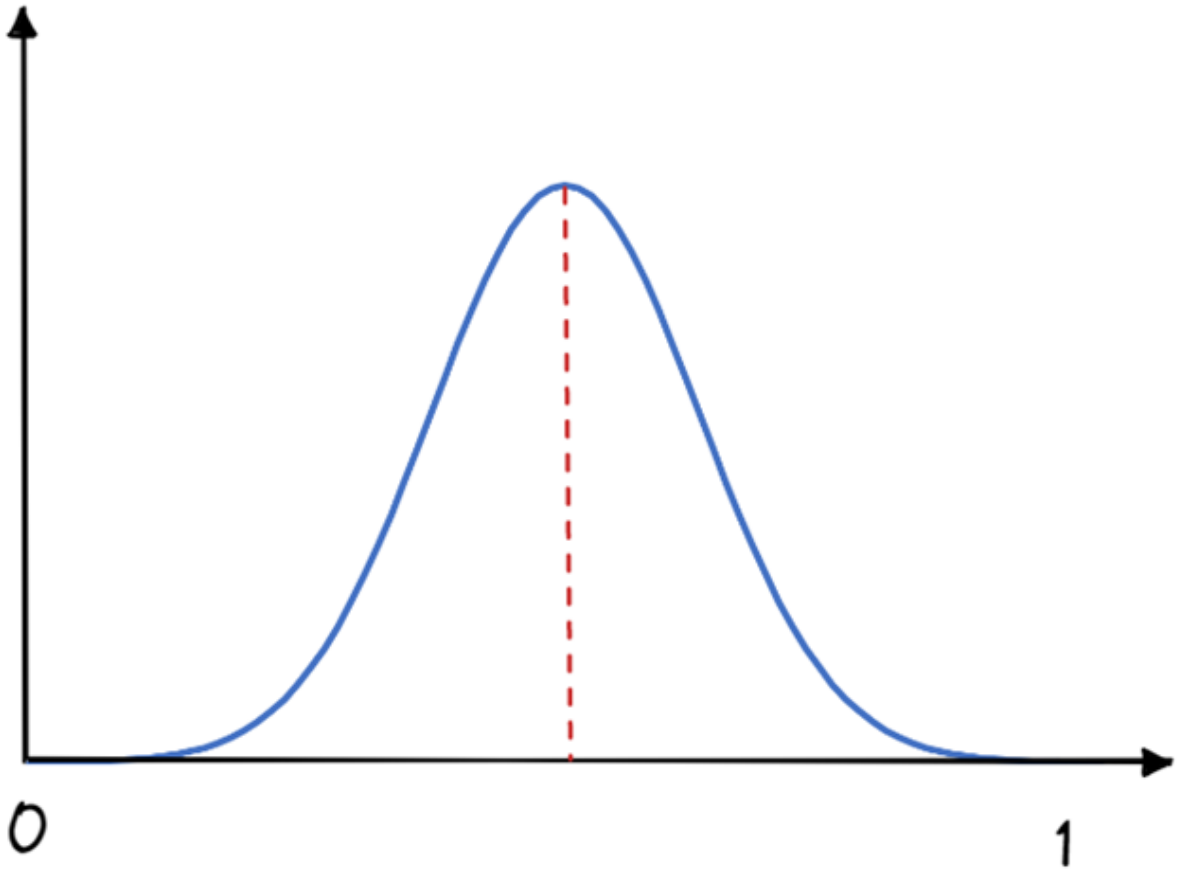


**Normalization:**

Veriyi 0 ile 1 arasına sıkıştırma işlemidir.

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

| | Normali. | |
|---|---|---|
| 1 | 0 | min: 1 |
| 3 | 2/7 | |
| 5 | 4/7 | |
| 7 | 6/7 | |
| 8 | 1 | max:8 |

Bu formüle yukarıdaki değerleri uyguladığımızda:
Xmin: 1
Xmax: 8 olarak aldığımızda
Normali. kısmında normalizasyon değerlerini görebiliriz.

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

# Gradient Descent (Gradyan İnişi)

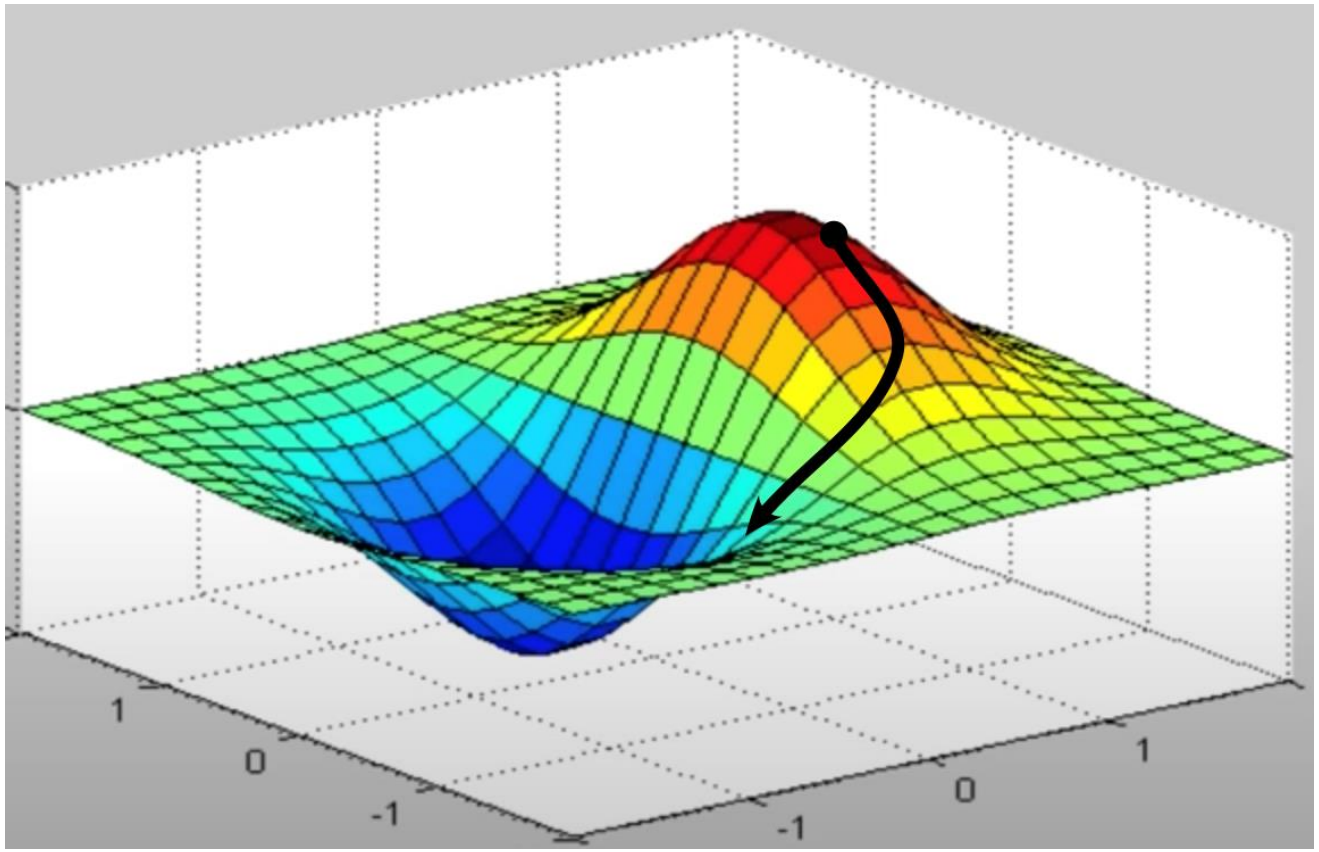


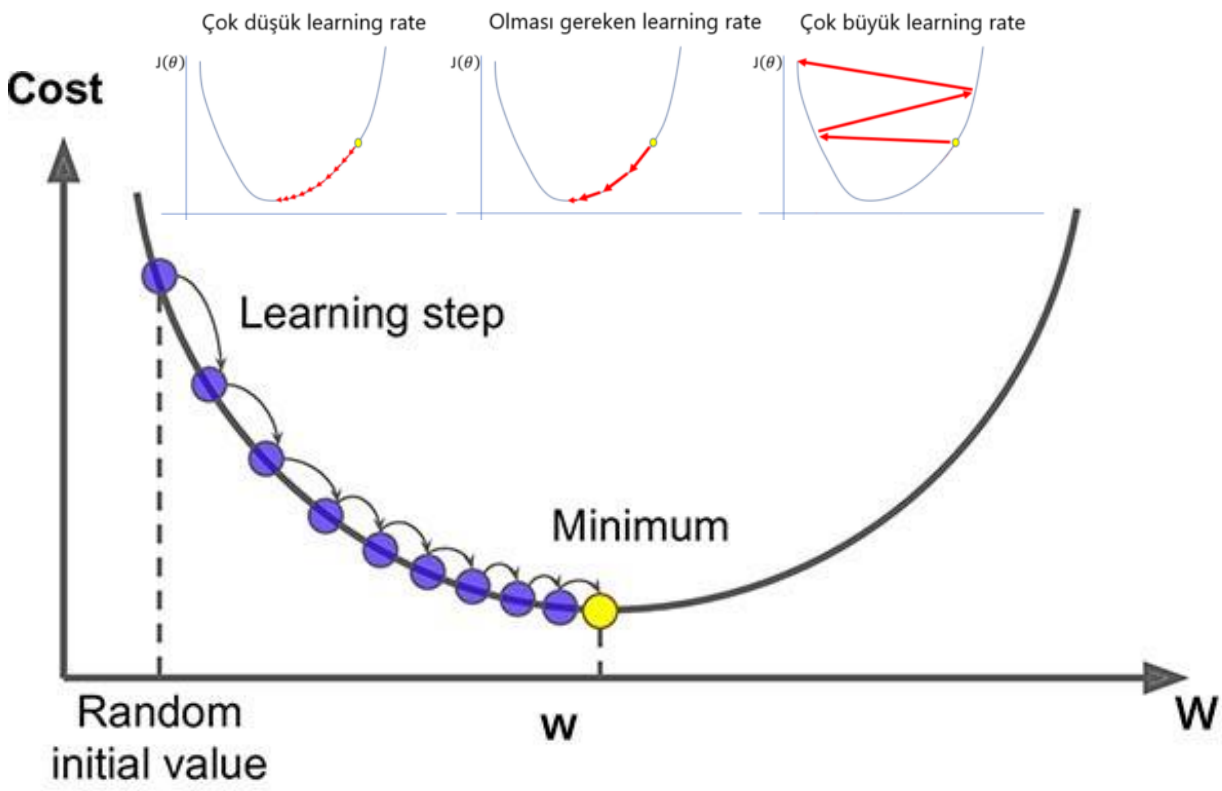


## Gradient descent algorithm

Repeat until convergence

$$w = w - \alpha \boxed{\frac{\partial}{\partial w} J(w,b)}$$

$$b = b - \alpha \frac{\partial}{\partial b} J(w,b)$$

Learning rate

Derivative

Simultaneously update w and b

α: Öğrenme oranı (büyükse ıskalar, küçükse çok yavaş ilerler.)

w: Ağırlık (parametrenin ne kadar etkilediğini gösterir.)

b: Bias

# Gradient Problemleri

Chain rule: son katmandan ilk katmana çarpılarak gelmesi

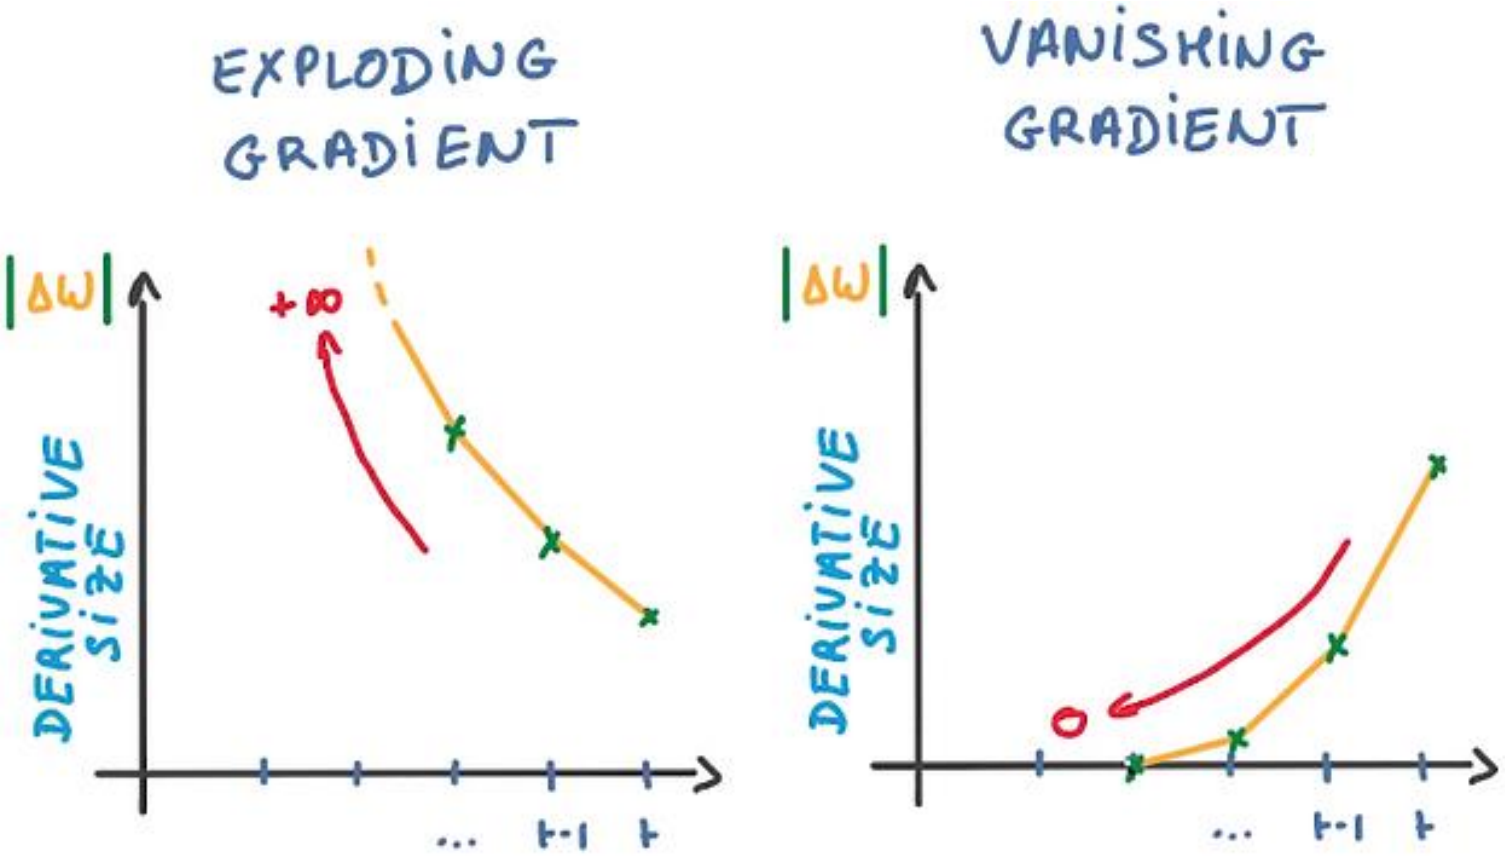


**Exploding Gradient:**
Grafikte görüldüğü gibi katmanda geriye gidildikçe türev büyüklüğü hızlıca artar ve gradyan sonsuza yaklaşır. Gradyan o kadar büyür ki ağırlıklar(w) bir o kadar değişken olur. Bu da verimli öğrenmeye engeller

**Vanishing Gradient:**
Grafikte görüldüğü gibi katmanda geriye gidildikçe türev büyüklüğü hızlıca azalır ve gradyan sıfıra yaklaşır. Gradyan o kadar küçülür ki ağırlıklar(w) güncellenemez hale gelir. Bu da verimli öğrenmeye engeller.

# Weight Initialization (Ağırlık Başlatma)

$$W = \begin{bmatrix} W_{11} & W_{12} & \cdots & W_{1j} \\ W_{21} & W_{22} & \cdots & W_{2j} \\ \vdots & \vdots & \cdots & \vdots \\ W_{n1} & W_{n2} & \cdots & W_{nj} \end{bmatrix}$$

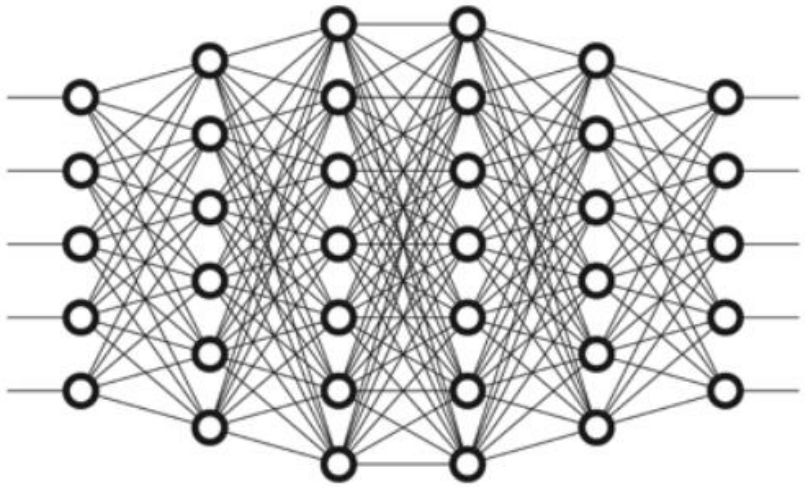

w'e verilen ilk sayısal değerdir, eğer 0 değeri verilirse tüm nöronlar aynı şeyi öğrenir veya yanlış değer verilirse gradient descent problemleri yaşanır.

## a. Xavier (Glorot) Initialization

Sigmoid ve Tanh aktivasyon fonksiyonları kullanıldığında

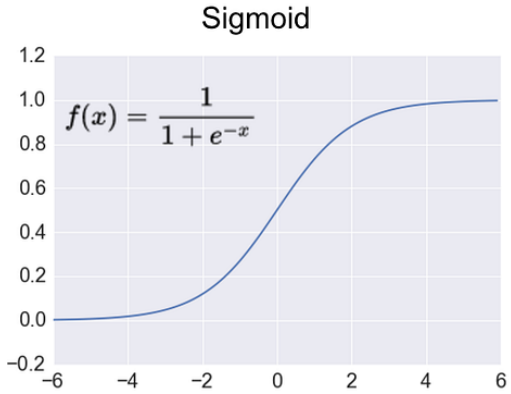


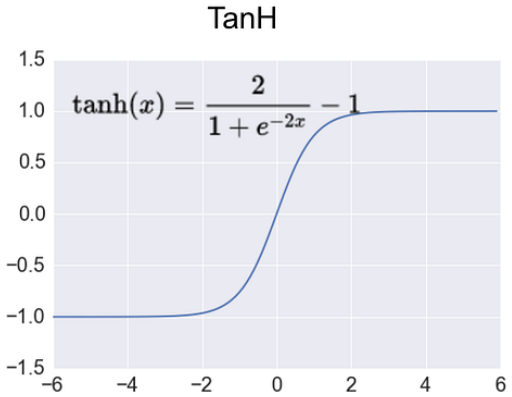


## b. He Initialization

ReLU aktivasyon fonksiyonu kullanıldığında

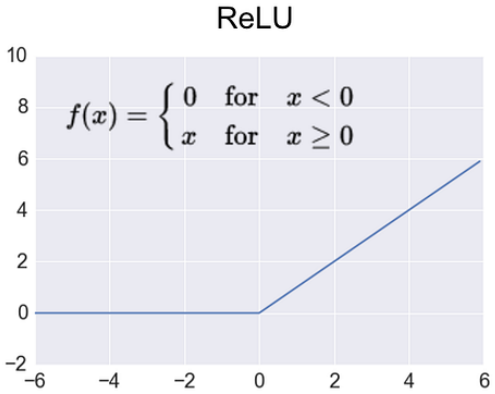

# Gradient Descent Türleri

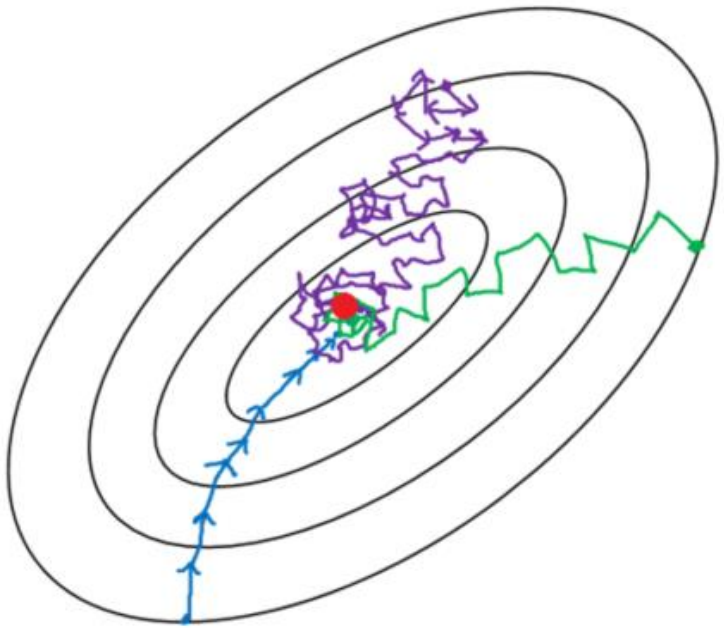

**Batch Gradient Descent:**
Tüm veri setini kullanarak gradyan hesaplar ve sadece bir kez güncelleme yapar. Kararlıdır ve gürültüsü azdır. Minimum noktaya direkt gider. Ayrıyeten yavaştır, büyük veri setlerinde çok yavaş ve hesaplama açısından maliyetlidir.

**Mini-batch Gradient Descent:**
Tüm veri setini bölerek gradyan hesaplar ve her böldüğünde güncelleme yapar. Daha sık güncelleme yaptığı için Batch'a göre daha hızlıdır.

**Stochastic Gradient Descent (SGD):**
Veri setinden sadece bir örnek veri seçer, bunun üzerinden gradyan hesaplar ve güncelleme yapar. Çok hızlıdır, ancak gürültülü güncellemeler yapar, zikzak çizerek ilerler.

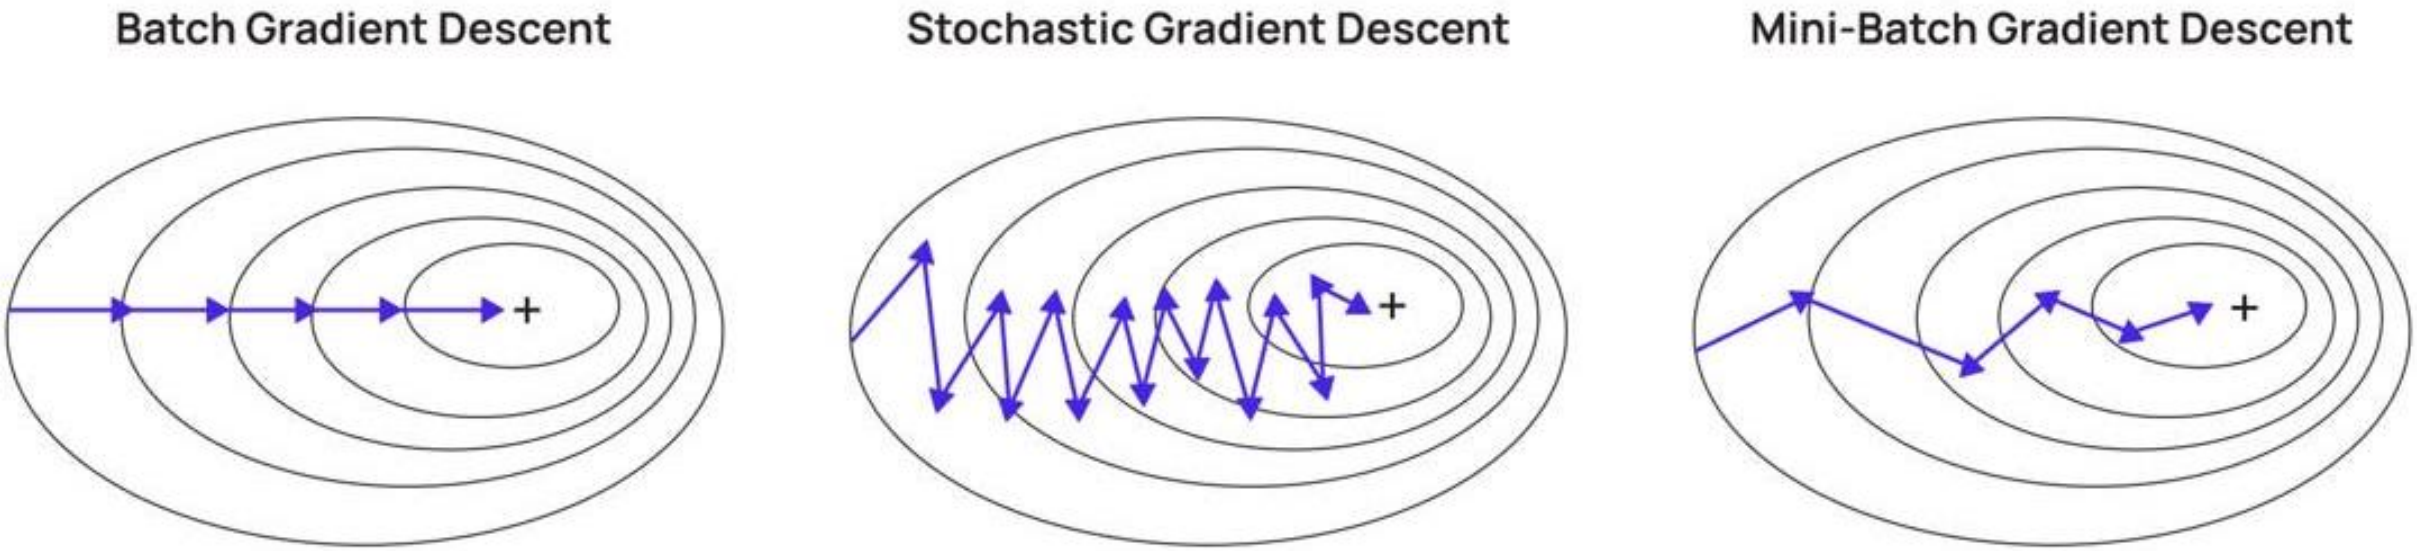

# Learning Rate ve Batch Size

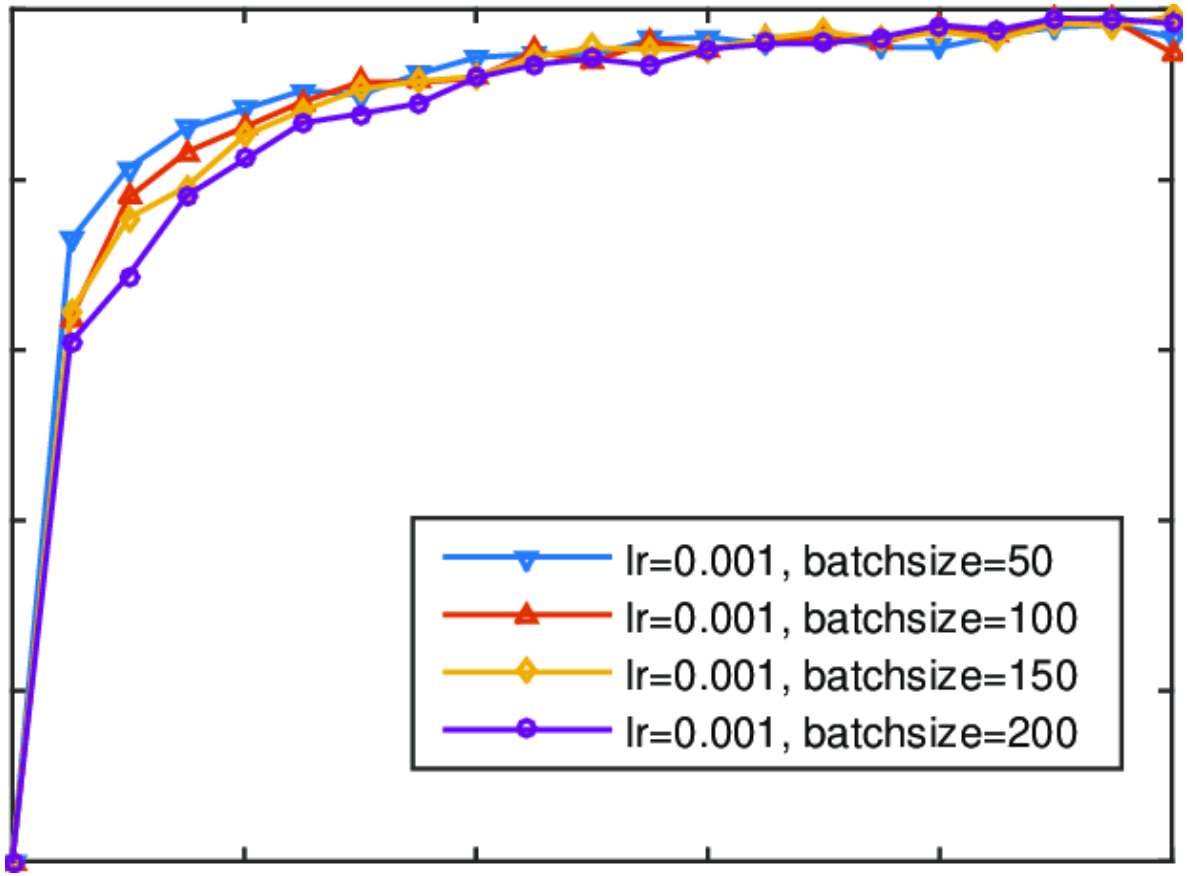


Şekilde sabit learning rate'de batch size'lerin etkisi

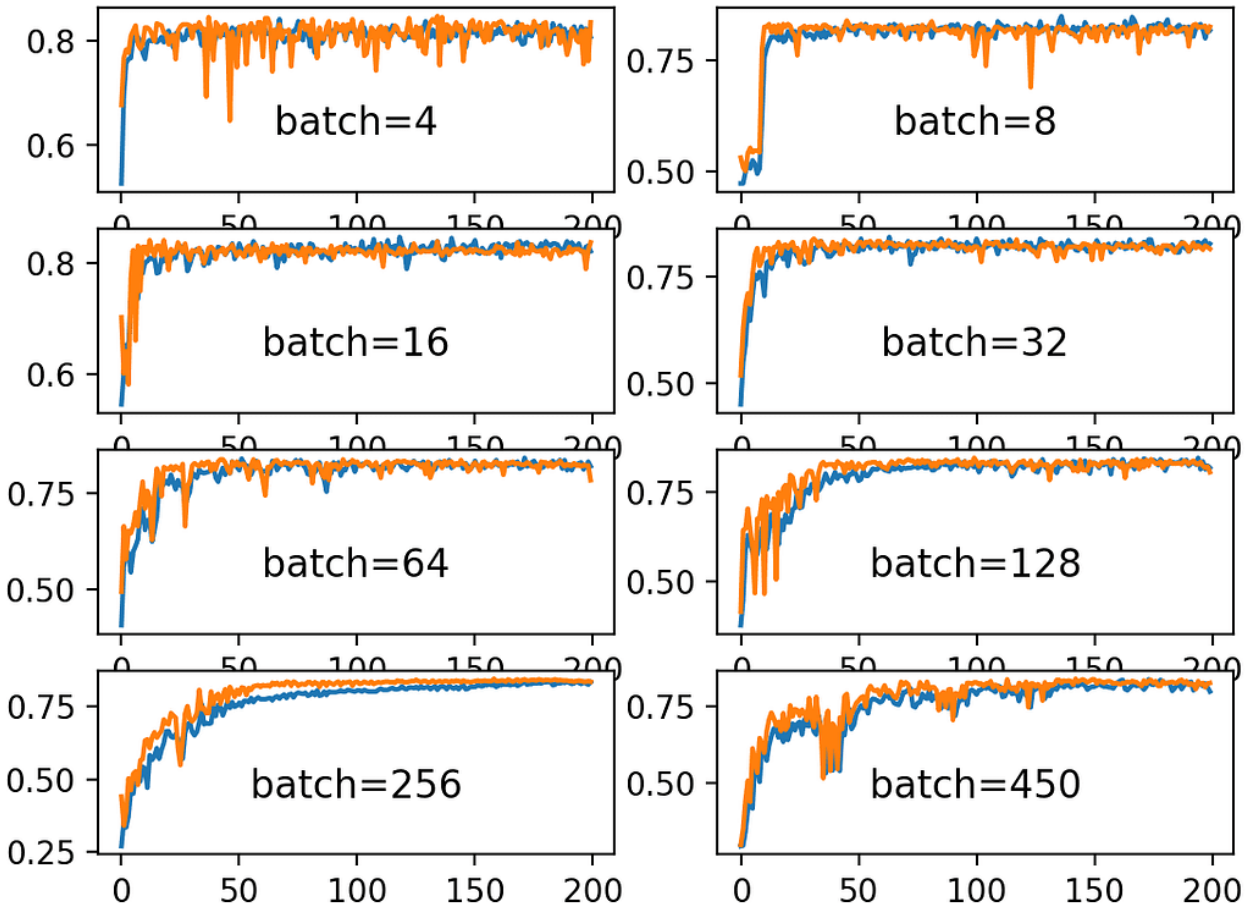


Şekilde 8 farklı batch size'ların 200 epoch'ta davranışı

Batch size küçüldükçe ağırlık güncellemesi o kadar artar. Buna göre Batch Size 50 (gürültülü) olan Batch Size 200 (kararlı) olana göre daha fazla güncelliyor ve bu yüzden hedefe daha hızlı varıyor.

Küçük batch size'lar hızlı öğrenir ama gürültülüdür. Büyük batch size'ler yavaş öğrenir ama kararlıdır.

# Gelişmiş Optimizasyon Algoritmaları

## 1. Momentum

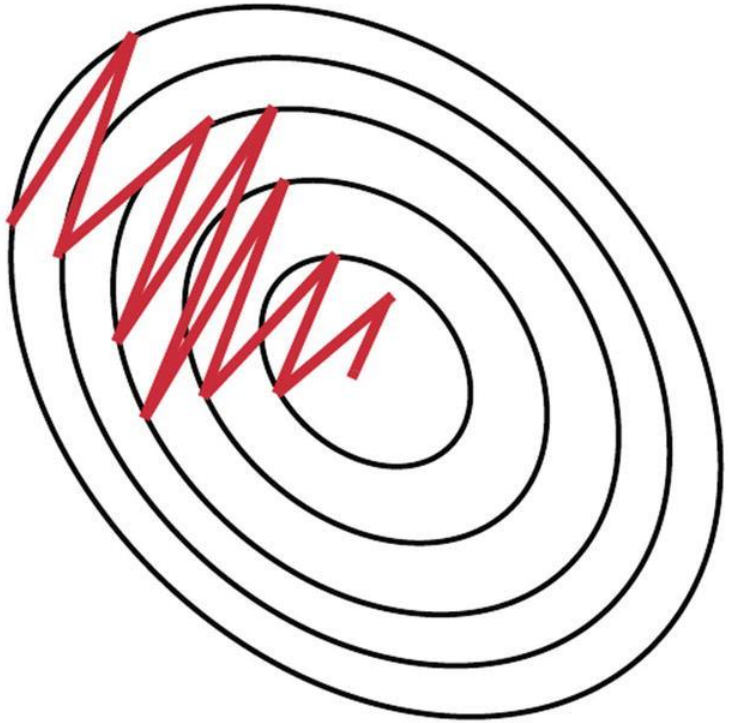

Stochastic Gradient Descent **without** Momentum

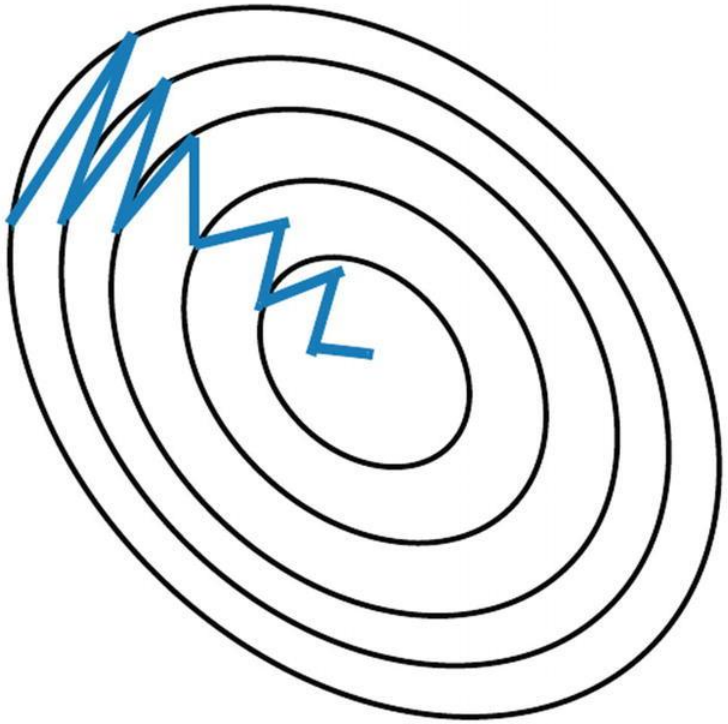

Stochastic Gradient Descent **with** Momentum

Doğru yönde ilerlerken adımları hızlandırır, yanlış yöndeki salınımları ve gürültüyü azaltır
SGD’den farklı olarak geçmiş adımları da hatırlar.

# Gelişmiş Optimizasyon Algoritmaları

## 2. RMSprop (Root Mean Square Propagation)

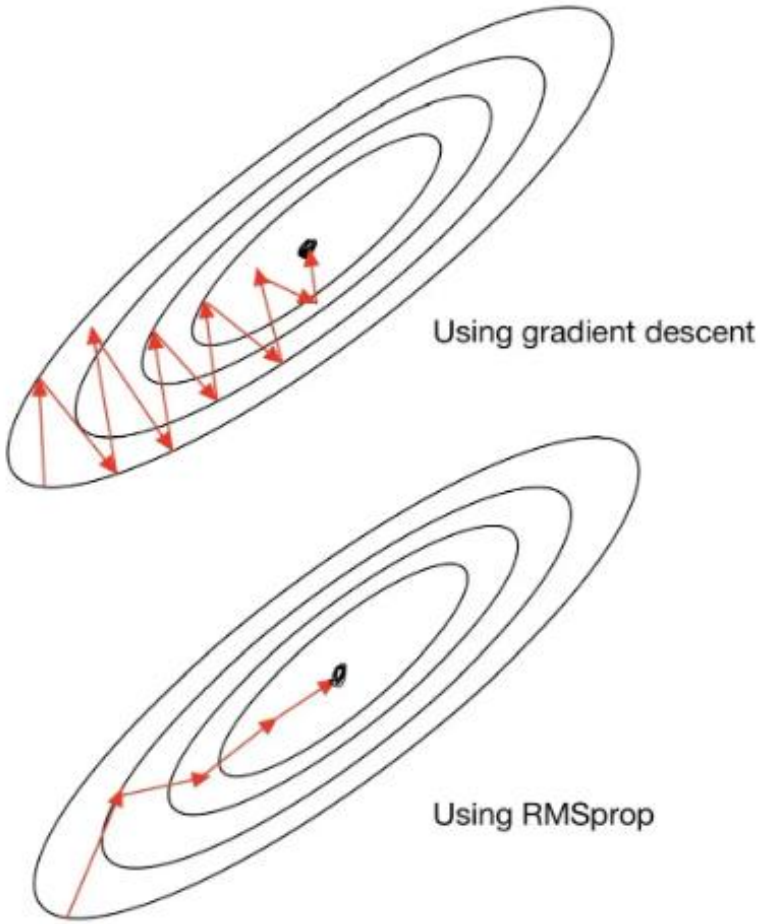


α oranını her bir parametre için otomatik ayarlar. Eğer gradyan çok büyükse adımı küçültür, gradyan çok küçükse adımı büyütür böylece uygun bir öğrenme oranı yakalar.

## 3. Adam (Adaptive Moment Estimation)

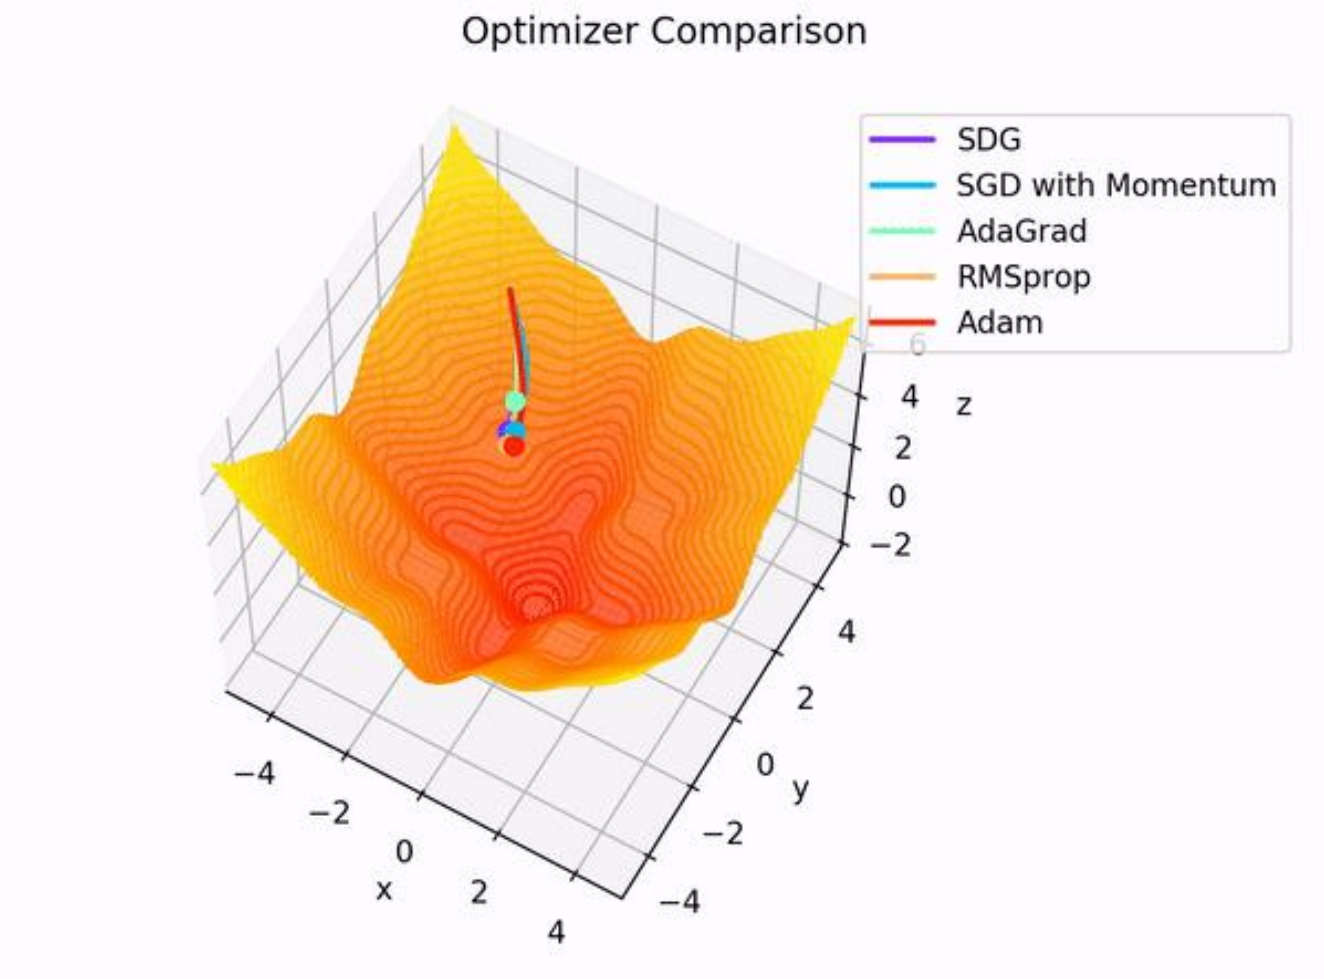


Momentum (geçmiş adımların hızını kullanması) + RMSprop (her parametre için öğrenme hızını otomatik ayarlaması) birleşimidir

# Learning Rate Scheduling

## 1. Step Decay (Adımlı Azalma)

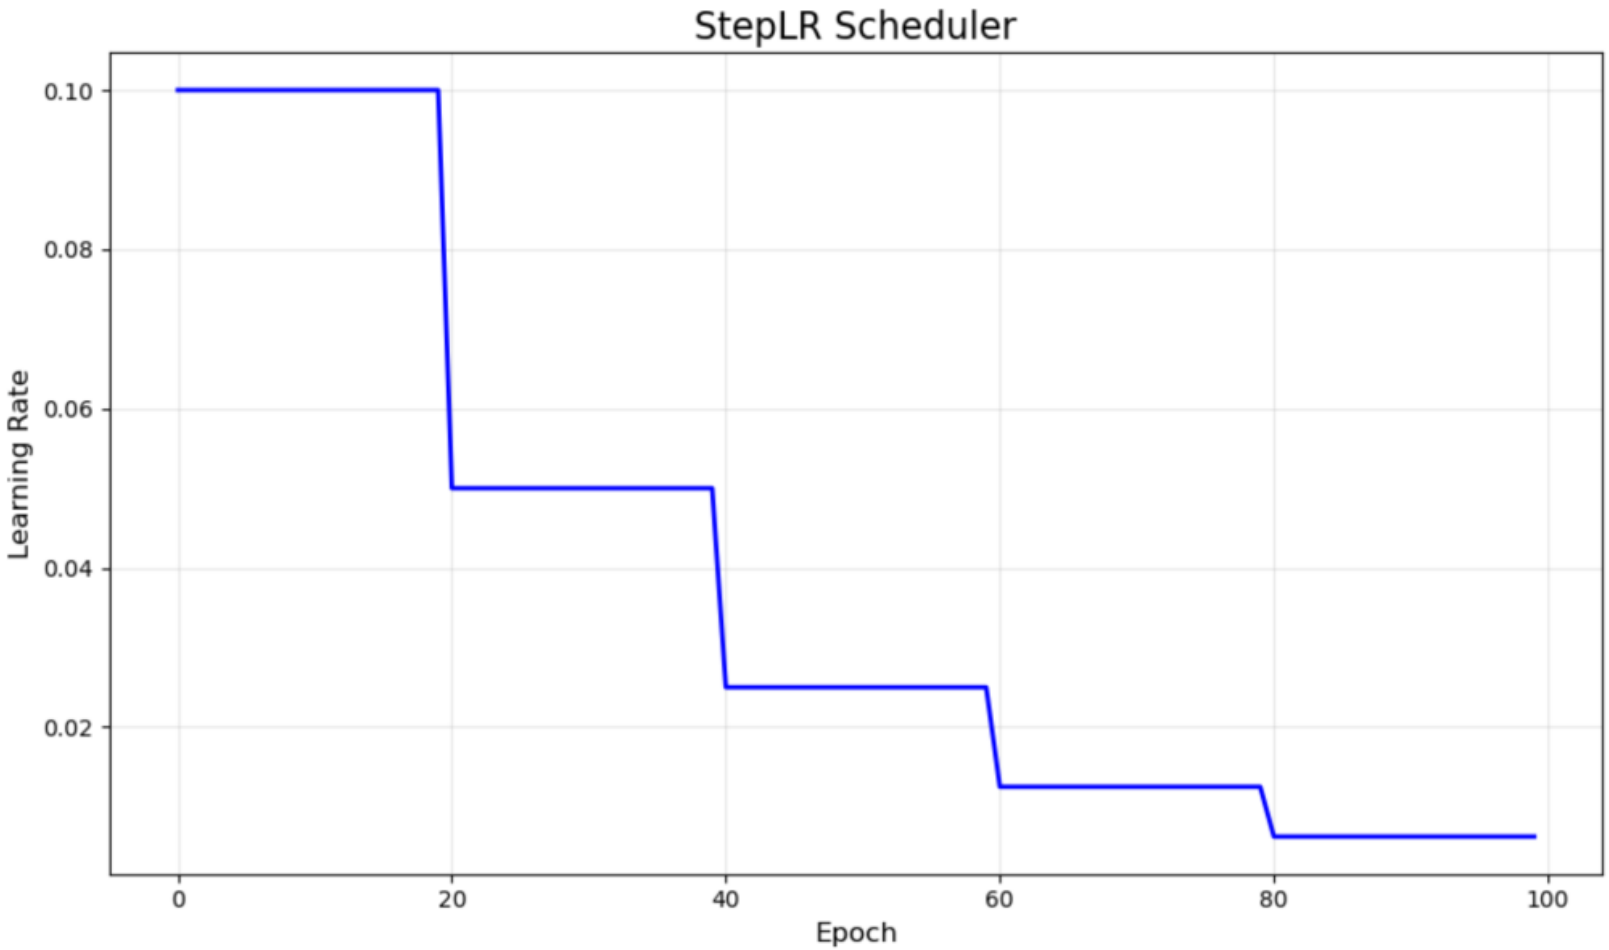


LR'i düzenli aralıklarla sabit bir faktörle azaltır.

# Learning Rate Scheduling

## 2. Exponential Decay (Üstel Azalma)

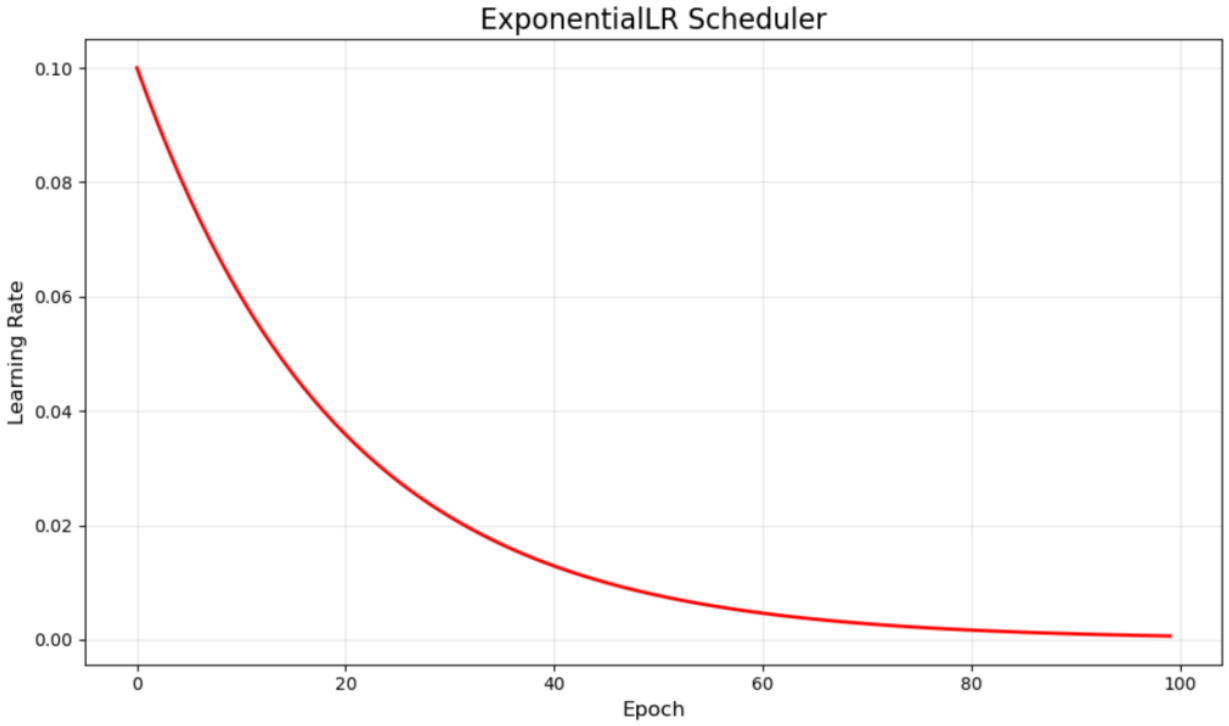


LR her adımda üstel olarak sürekli ve kademeli bir şekilde azalır.

## 3. Cosine Annealing (Kosinüs Azalması)

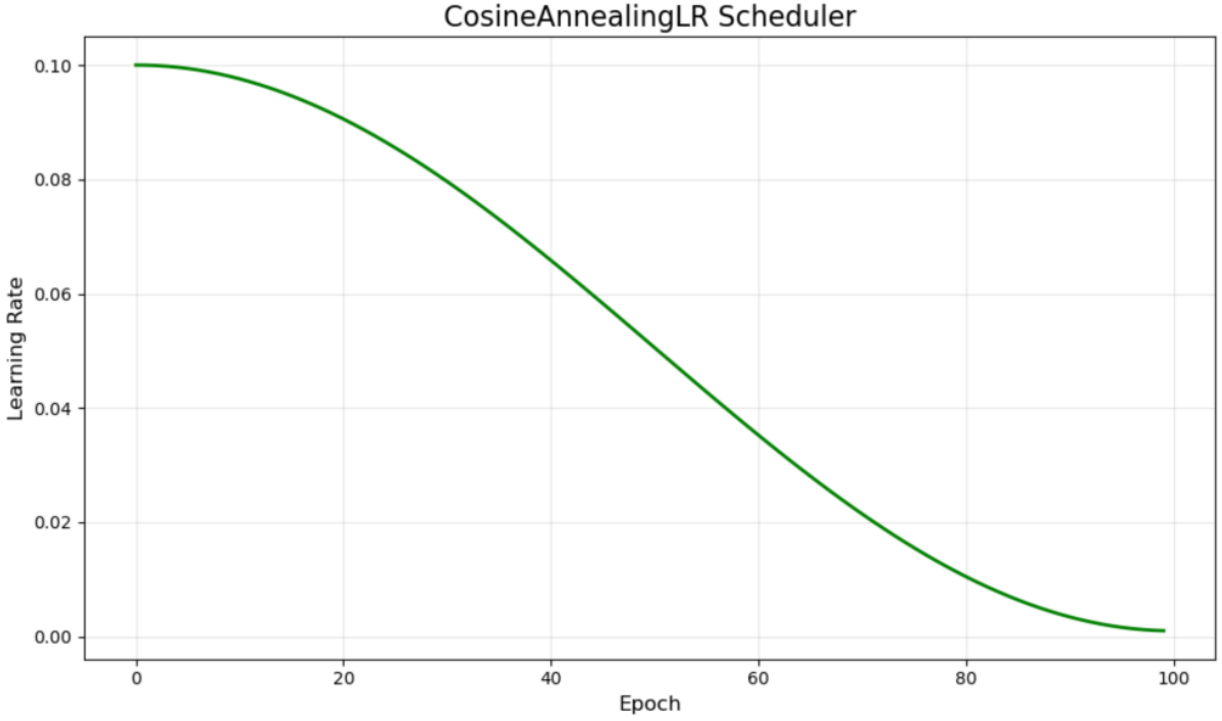


LR bir cosinüs dalgasının yarım periyodu şeklinde azalır.