MAKİNE ÖĞRENMESİNE GİRİŞ

MODEL EĞİTİMİ VE OPTİMİZASYON

ARDA MERT GACAL

2412705043

14.04.2026

GİRİŞ

Makine öğrenmesi modelleri, verilen bir problemi çözmek için sadece matematiksel verileri değil, bu verilerin ağırlıklarını en az hatayla güncelleyecek optimizasyon yöntemlerine ihtiyaç duyar. Model eğitimi temelde bir hata vadisinde en düşük noktayı bulma çabasıdır. Bu raporun amacı, makine öğrenmesi modellerinin eğitim sürecini etkileyen optimizasyon algoritmalarını, veri ön işleme (normalizasyon) adımlarını ve bu parametrelerin modelin öğrenme hızına olan etkilerini teorik ve pratik olarak incelemektir.

TEMEL KAVRAMLAR

Model eğitiminde optimizasyon motorlarının doğru çalışabilmesi için verinin ve başlangıç koşullarının doğru ayarlanması gerekmektedir.

- *Normalizasyon (Input Scaling):* Veri setindeki farklı özelliklerin birbirini ezmesini engellemek için tüm değerlerin 0 ile 1 aralığına sıkıştırılması işlemidir. Bu sayede modelin hata oranı hesaplamaları çok daha kararlı hale gelir.
- *Gradyan Problemleri (Vanishing/Exploding Gradient)*: Modelin ağırlıkları (W) çok yanlış başlangıç değerleri alırsa, geriye yayılım sırasında türevler çarpılarak ya sıfıra yaklaşır (kaybolur) ya da sonsuza giderek sistemi çökertir (patlar).
- *Learning Rate (Öğrenme Oranı):* Optimizasyon algoritmasının vadiye inerken atılacak adımların büyüklüğüdür. Çok büyük olursa hedef ıskalanır, çok küçük olursa eğitim çok yavaşlar.

YÖNTEM / MODEL AÇIKLAMASI (SGD VE ADAM)

Makine öğrenmesinde hedef, modeli en az hata verecek ağırlık düzeyine ulaştırmaktır. Bunun için Gradient Descent algoritmaları kullanılır.

- *SGD:* Her tekrarlama sürecinde tek bir (veya küçük bir grup) veriyi kullanarak eğimi (gradyan) hesaplar ve adım atar. Hızlıdır ancak dik yamaçlarda zikzaklar çizerek ilerlediği için hedefe ulaşması zaman alır.
- *Adam (Adaptive Moment Estimation):* Sektör standardı kabul edilen gelişmiş bir yöntemdir. SGD'nin yavaşlığını aşmak için "Momentum" (geçmiş adımların ivmesini biriktirme) özelliğini ve "RMSprop" (gereksiz zikzakları sönümleme) özelliğini birleştirir. Bu sayede hedefe çok daha stabil, pürüzsüz ve hızlı bir şekilde ilerler.

UYGULAMA ALANLARI

Gelişmiş optimizasyon algoritmaları (özellikle Adam) bugün endüstrinin hemen her alanında karşımıza çıkmaktadır.

- *Görüntü İşleme (Computer Vision)*: Otonom araçlardaki nesne tanıma sistemleri milyonlarca pikseli analiz ederken Adam optimizer kullanılarak çok daha kısa sürede eğitilir.
- *Doğal Dil İşleme (NLP)*: Büyük dil modellerinin (LLM) milyarlarca parametresinin stabilize edilerek eğitilmesinde, Learning Rate Scheduling (Zamanlama) ve gelişmiş optimizasyon teknikleri kritik rol oynar.

YAPILAN MİNİ PROJE AÇIKLAMASI

Çalışmanın Amacı: Teorik olarak incelenen Klasik SGD ve Adam optimizasyon algoritmalarının, bir yapay sinir ağı üzerindeki öğrenme hızlarını pratik olarak kıyaslamaktır.

Kullanılan Veri Seti: Çalışmada 0'dan 9'a kadar el yazısı rakamları içeren, 28x28 piksellik görsellerden oluşan MNIST veri seti kullanılmıştır.

Kullanılan Yöntem ve Ön İşleme: Pikseller 0-255 aralığından 0-1 aralığına normalize edilmiştir. Adil bir kıyaslama için Flatten, Dense(128, relu) ve Dense(10, softmax) katmanlarından oluşan birebir aynı iki model kurulmuştur. Modellerden ilki Klasik SGD, ikincisi ise ADAM ile 5 epoch (eğitim adımı) boyunca eğitilmiştir.

Kodlama Ortamı: Proje Python dili ve TensorFlow/Keras kütüphaneleri kullanılarak Jupyter Notebook (.ipynb) ortamında kodlanmıştır.

Elde Edilen Sonuçlar ve Program Çıktıları:

Klasik SGD ve Adam Optimizer Doğruluk (Accuracy) Karşılaştırması Grafik incelendiğinde Klasik SGD modelinin doğrusal ve yavaş bir şekilde öğrendiği, 5. adımda bile Adam'ın ilk adımdaki başarısına ulaşamadığı görülmüştür. Adam algoritması ise ivme ve sönümleme mekanizmaları sayesinde ilk adımlardan itibaren çok yüksek doğruluk oranlarına hızlıca yaklaşmıştır.

SONUÇ VE DEĞERLENDİRME

Bu çalışma kapsamında, makine öğrenmesi modellerindeki başarının yalnızca ağın katman sayısıyla veya derinliğiyle değil, doğrudan optimizasyon algoritmalarının kalitesiyle ilgili olduğu uygulamalı olarak görülmüştür. Geleneksel SGD algoritmasının hedefe inerken zikzaklar çizip zaman kaybettiği gözlemlenirken; Momentum ve RMSprop özelliklerini barındıran gelişmiş Adam algoritmasının eğitim süresini önemli ölçüde kısalttığı ve çok daha az tekrarlamayla yüksek doğruluk oranlarına ulaştığı kanıtlanmıştır.

Bununla birlikte, başarılı bir eğitim için sadece optimizasyon motorunun yeterli olmadığı teyit edilmiştir. Eğitime başlamadan önce verilerin 0-1 aralığına sıkıştırılarak normalize edilmesinin ve hedefe yaklaştıkça adımları sistemli olarak küçülten Learning Rate (öğrenme oranı) zamanlamasının, model stabilitesini korumada hayati bir role sahip olduğu görülmüştür. Özetle, akıllı algoritma seçimi ve doğru ön işleme adımlarının, modelin hem daha az donanım gücü harcayarak eğitilmesini hem de hata vadisinde mutlak minimum noktasına kusursuz bir iniş yapmasını sağladığı sonucuna varılmıştır.

KAYNAKÇA

1. D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," 3rd International Conference on Learning Representations (ICLR), San Diego, CA, USA, 2015.
2. S. Ruder, "An Overview of Gradient Descent Optimization Algorithms," arXiv preprint arXiv:1609.04747, 2016.
3. I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA, USA: MIT Press, 2016.
4. C. M. Bishop, Pattern Recognition and Machine Learning. New York, NY, USA: Springer, 2006.
5. TensorFlow Developers, "Module: tf.keras.optimizers," TensorFlow Documentation, 2024. [Online]. Available: https://www.tensorflow.org/api_docs/python/tf/keras/optimizers
6. A. Senturk, "EEM272 Sunum Konuları ve Açıklamalar," GitHub Repository. [Online]. Available: https://github.com/asenturk/asenturk.github.io/blob/main/eem272/sunum/sunumlar_aciklama.md