EEM-272: MAKINE ÖĞRENMESI

# Sunum 5:Model İyileştirme ve Transfer Öğrenme

11. Hafta

2212705045 Umut Can

# Hata Analizi (Error Analysis)

- **Kök neden tespiti(Root Cause Analysis):**Problemin ortaya çıkmasına sebep olan temel kaynağının bulunması.
- **Hata Tablolama:** Hatalar; düşük ışık, arka plan veya etiket hatası olarak kategorize edilir.

# Confusion Matrix(Karmaşıklık matrisi)

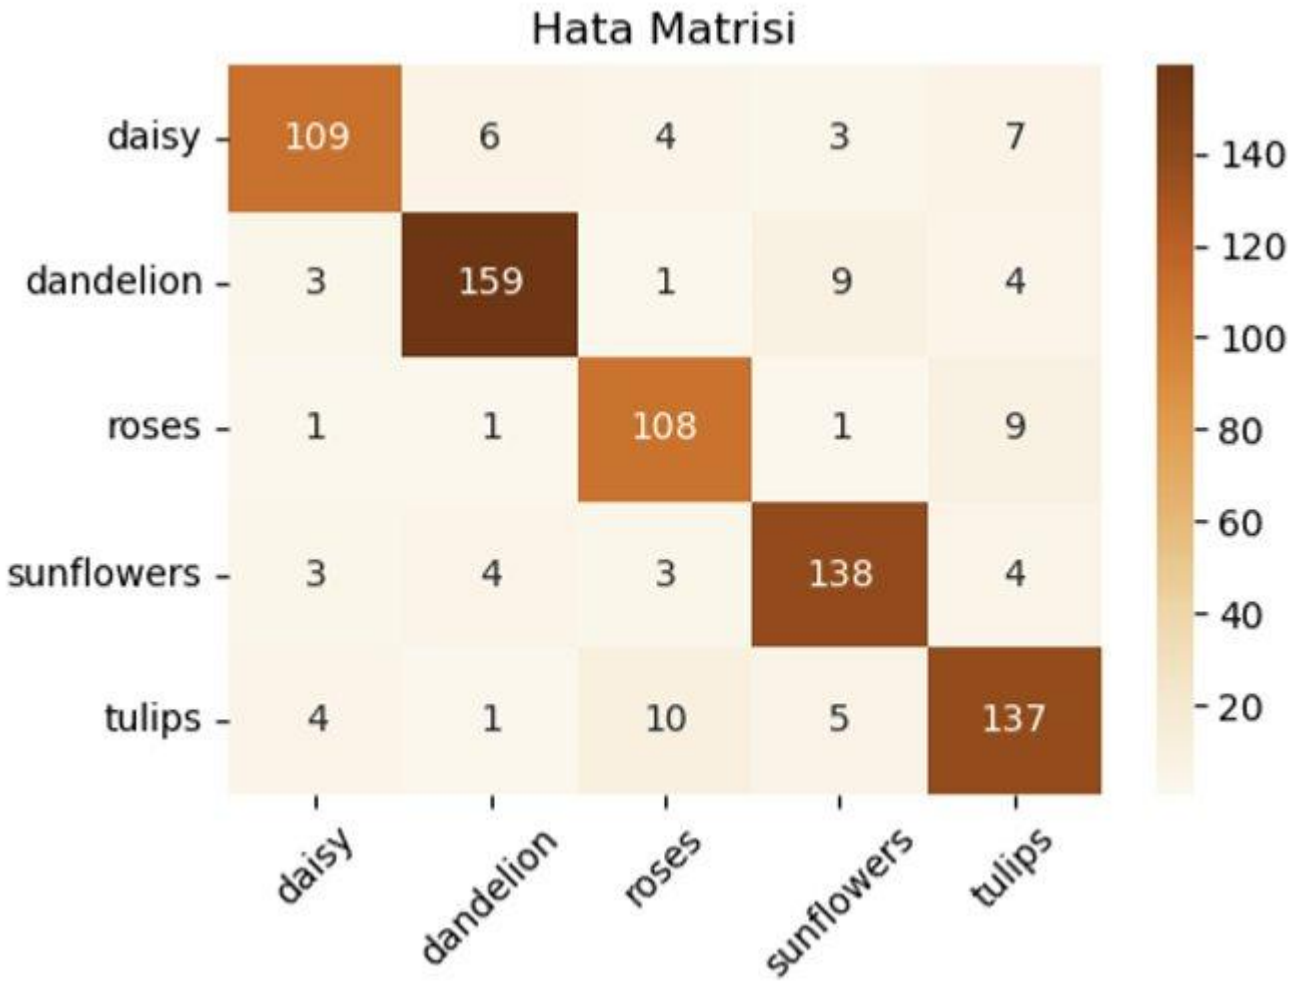

# Dağılım Kayması Problemleri(Distrubution Shift)

**Covariate Shift(Ortak Değişken Kayması):** Girdi özelliklerinin (X) dağılımındaki değişim (Gece/Gündüz sürüşü).

**Concept Drift(Kavram Kayması):** Girdi ile hedef çıktı arasındaki ilişkinin zamanla değişmesi.

**Label Shift( Etiket Kayması):** Hedef değişkenin (y) dağılımındaki istatistiksel kayma.

*"Modelin eğitildiği dünya ile karşılaştığı dünya arasındaki fark başarımı düşürür."*

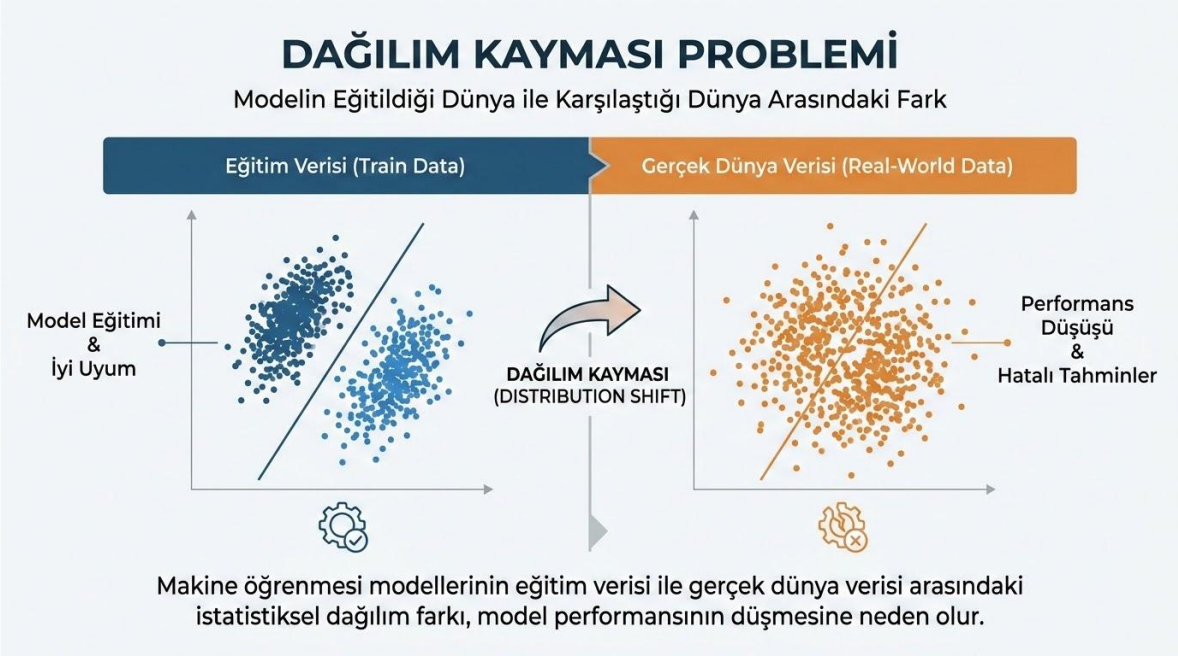

# Transfer Öğrenme(Transfer Learning)

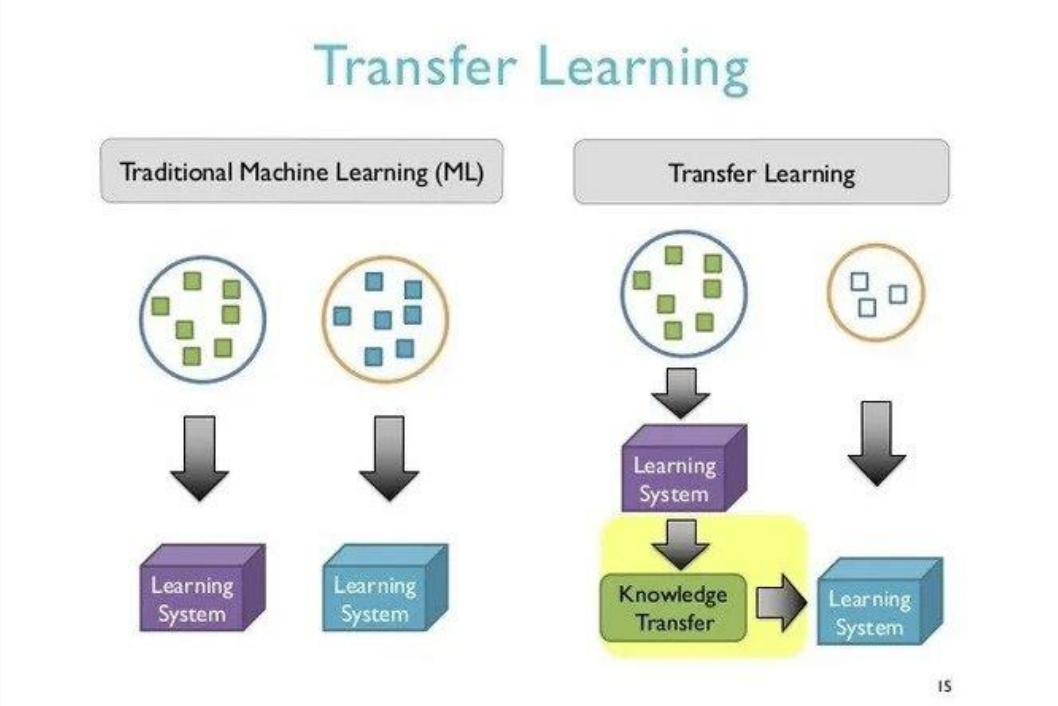


**Bilginin Adaptasyonu**

Transfer öğrenme, ResNet veya VGG gibi devasa veri setlerinde (ImageNet) eğitilmiş modellerin temel görsel özelliklerini (kenar, doku, şekil) kullanır.

- Hızlı Yakınsama
- Düşük Veri Gereksinimi
- Yüksek Doğruluk

# Çok Görevli Öğrenme (Multi-Task)

### Paylaşılan Katmanlar

Modelin ilk katmanları tüm görevler için genel özellikleri öğrenir.

### Regularizasyon

Birden fazla görevi öğrenmek, modelin ezberleme (overfitting) yapmasını engeller.

### Verimlilik

Tek bir mimari ile işlem gücü ve bellek kullanımı optimize edilir.

# UNDERSTANDING MULTI-TASK LEARNING (MTL) WORKFLOW

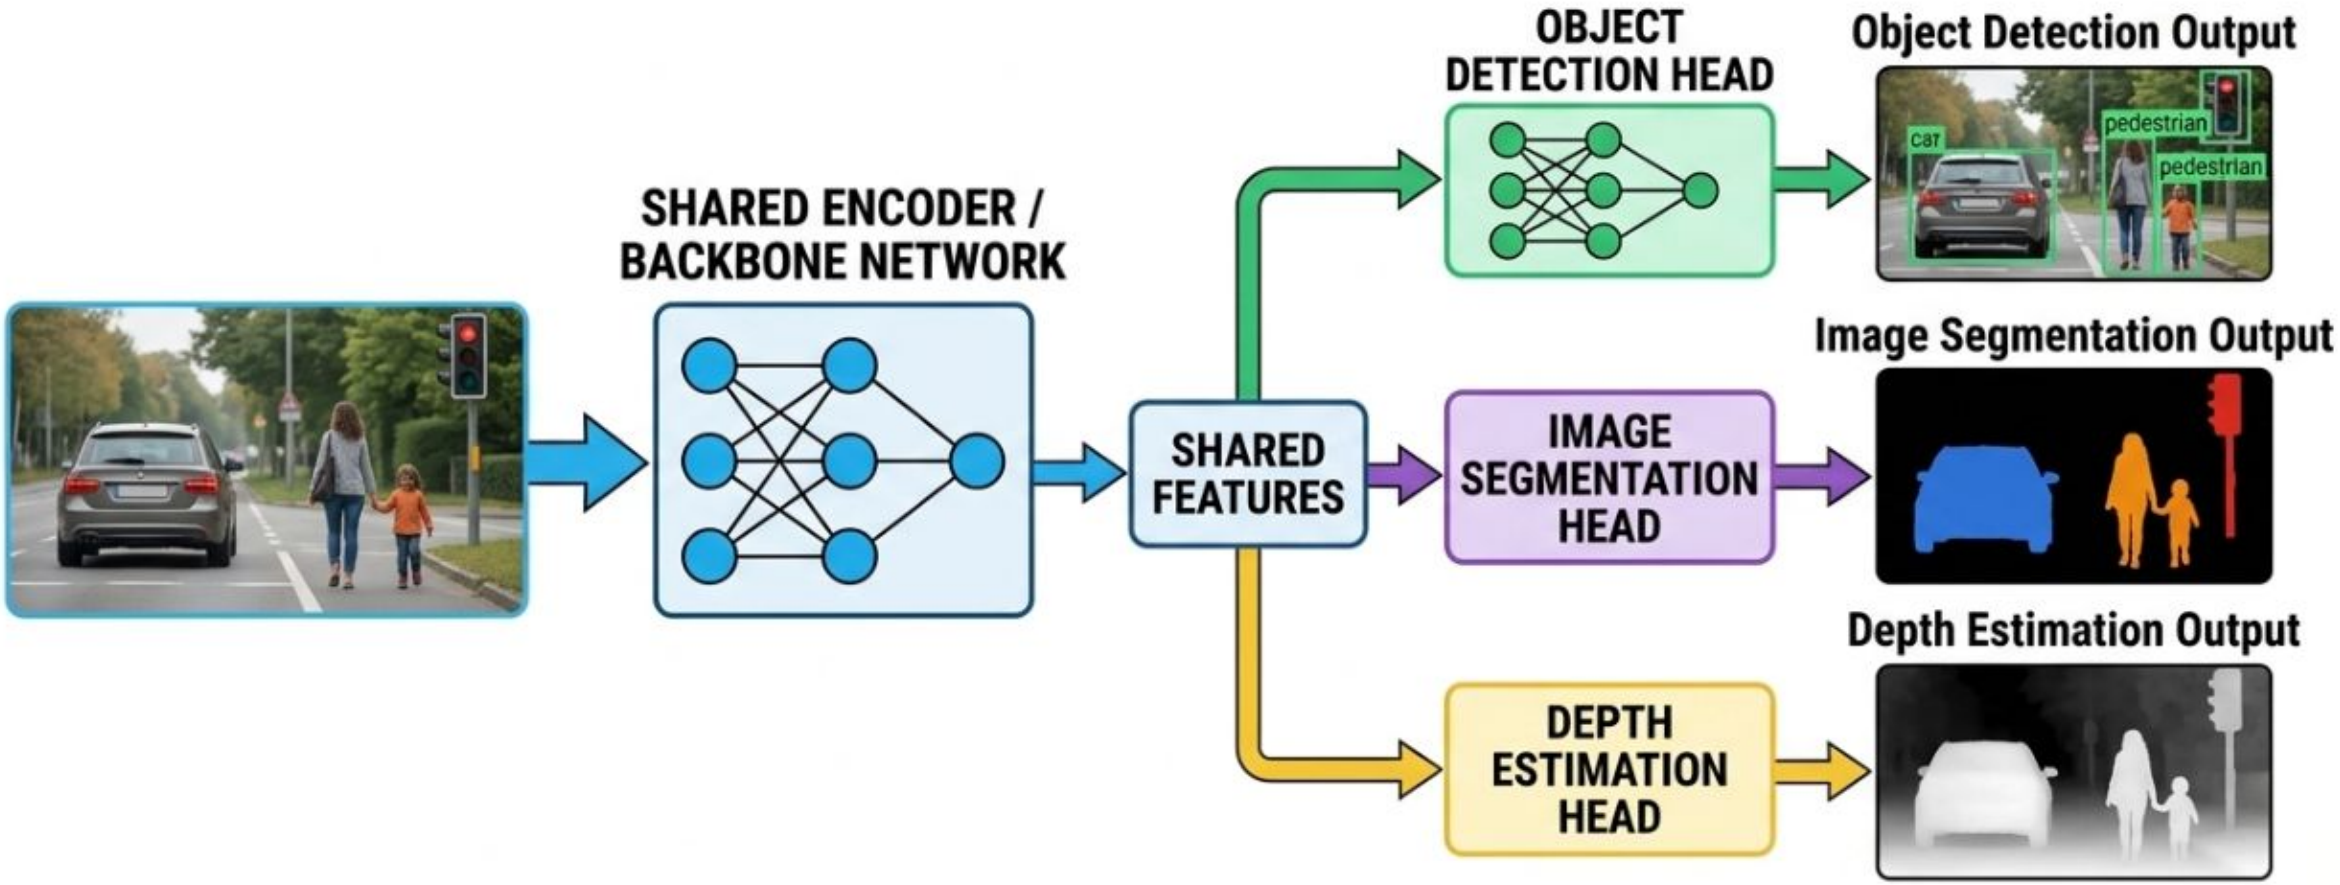


## KEY BENEFITS OF MTL (SIMPLIFIED)

**MORE ROBUST FEATURES**
From multiple tasks.

**FASTER INFERENCE**
One shared network.

**DATA EFFICIENCY**
Fewer labels per task.

**REDUCED OVERFITTING**
Implicit regularization.

# Karşılaştırmalı Strateji Analizi (Fine Tuning vs Feature Extraction)

| Özellik | Feature Extraction | Fine-Tuning |
|---|---|---|
| **Katman Durumu** | Evrişimsel taban tamamen dondurulur. | Son bloklar eğitime açılır. |
| **Veri İhtiyacı** | Çok küçük veri setleri için ideal. | Nispeten daha büyük veri seti ister. |
| **Eğitim Hızı** | Çok hızlı (Sadece sınıflandırıcı). | Yavaş (Geri yayılım daha derindir). |
| **Overfitting Riski** | Çok düşük. | Veri azsa yüksek. |

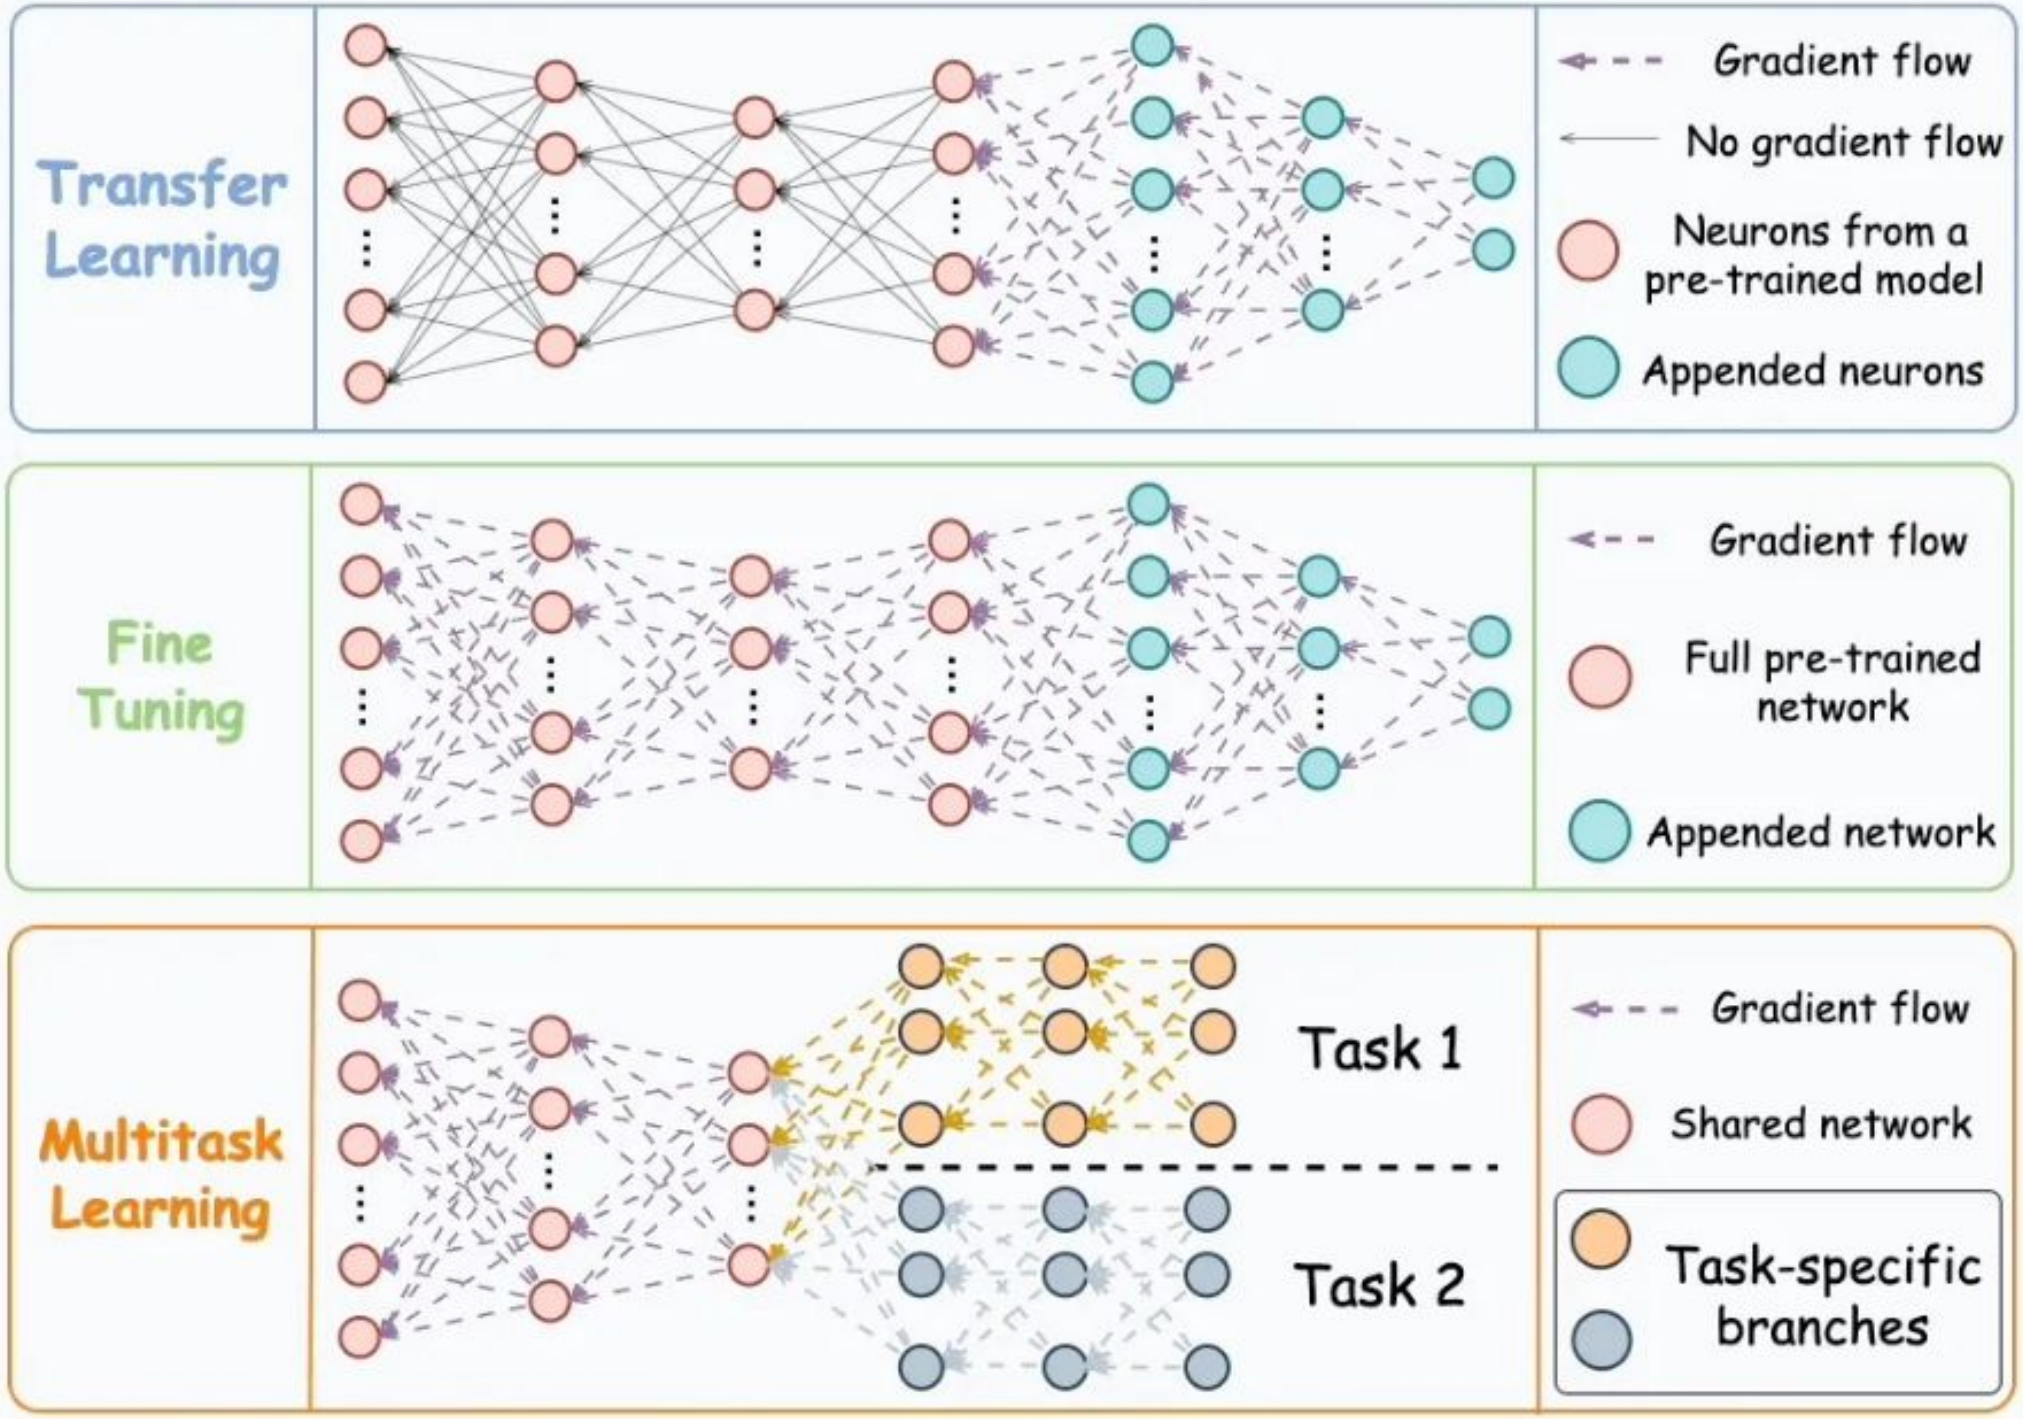
Transfer Learning
Gradient flow
No gradient flow
Neurons from a pre-trained model
Appended neurons
Fine Tuning
Gradient flow
Full pre-trained network
Appended network
Multitask Learning
Task 1
Task 2
Gradient flow
Shared network
Task-specific branches

# Fine-Tuning ve Optimizasyon

### ❄ Katman Dondurma(Freeze Layers)

Eğitimin başında ilk katmanlar dondurularak önceden öğrenilmiş genel özelliklerin bozulması engellenir.

### Kısmi Eğitim(Partial Training)

Modelin sadece son bloklarının eğitilmesi, hesaplama maliyetini düşürürken doğruluğu artırır.

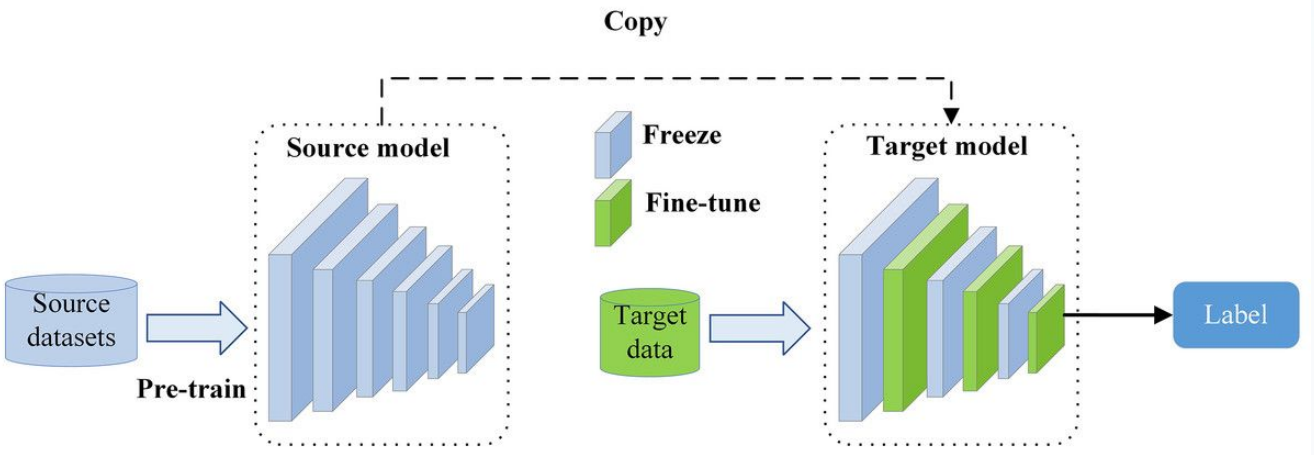

# FINE-TUNING STRATEJİLERİ

Aynı ön-eğitimli model için farklı güncelleme yaklaşımları

## 1) FREEZE LAYERS (KATMAN DONDURMA)

Modelin bazı katmanları dondurulur (güncellenmez), sadece seçilen katmanlar eğitilir.

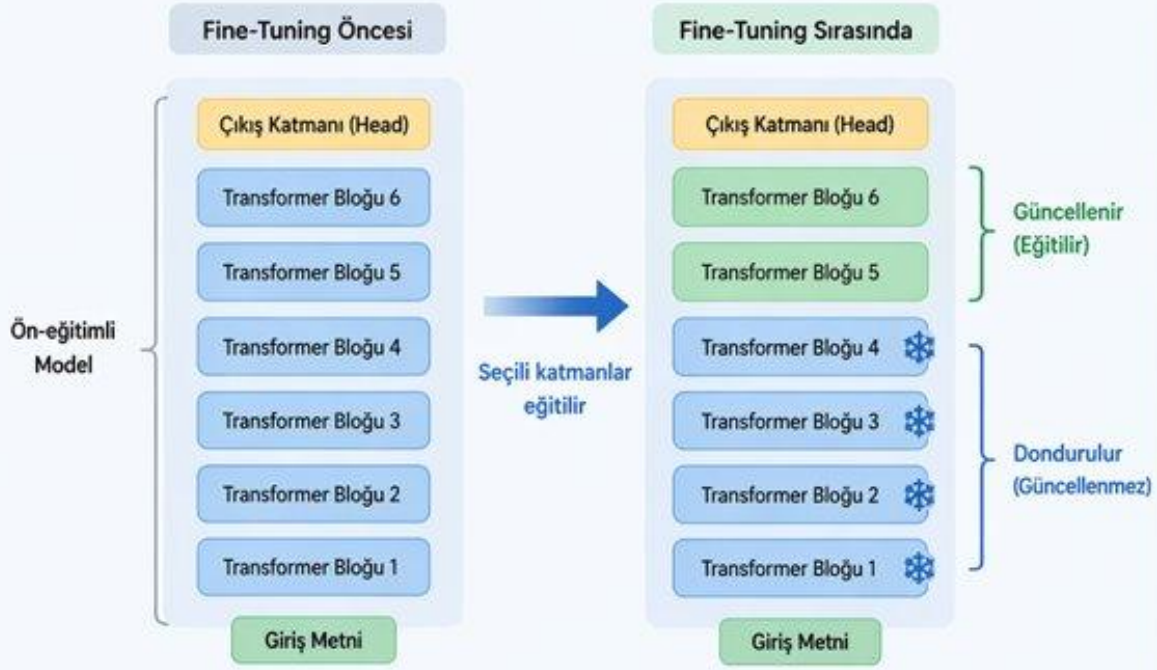


- Dondurulan Katman
- Eğitilen Katman

**Örnek:**

BERT modelinde ilk 8 katmanı dondurup, son 4 katmanı ve çıktı katmanını eğitmek.

**Ne zaman kullanılır?**

- Veri az olduğunda
- Hesaplama maliyetini azaltmak istediğinde.
- Ön-eğitimli özellikleri korumak istediğinde

## 2) PARTIAL TRAINING (KISMİ EĞİTİM)

Modelin tamamı yerine sadece belirli bölümleri veya bileşenleri eğitilir.

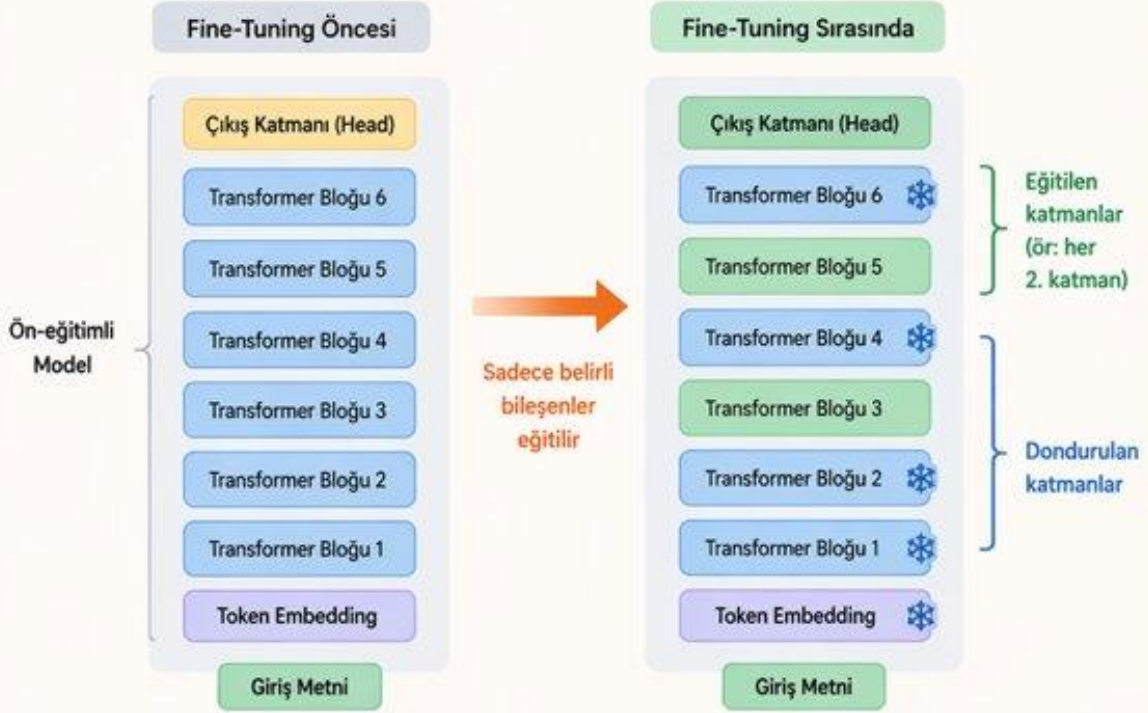


- Dondurulan Katman
- Eğitilen Katman
- Opsiyonel - Sabit Bileşen

**Örnek:**

Sadece attention katmanlarını veya MLP katmanlarını eğitmek, diğerlerini dondurmak.

**Ne zaman kullanılır?**

- Çok büyük modellerde bellek ve hesaplama tasarrufu için
- Belirli bileşenleri uyarlamak istediğinde
- Daha kontrollü bir güncelleme istediğinde

# Gerçek Dünyada Kullanım Alanları

Sosyal Medya ve içerik platformları

Yüz tanıma sistemleri

Görüntü işleme tabanlı fotoğraf uygulamaları

İlginiz için teşekkürler.