Teknoloji Fakültesi

Elektrik-Elektronik Mühendisliği

EEM 272 – Makine Öğrenmesine Giriş Sunum ve Proje Raporu

Konu: Evrişimli Sinir Ağları (CNN) Temelleri ve MNIST Uygulaması

Hazırlayan:

Yusuf Taha Şahin

2222705011

Ders Sorumlusu:

Dr. Öğretim Üyesi Ali Şentürk

1.GİRİŞ

Günümüzde veri miktarının katlanarak artmasıyla birlikte bu verilerin anlamlandırılması süreci geleneksel yöntemlerin ötesine geçmiştir. Özellikle görsel verilerin işlenmesi söz konusu olduğunda bilgisayarların nesneleri tıpkı bir insan gibi ayırt edebilmesi modern mühendisliğin en önemli çalışma alanlarından biri haline gelmiştir. Bu bağlamda geliştirilen Evrişimli Sinir Ağları (CNN) karmaşık görüntü yapılarını analiz etmede kullanılan en güçlü derin öğrenme mimarisidir.

1.1. Konunun Tanımı

CNN biyolojik görme sistemindeki nöron diziliminden esinlenerek tasarlanmış bir yapay sinir ağı türüdür. Görüntüyü bir bütün olarak değil matrisler üzerinden küçük parçalara ayırarak inceleyen bu mimari; convolution, pooling ve fully connected gibi temel katmanlardan oluşur. Klasik yapay sinir ağlarından farklı olarak görüntünün pikselleri arasındaki mekansal ilişkiyi kaybetmeden özellik çıkarımı yapabilmesi CNNi bu alanda benzersiz kılar.

1.2. Konunun Önemi

CNN mimarisinin mühendislik ve teknoloji dünyasındaki önemi şu üç ana nedene dayanmaktadır:

- **Otomatik Özellik Çıkarımı:** Geleneksel görüntü işleme yöntemlerinde bir resimdeki kenarları veya köşeleri bulmak için filtrelerin elle tasarlanması gerekirken CNN hangi filtrenin hangi özelliği yakalayacağını eğitim sürecinde kendi kendine öğrenir.
- **Hız ve Verimlilik:** Parametre paylaşımı ve havuzlama gibi teknikler sayesinde çok büyük boyutlu görselleri işlem gücünü optimize ederek kısa sürede analiz edebilir.
- **Geniş Uygulama Alanı:** Otonom sürüş teknolojilerinden tıbbi görüntülemedeki kanserli hücre tespitine savunma sanayindeki hedef takibinden yüz tanıma sistemlerine kadar her alanda CNN temelli çözümler standart hale gelmiştir.

Bu çalışma kapsamında CNN mimarisinin teknik işleyişi detaylandırılacak ve MNIST veri seti üzerinde bir uygulama gerçekleştirilerek teorik bilginin pratik sonuçları değerlendirilecektir.

2.TEMEL KAVRAMLAR

CNN görsel verilerdeki hiyerarşik özellikleri otomatik olarak öğrenmek üzere tasarlanmış katmanlı bir yapıdır. Bu mimariyi oluşturan temel bileşenler şunlardır:

2.1. Convolutional Layer

Bu katman CNN'in temel yapı taşıdır. Görüntünün yerel özelliklerini (kenarlar dokular renk geçişleri gibi) saptamak için kullanılır. Bir kernel veya filtre olarak adlandırılan küçük matris görüntünün üzerinde belirli bir adım (Stride) ile gezer. Bu işlem sırasında matris çarpımları yapılarak özellik H

haritaları elde edilir.

2.2. ReLU

Doğrusal olmayan özellikleri modele kazandırmak için evrişim işleminden sonra genellikle ReLU fonksiyonu uygulanır.

Matematiksel olarak f(x) = max (0, x) şeklinde ifade edilen bu fonksiyon negatif değerleri sıfıra eşitleyerek modelin karmaşık desenleri öğrenme kapasitesini artırır ve gradyan sönümlenmesi problemini azaltır.

2.3. Stride ve Padding

- **Stride:** Filtrenin her adımda kaç piksel atlayacağını belirler. Büyük stride değerleri çıktı boyutunun hızla küçülmesine neden olur.
- **Padding:** Evrişim işlemi sırasında görüntünün kenarlarındaki bilginin kaybolmasını önlemek ve çıktı boyutunu kontrol etmek için görüntünün etrafına eklenen sıfır değerleridir.

2.4. Pooling

Havuzlama özellik haritalarının boyutsallığını azaltmak için kullanılır. Bu sayede hesaplama maliyeti düşürülür ve modelin nesnenin görüntü içindeki konumuna karşı daha toleranslı olması sağlanır. En yaygın kullanılan teknik olan max pooling belirlenen pencere alanındaki en yüksek değeri seçerek veriyi özetler.

2.5. Fully Connected Layer

Özellik çıkarımı aşamalarından sonra gelen bu katmanda elde edilen 2 boyutlu veriler düzleştirme işlemi ile tek boyutlu bir vektöre dönüştürülür. Bu vektör klasik yapay sinir ağı katmanlarından geçirilerek sınıflandırma işlemi gerçekleştirilir. En son katmanda kullanılan Softmax fonksiyonu ile giriş verisinin sınıflara ait olma olasılıkları hesaplanır.

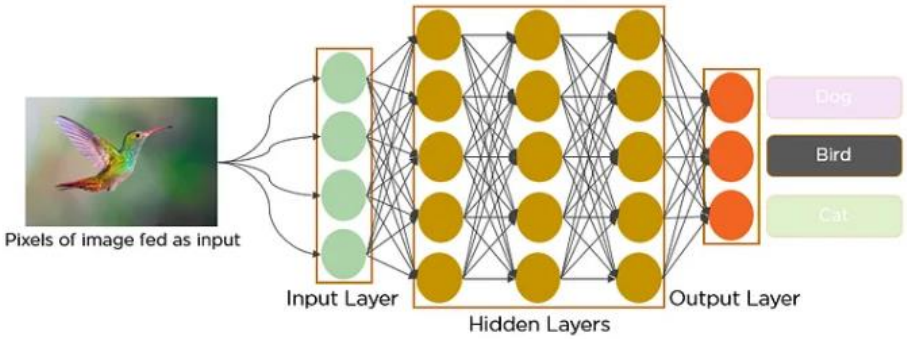

Şekil 2.1: Bir Evrişimli Sinir Ağının (CNN) uçtan uca mimari yapısı özellik çıkarımı ve sınıflandırma aşamalarının hiyerarşik dizilimi.

3.YÖNTEM / MODEL AÇIKLAMASI

Bu çalışmada el yazısı rakamların tanınması amacıyla MNIST veri seti kullanılarak bir CNN modeli tasarlanmıştır. Tasarlanan model mimarisi hiyerarşik olarak şu katmanlardan oluşmaktadır:

Giriş Katmanı: 28x28 piksel boyutunda gri seviyeli görüntüler.

Birinci Evrişim Katmanı: 32 adet 3x3 boyutunda filtre kullanılarak temel özellikler yakalanmıştır. Aktivasyon fonksiyonu olarak ReLU tercih edilmiştir.

Pooling: 2x2 boyutunda Max Pooling uygulanarak verinin boyutu yarıya indirilmiş ve işlem yükü azaltılmıştır.

Düzleştirme: Elde edilen özellik haritaları sınıflandırma katmanına giriş yapabilmesi için vektör haline getirilmiştir.

Tam Bağlantılı Katman: 128 nöronlu bir gizli katman ve ardından 10 rakamı temsil eden 10 çıkışlı bir Softmax katmanı ile model tamamlanmıştır.

4.UYGULAMA ALANLARI

CNN mimarisi günümüzde sadece akademik çalışmalarda değil endüstriyel ve ticari birçok alanda devrim yaratmıştır:

- **Sağlık:** MR ve röntgen görüntülerinde tümör veya anomali tespiti.
- **Otomotiv:** Otonom araçlarda trafik tabelalarının ve yayaların algılanması.
- **Güvenlik:** Yüz tanıma sistemleri ve biyometrik doğrulama.
- **Tarım:** İnsansız hava araçları (İHA) ile bitki hastalıklarının teşhisi.

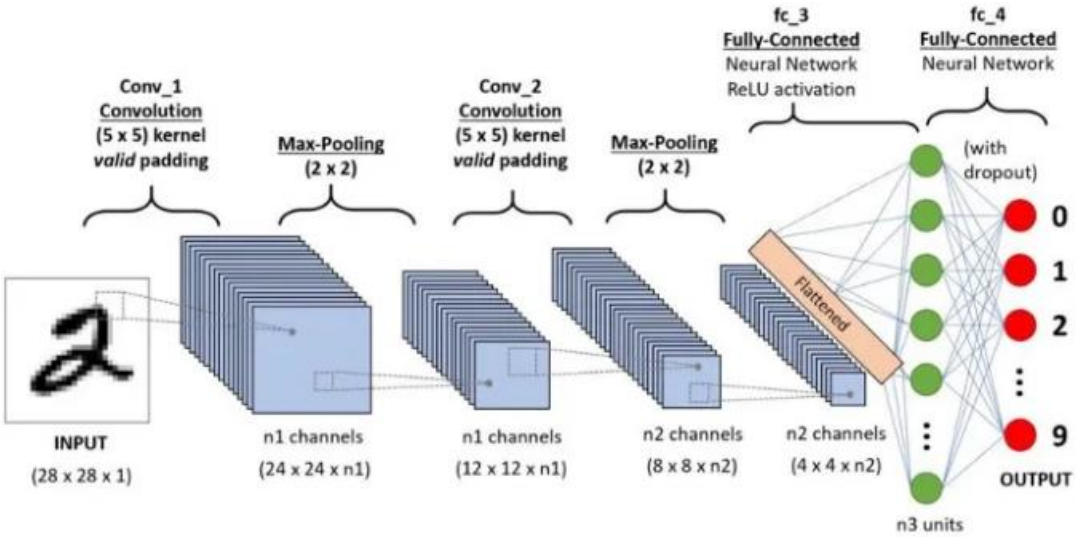

Şekil 3.1: MNIST veri seti için tasarlanan evrişimli sinir ağı mimarisinin katman bazlı teknik gösterimi. Girişten itibaren verinin nasıl küçüldüğü ve tam bağlantılı katmanlar aracılığıyla nasıl sınıflandırıldığı görülmektedir.

5.YAPILAN MİNİ PROJE AÇIKLAMASI

5.1. Kullanılan Veri Seti (MNIST)

Bu projede CNN görüntü sınıflandırma performansını analiz etmek amacıyla MNIST veri seti kullanılmıştır. Veri seti 0dan 9a kadar olan el

yazısı rakamların 28x28 piksel çözünürlüğündeki gri seviyeli görüntülerinden oluşmaktadır. Modelin genelleme yeteneğini ölçmek adına veriler 60.000 adet eğitim ve 10.000 adet test verisi olarak ikiye ayrılmıştır.

5.2. Modelin Kurulumu ve Eğitim Süreci

Model Bölüm 3 ve Şekil 3.1 de detaylandırılan mimariye sadık kalınarak Python programlama dili ve TensorFlow/Keras kütüphaneleri ile inşa edilmiştir:

- **Özellik Çıkarımı:** İki adet evrişim ve iki adet pooling katmanı kullanılarak görüntüdeki mekansal özellikler yakalanmıştır. Filtre boyutları 3x3 havuzlama boyutları ise 2x2 olarak belirlenmiştir.
- **Sınıflandırma:** Özellik haritaları düzleştirildikten sonra 128 nöronluk tam bağlantılı bir gizli katmana aktarılmıştır.
- **Optimizasyon:** Modelin derlenmesi aşamasında "Adam" optimizasyon algoritması ve "Sparse Categorical Crossentropy" kayıp fonksiyonu tercih edilmiştir. Model eğitim verisi üzerinde 5 epoch boyunca eğitilmiştir.

5.3. Elde Edilen Sonuçlar ve Performans Analizi

Eğitim süreci sonunda model eğitim verileri üzerinde yaklaşık %99 test verileri üzerinde ise %98 civarında bir doğruluk oranına ulaşmıştır. Eğitim ve test başarılarının birbirine çok yakın olması modelin ezberleme yapmadığını ve yeni gördüğü el yazısı rakamları başarılı bir şekilde sınıflandırabildiğini kanıtlamaktadır.

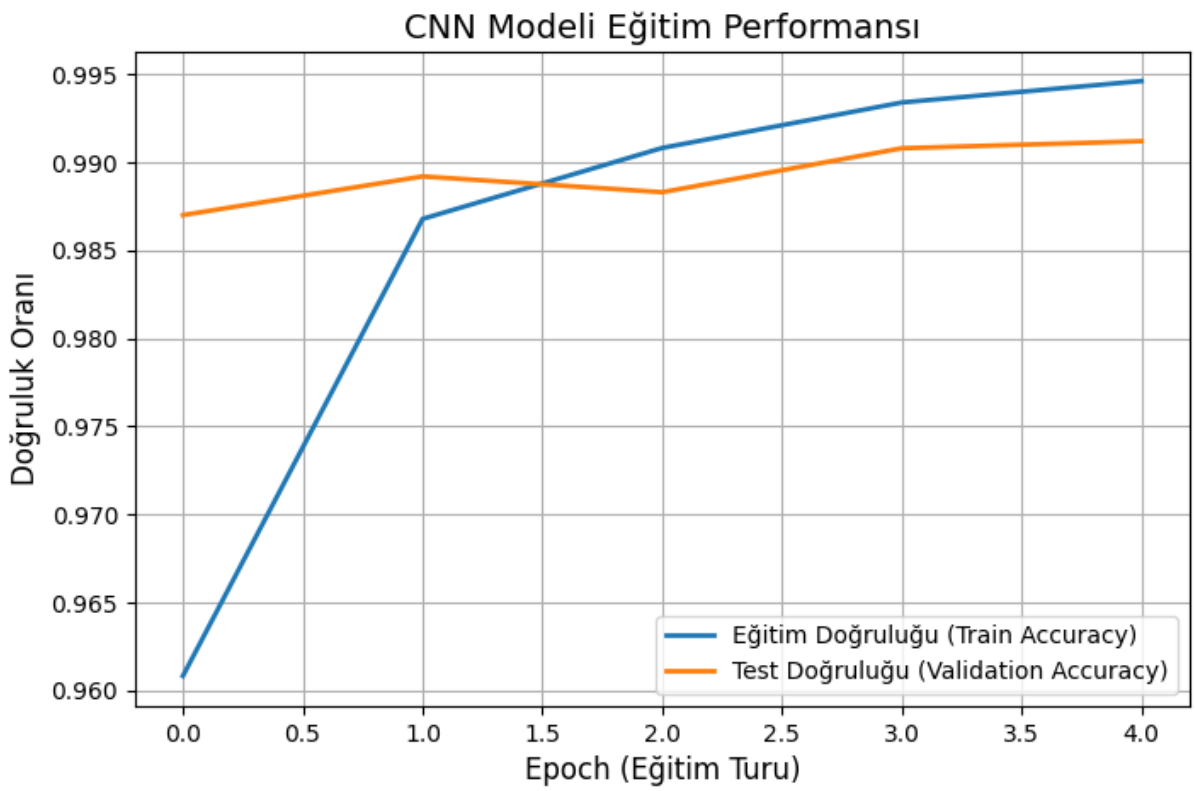

Şekil 5.1: Modelin Eğitim ve Test Süreci Doğruluk Grafiği

Grafikte görüldüğü üzere eğitim ve test başarıları birbirine yakın seyrederek %99 seviyelerine ulaşmıştır bu da modelin ezberleme yapmadan başarılı bir şekilde öğrendiğini göstermektedir.

6.SONUÇ

Bu çalışma kapsamında derin öğrenme temelli CNN çalışma prensipleri ve görüntü sınıflandırma üzerindeki etkinliği hem teorik hem de uygulamalı olarak incelenmiştir. Yapılan araştırmalar ve gerçekleştirilen MNIST rakam tanıma projesi sonucunda şu çıkarımlara varılmıştır:

Mimari Verimlilik: CNN mimarisinin klasik yapay sinir ağlarından farklı olarak pikseller arasındaki mekansal ilişkiyi koruyarak özellik çıkarımı yaptığı gözlemlenmiştir.

Başarı Oranı: Geliştirilen modelin eğitim verileri üzerinde %99 test verileri üzerinde ise %99.1 gibi yüksek bir doğruluk oranına ulaşması seçilen katman yapısının ve parametrelerin verimli çalıştığını kanıtlamıştır.

Optimizasyon: Evrişim ve Havuzlama işlemlerinin veri setindeki gürültüyü azaltırken en ayırt edici özellikleri başarılı bir şekilde ön plana çıkardığı tespit edilmiştir.

7.KAYNAKÇA

https://www.ultralytics.com/tr/glossary/convolutional-neural-network-cnn

https://www.teknoloji.org/cnn-convolutional-neural-networks-nedir/

https://onlyjs.com/yazilim-sozlugu/cnn

https://www.glasshouse.com.tr/blog/gelecek-teknolojileri/tum-merak-edilenleriyle-convolutional-neural-network-cnn