TC.

ISPARTA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

TEKNOLOJİ FAKÜLTESİ

ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ BÖLÜMÜ

EVRİŞİMLİ SİNİR AĞLARINDA (CNN) KERNEL BOYUTUNUN GÖRÜNTÜ SINIFLANDIRMA PERFORMANSI ÜZERİNDEKİ ETKİSİNİN İNCELENMESİ

Hazırlayan:

Mustafa Yasir KARADAĞ – 2322705041

Danışman:

Doktor Öğretim Üyesi Ali ŞENTÜRK

ISPARTA 2026

1.Giriş

Evrişimli Sinir Ağları (CNN), görsel verileri analiz etmek ve görüntü tanıma görevlerini yerine getirmek için kullanılan derin öğrenmenin bir alt sınıfıdır. Geleneksel makine öğrenmesi yöntemlerinde özellik çıkarımı mühendisler tarafından elle yapılırken, CNN'ler bu özellikleri veri setinden otomatik olarak öğrenme yeteneğine sahiptir. Bu durum, CNN'leri çok daha esnek ve güçlü kılmaktadır.[1], [2], [3]

CNN'lerin neden bu kadar önemli olduğuna gelecek olursak klasik yöntemler görüntü sınıflandırma ve bölütleme işlemlerinde oldukça maliyetli ve insan hatasına açıktır. CNN'ler ise katmanlı yapıları sayesinde görüntünün en küçük detaylarından (kenarlar gibi) en karmaşık özelliklerine (nesne parçaları gibi) kadar her şeyi hiyerarşik bir şekilde kavrayabilmektedir. Günümüzde otonom araçlardan tıbbi teşhis sistemlerine kadar pek çok kritik alanda bu teknolojinin kullanılmasının temel sebebi, insan gözünün hassasiyetine yaklaşan ve bazen onu bile aşan başarısıdır.[1], [3]

2.Temel Kavramlar

CNN mimarisi, belirli görevleri üstlenen çeşitli katmanlardan oluşmaktadır. İşte bu ağın beynini oluşturan ana kavramlar şunlardır:

A. Evrişim (Convolution) ve Filtreler

Evrişim, iki sinyalin birleşerek üçüncü bir sinyali oluşturduğu doğrusal bir cebirsel işlemdir. Bir CNN modelinde ana görüntü ile Kernel adı verilen ağırlıklı bir filtre matrisi çarpılmaktadır. Bu çarpımın sonucunda özellik haritası denilen 2 boyutlu bir dizi elde edilmektedir.[1]

Evrişim Katmanı Formülü:

$$Q_J = f\left(\sum_{i=1}^{N} w_{i,j} * x_{i,j} + B_j\right)$$

Burada w modelin ağırlıklarını, x giriş özelliklerini ve B ise sapmayı (bias) temsil etmektedir.[4]

B. Havuzlama (Pooling)

Havuzlama katmanı, evrişim katmanından gelen çıktının boyutsal karmaşıklığını ve parametre sayısını azaltmak için kullanılmaktadır. En yaygın yöntem olan Max Pooling, filtre bölgesindeki en yüksek değeri seçerek önemli özellikleri korurken veriyi küçültmektedir.[1], [3], [4]

Çıkış Boyutu Hesaplama Formülü:

$$Dim = \left(\frac{I - w + 2P}{S} \right) + 1$$

Burada I giriş matrisini, w evrişim matrisini, P dolguyu (padding) ve S ise kaydırma miktarını (stride) temsil etmektedir.[3]

C. Aktivasyon Fonksiyonları

ReLU: Negatif değerleri sıfıra indiren ve ağa doğrusal olmayan özellik katan bir fonksiyondur. Formül $f(x) = \max(0, x)$.[1], [3], [4]

Softmax: Genellikle ağın çıkış katmanında yer alır ve çıktıyı bir olasılık dağılımına dönüştürerek nesnenin hangi sınıfa ait olma ihtimalinin en yüksek olduğunu belirlemektedir.[1], [4]

D. Hiperparametreler

Modelin performansını doğrudan etkileyen, eğitim öncesi ayarlanan parametrelerdir.

Öğrenme Hızı (Learning Rate): Modelin ağırlıklarını ne kadar hızlı güncelleyeceğini belirlemektedir.[1]

Filtre Boyutu ve Sayısı: Veriden kaç tane ve ne kadar büyük özellik çıkarılacağını belirlemektedir.[1], [5]

3.Yöntem/Model Açıklaması

CNN modelleri, biyolojik görme sisteminden esinlenerek tasarlanmıştır. Tipik bir CNN modeli şu adımları izleyerek gerçekleşmektedir:

1.İleri Yayılım (Forward Propagation): Giriş katmanından alınan pikseller, evrişim ve havuzlama katmanlarından geçerek özellik haritalarına

dönüştürülmektedir. Bu süreçte kenar, doku ve şekil gibi bilgiler çıkarılmaktadır.[1], [2]

2.Düzleştirme (Flattening): Çıkarılan 2 boyutlu özellik haritaları tek boyutlu bir vektöre dönüştürülür ki tam bağlantılı katmana girebilsin.[4]

3.Sınıflandırma: Tam bağlantılı katman bu özellikleri kullanarak görüntüyü etiketlemektedir.[4]

4.Hata Hesaplama ve Geri Yayılım (Backpropagation): Tahmin edilen sonuç ile gerçek sonuç arasındaki fark hesaplanmaktadır. Adam veya SGDM gibi optimizasyon algoritmaları kullanılarak bu hatayı azaltmak için ağdaki ağırlıklar güncellenmektedir.[1], [2], [4], [6]

Yapılan deneyler, örneğin ZfNet mimarisinin CIFAR-10 veri setinde yüksek doğruluk oranlarına ulaşabildiğini göstermektedir. Aşağıdaki tablo bir modelin katman bazlı parametre değişimini özetlemektedir.[5]

TABLE 1: ARITHMETIC CALCULATION FOR ZFNET ARCHITECTURE

	Arithmetic Calculation for ZfNet Architecture							
Layers	***Channels***	***Kernel Size***	***Stride***	***Number of Filters***	***Number of Parameters***	***Input image size***	***Output Image size***	***FLOPS***
Input								
Conv 1	3	7	2	96	14208	224 * 224	110 * 110	341510400
MaxPool 1	96	3	2			110 * 110	55 * 55	
Conv 2	96	5	2	256	614656	55 * 55	26 * 26	830668800
MaxPool 2	256	3	2			26 * 26	13 * 13	
Conv 3	256	3	1	384	885120	13 * 13	13 * 13	299040768
Conv 4	384	3	1	384	1327104	13 * 13	13 * 13	448561152
Conv 5	384	3	1	256	885120	13 * 13	13 * 13	299040768
MaxPool 3	256	3	2	256		13 * 13	6 * 6	
FC 1	256			4096	37748736			75497472
FC 2	4096			4096	16777216			33554432
Softmax	4096			10	40960			81920
Total					**58,293,120**			**2327873805**

4.Uygulama Alanları

Çocuk El Yazısı Tanıma: Okul öncesi çocukların motor becerilerini geliştirmesine yardımcı olan Drawing Apps gibi uygulamalarda çocukların elle çizdiği rakamları (0-9) %99'a varan doğrulukla tanımak için CNN kullanılmaktadır.[4]

Kenar Belirleme: Geleneksel Sobel veya Canny gibi yöntemler yerine kullanılan CNN tabanlı operatörler görüntüdeki kenar bilgilerini çok daha detaylı ve zengin bir şekilde sunmaktadır..[2]

Tıbbi Görüntü İşleme: Özellikle kanser teşhisinde kritik öneme sahip olan biyopsi örneklerinin analizinde kullanılmaktadır. Bu sistemler,

patologların saatlerce süren yorucu inceleme sürecini kısaltarak hatalı teşhis riskini azaltmaktadır.[3]

Nesne Tanıma: CIFAR-10 ve ImageNet gibi devasa veri setleri üzerinden eğitilen modeller; arabaları, uçakları, hayvanları ve günlük nesneleri gerçek zamanlı olarak tanıyabilmektedir.[5], [7], [8]

CNN'ler, veriden öğrenme yeteneği ve hiyerarşik öznitelik çıkarımı sayesinde görüntü işleme dünyasının altın standardı haline gelmektedir. Katman sayısının ve filtre boyutlarının doğru ayarlanması modelin başarısı için en kritik unsurlardan biri olmaktadır.[1], [6]

5.Yapılan Mini Proje Açıklaması

Çalışmanın Tanımı

Bu çalışmada, bir CNN modelinin performansı üzerinde Kernel Boyutunun (3x3, 5x5 ve 7x7) etkileri karşılaştırmalı olarak incelenmektedir. Amaç, aynı ağ mimarisinde sadece filtre boyutlarını değiştirerek doğruluğun ve parametre sayısının nasıl değiştiğini gözlemlemektir.

Kullanılan Veri Seti

Çalışmada, bilgisayarlı görü dünyasının standart veri setlerinden biri olan CIFAR-10 kullanılmaktadır. Bu veri seti uçak, otomobil, kuş, kedi, geyik, köpek, kurbağa, at, gemi ve kamyon olmak üzere 10 farklı sınıfa ait 60.000 adet 32x32 renkli görüntüden oluşmaktadır.

Kullanılan Yöntem ve Kodlama

Çalışma Python dili kullanılarak TensorFlow/Keras kütüphanesi üzerinde yürütülmektedir. Üç farklı model tasarlanmaktadır.

Model 1: 3x3 Kernel boyutuna sahip evrişim katmanları.

Model 2: 5x5 Kernel boyutuna sahip evrişim katmanları.

Model 3: 7x7 Kernel boyutuna sahip evrişim katmanları.

Kodlamada Sequential model yapısı tercih edilmekte olup her modelde Conv2D, MaxPooling2D, Flatten ve Dense katmanları standart

tutulmaktadır. Aktivasyon olarak ReLU, çıkış katmanında ise Softmax kullanılmaktadır.

Elde Edilen Sonuçlar ve Program Çıktıları

Doğruluk Oranları: Eğitim sonrasında elde edilen grafik incelendiğinde, 3x3 ve 5x5 Kernel boyutlarının CIFAR-10 gibi düşük çözünürlüklü (32x32) görüntülerde daha yüksek başarı gösterdiği görülmektedir. 7x7 boyutundaki büyük filtreler küçük detayları kaçırdığı için başarımı bir miktar düşürmektedir.

```
3x3 Modeli Eğitiliyor...
Epoch 1/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 10s 5ms/step - accuracy: 0.9576 - loss: 0.1390 - val_accuracy: 0.9867 - val_loss: 0.0440
Epoch 2/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 8s 4ms/step - accuracy: 0.9853 - loss: 0.0466 - val_accuracy: 0.9883 - val_loss: 0.0344
Epoch 3/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 9s 5ms/step - accuracy: 0.9898 - loss: 0.0323 - val_accuracy: 0.9892 - val_loss: 0.0321

5x5 Modeli Eğitiliyor...
Epoch 1/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 10s 5ms/step - accuracy: 0.9622 - loss: 0.1248 - val_accuracy: 0.9841 - val_loss: 0.0473
Epoch 2/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 9s 5ms/step - accuracy: 0.9874 - loss: 0.0402 - val_accuracy: 0.9901 - val_loss: 0.0304
Epoch 3/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 9s 5ms/step - accuracy: 0.9912 - loss: 0.0285 - val_accuracy: 0.9908 - val_loss: 0.0271

7x7 Modeli Eğitiliyor...
Epoch 1/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 10s 5ms/step - accuracy: 0.9546 - loss: 0.1450 - val_accuracy: 0.9842 - val_loss: 0.0523
Epoch 2/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 8s 5ms/step - accuracy: 0.9855 - loss: 0.0488 - val_accuracy: 0.9864 - val_loss: 0.0447
Epoch 3/3
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 8s 5ms/step - accuracy: 0.9892 - loss: 0.0345 - val_accuracy: 0.9898 - val_loss: 0.0325
```

Parametre Sayısı: Modelleri eşit karmaşıklıkta kıyaslamak amacıyla filtre sayıları optimize edilerek toplam parametre sayısı 121.930'a sabitlenmiştir. Bu sayede performans farklarının model kapasitesinden ziyade doğrudan Kernel boyutunun öznitelik çıkarma yeteneğinden kaynaklandığı saptanmaktadır.

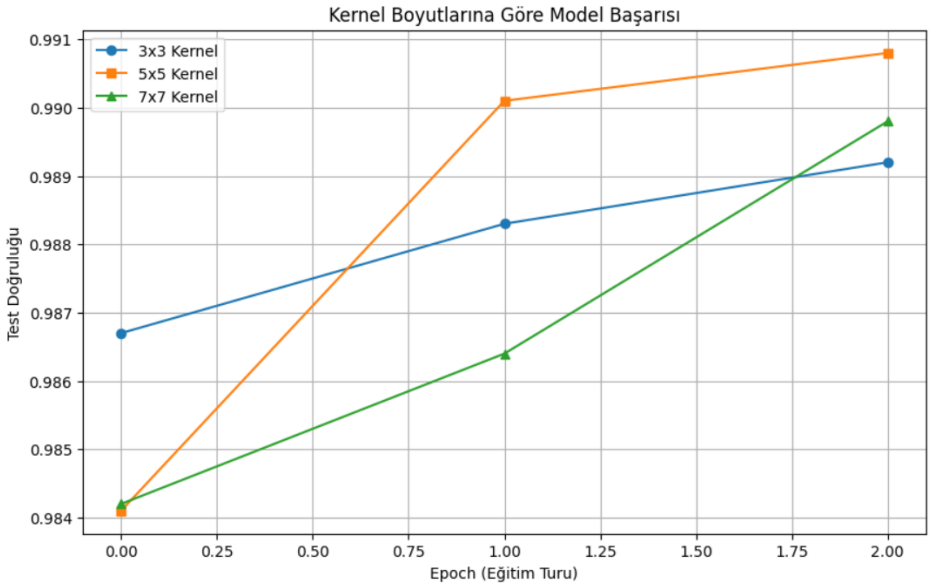


```
3x3 Toplam Parametre: 121930
5x5 Toplam Parametre: 121930
7x7 Toplam Parametre: 121930
```

6.Sonuç

Genel Değerlendirme

Bu çalışmada, CNN'lerin otomatik öznitelik çıkarma yeteneği sayesinde geleneksel yöntemlerden daha başarılı olduğu görülmüştür. CIFAR-10 veri setiyle yapılan deneyler, başarının sadece katman sayısına değil, Kernel boyutu gibi parametrelere bağlı olduğunu kanıtlamıştır. Özellikle düşük çözünürlüklü görüntülerde 3x3 ve 5x5'lik küçük Kernel'lerin, 7x7'lik büyük filtrelere kıyasla daha stabil ve etkili sonuçlar verdiği tespit edilmiştir.

Çalışmadan Edinilen Kazanımlar ve Öğrenilenler

Hiperparametrelerin Kritik Rolü: Model başarısının öğrenme hızı ve filtre boyutu gibi parametrelerin optimizasyonuna bağlı olduğu özellikle öğrenme hızının ağın kararlılığı üzerinde belirleyici olduğu görülmektedir.

Kernel Boyutu ve Detay Kaybı: Düşük çözünürlüklü verilerde büyük filtrelerin detay kaybına yol açtığı 3x3 gibi küçük Kernel'lerin ise daha az parametreyle daha derin özellikler yakaladığı saptanmaktadır.

Maliyet ve Verimlilik Dengesi: Filtre boyutu arttıkça donanım yükünün arttığı gerçek zamanlı sistemler için yüksek performanslı ancak düşük parametreli hafif modellerin gerekliliği anlaşılmaktadır.

Pratik Uygulama Sahaları: CNN'lerin tıbbi teşhis ve eğitim gibi pek çok sahada sadece akademik bir teori değil, hayati ve pratik çözümler sunan bir teknoloji olduğu kavranmaktadır.

KAYNAKÇA

[1] R. Talashilkar ve K. Tewari, “Analyzing the Effects of Hyperparameters on Convolutional Neural Network & Finding the Optimal Solution with a Limited Dataset”, içinde *2021 International Conference on Advances in Computing, Communication, and Control (ICAC3)*, Ara. 2021, ss. 1-5. doi: 10.1109/ICAC353642.2021.9697177.

[2] C. Xue, J. Zhang, J. Xing, Y. Lei, ve Y. Sun, “Research on Edge Detection Operator of a Convolutional Neural Network”, içinde *2019 IEEE 8th Joint International Information Technology and Artificial Intelligence Conference (ITAIC)*, May. 2019, ss. 49-53. doi: 10.1109/ITAIC.2019.8785855.

[3] Ş. Öztürk, U. Özkaya, B. Akdemir, ve L. Seyfi, “Convolution Kernel Size Effect on Convolutional Neural Network in Histopathological Image Processing Applications”, içinde *2018 International Symposium on Fundamentals of Electrical Engineering (ISFEE)*, Kas. 2018, ss. 1-5. doi: 10.1109/ISFEE.2018.8742484.

[4] M. S. Kartika, P. H. Gunawan, Indwiarti, ve N. Aquarini, “Detection of Kids Handwriting for Numbers With Convolutional Neural Network Algorithm”, içinde *2023 International Conference on Data Science and Its Applications (ICoDSA)*, Ağu. 2023, ss. 1-6. doi: 10.1109/ICoDSA58501.2023.10277403.

[5] N. Darapaneni, B. Krishnamurthy, ve A. R. Paduri, “Convolution Neural Networks: A Comparative Study for Image Classification”, içinde *2020 IEEE 15th International Conference on Industrial and Information Systems (ICIIS)*, Kas. 2020, ss. 327-332. doi: 10.1109/ICIIS51140.2020.9342667.

[6] S. Maitra, R. K. Ojha, ve K. Ghosh, “Impact of Convolutional Neural Network Input Parameters on Classification Performance”, içinde *2018 4th International Conference for Convergence in Technology (I2CT)*, Eki. 2018, ss. 1-5. doi: 10.1109/I2CT42659.2018.9058213.

[7] D. Chansong ve S. Supratid, “Impacts of Kernel Size on Different Resized Images in Object Recognition Based on Convolutional Neural Network”, içinde *2021 9th International Electrical Engineering Congress (iEECON)*, Mar. 2021, ss. 448-451. doi: 10.1109/iEECON51072.2021.9440284.

[8] Y. Hozak ve S. Paliy, “Optimizing Kernel Configurations and Convolutional Strategies for Efficient Shallow CNNs in Real-Time Vision Systems”, içinde *2025 IEEE 5th International Conference on Smart Information Systems and Technologies (SIST)*, May. 2025, ss. 1-6. doi: 10.1109/SIST61657.2025.11139312.