SUNUM 7: MODERN CNN MİMARİLERİ

ISPARTA UYGULAMLI BİLİMLER ÜNİVERSİTESİ

TEKNOLOJİ FAKÜLTESİ

DERS:MAKİNE ÖĞRENMESİ

Süleyman Yavuz

2312705001

CNN (EVRİŞİMLİ SİNİR AĞI) NEDİR?

Görüntü ve video gibi verileri işlemek için tasarlanmış derin öğrenme mimarisidir

Görüntüyü bozmaz; pikseller arasındaki fiziksel komşuluk ilişkilerini koruyarak resimdeki özellikleri (kenar, doku) kendi kendine öğrenir.

GELENEKSEL VE MODERN CNNLER

Geleneksel (Klasik) CNN'ler

•**LeNet-5 (1998):** Temeli attı ama donanıma takıldı.
•**AlexNet (2012):** GPU gücünü buldu, modeli büyüttü.
•**VGG-16 (2014):** Sadece katmanları üst üste yığarak derinliği artırdı, donanım limitlerini (138 Milyon parametre) sonuna kadar zorladı ve tıkandı.

Modern CNN'ler

•**ResNet (2015):** Ağı körü körüne derinleştirmek yerine "Atlama Bağlantıları" (Skip Connections) kullanarak verinin kaybolmasını engelledi.
•**Inception (2014/15):** Filtreleri arka arkaya değil, "Paralel" çalıştırarak işlem yükünü dağıttı.
•**MobileNet (2017):** Ağır evrişim işlemlerini iki hafif adıma bölerek matematiksel optimizasyon sağladı ve karmaşık yapay zekayı kısıtlı uç cihazlara sığdırdı.
•**EfficientNet (2019):** Derinlik, genişlik ve çözünürlüğü rastgele değil, kusursuz bir matematiksel katsayıyla aynı anda büyüterek donanım israfını bitirdi.

GELENEKSEL CNN VE MODERN CNN ARASINDAKİ FARKLAR.

Geleneksel CNN (Örn: VGG16): "Kaba Kuvvet"

- Sadece katman sayısını artırarak başarı arar.
- Devasa parametrelere ve yüksek hesaplama yüküne (FLOPs) sahiptir.
- Yalnızca güçlü sunucularda ve GPU'larda çalışır.

Modern CNN (Örn: MobileNet): "Akıllı Tasarım"

- Matematiksel optimizasyon (örn. parçalanmış evrişim) kullanır.
- Minimum parametre ile maksimum verim hedefler.
- Kısıtlı donanımlarda, gömülü sistemlerde ve uç cihazlarda (Edge AI) gerçek zamanlı çalışabilir.

CNN'IN ATASI: LENET-5 (1998)

- **Hiyerarşik Özellik Yakalama:** Görüntüyü temel çizgilerden başlayarak adım adım daha karmaşık nesne parçalarına doğru analiz eder.
- **Veri Süzme (Evrişim):** Matematiksel filtrelerle görüntüyü tarar; gereksiz pikselleri ayıklayıp sadece ayırt edici "izleri" (özellikleri) saklar.
- **Boyut Yönetimi (Pooling):** Kritik bilgiyi koruyarak veriyi sıkıştırır; bu sayede donanım yükünü azaltır ve görüntüdeki ufak kaymaları tolere eder.
- **Karar Mekanizması:** Süzülen tüm bu özellikleri birleştirerek görüntünün ne olduğuna dair nihai sınıflandırmayı yapar.

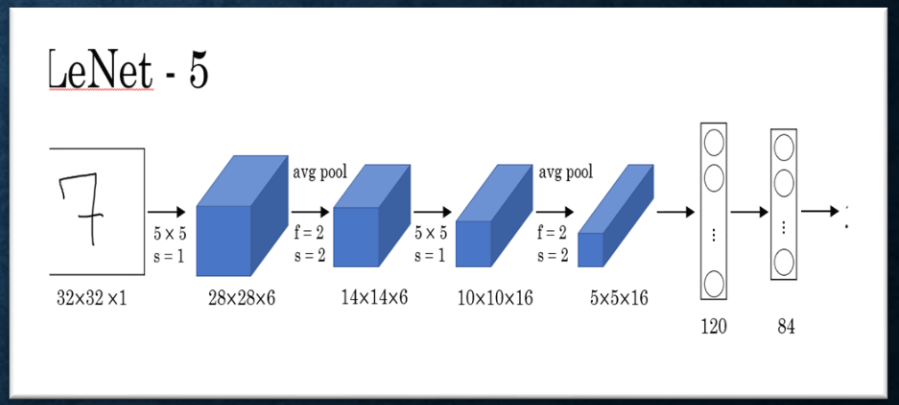

DONANIM DEVRİMİ VE ALEXNET (2012)

- **Paralel GPU İşleme:** Model, dönemin bellek sınırlarını aşmak için iki ayrı GPU kanalı üzerinden eğitildi.
- **ReLU ile Hızlanma:** Sigmoid gibi ağır fonksiyonlar yerine **ReLU** kullanılarak eğitim süresi 6 kat hızlandırıldı.
- **Veri Artırma ve Dropout:** Sistemin veriyi ezberlemesini (overfitting) engellemek için ilk kez gelişmiş düzenleme teknikleri kullanıldı.
- **Büyük Ölçekli Başarı:** ImageNet yarışmasında hata payını %25'ten %15'e indirerek derin öğrenme çağını resmen başlattı.

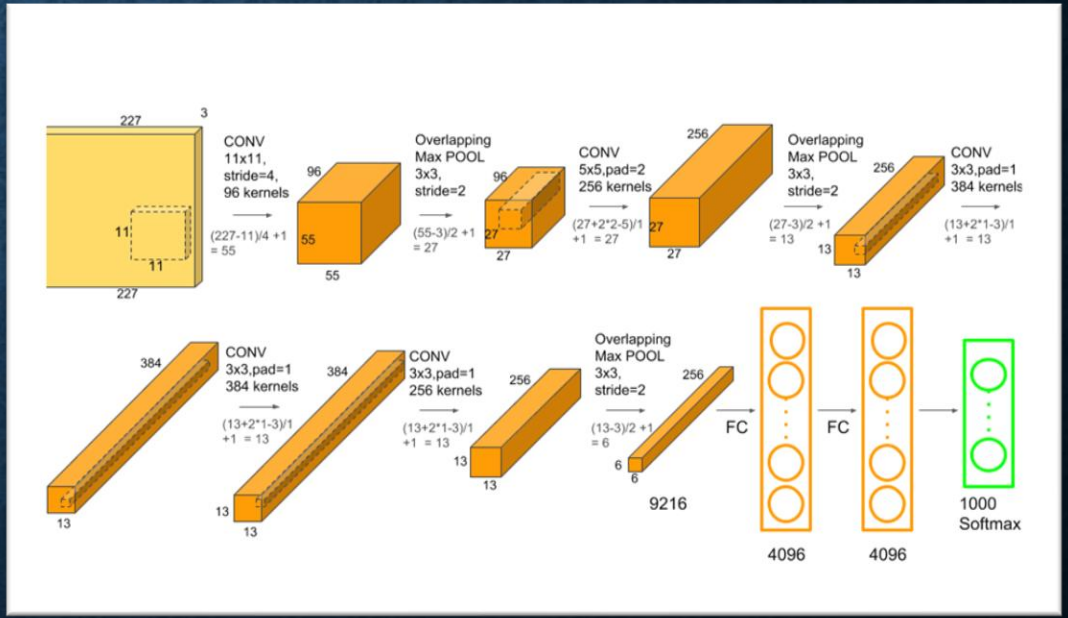

VGG-16 (2014)

•**Mimari Sadelik:** Karmaşık matematiksel filtreler yerine, tüm ağ boyunca sadece küçük (3x3) filtreler kullanılarak düzenli bir yapı kuruldu.
•**Derinlik Odaklı Başarı:** Katman sayısı 16'ya çıkarılarak (daha derin ağ) doğruluk oranı o güne kadarki en yüksek seviyeye çekildi.
•**Donanım Duvarı (Dezavantaj):** Bu kaba kuvvet stratejisi, modeli **138 Milyon** parametreye ulaştırdı. Devasa bir hafıza ve işlem gücü gerektirir.
•**Edge AI Uyumluluğu:** Kısıtlı donanımlara sahip gömülü sistemlerde çalıştırılması fiziksel olarak imkansızdır.

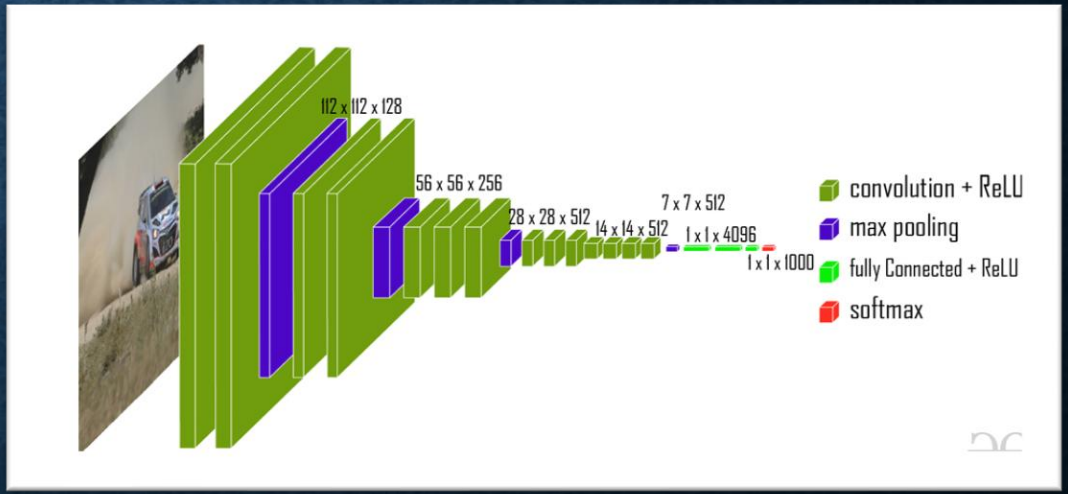

RESNET (2015) – DERINLIĞIN SINIRLARINI AŞMAK

- **Problem:** Ağlar derinleştikçe (50+ katman), gradyanlar geriye doğru akarken yok olur (Vanishing Gradient) ve eğitim durur.
- **Devrimsel Çözüm: Atlama Bağlantıları (Skip Connections).**
- **Mekanizma:** Verinin bir sonraki katmana doğrudan aktarılması, ağın "farkı" (residue) öğrenmesini sağlar.
- **Sonuç:** 152 ve daha fazla katmanlı, stabil ve yüksek doğruluğa sahip modellerin önü açılmıştır.

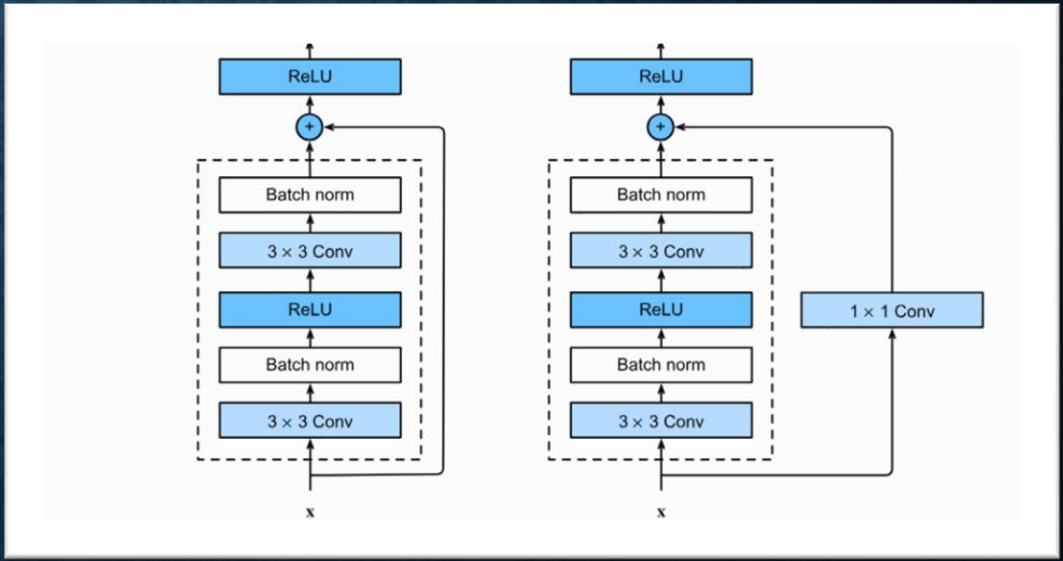

MODERN CNN'LER: INCEPTİON

•**Paralel İşleme:** Tek bir katmanda 1x1, 3x3, 5x5 konvolüsyonları ve ortaklama işlemlerini paralel olarak gerçekleştirir ("Inception Modülü").
•**Hesaplama Verimliliği:** Bu yapı, ağın işlem maliyetini artırmadan daha derin ve geniş olmasını sağlar, hesaplama karmaşıklığını kontrol altında tutar.
•**Boyut Azaltma:** Hesaplamayı optimize etmek için 1x1 konvolüsyonları (bottleneck katmanları) kullanarak boyut küçültme yapar.
•**Performans:** ILSVRC 2014 yarışmasında kazandığı başarıyla modern CNN mimarileri arasında önemli bir yere sahiptir.

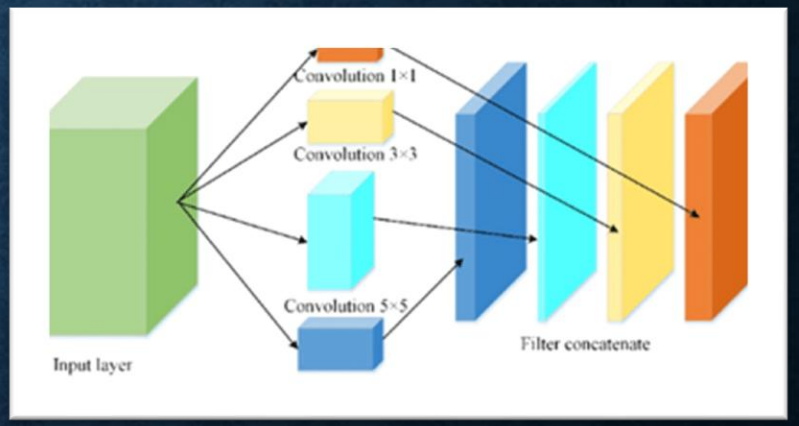

UÇ CIHAZLARDA YAPAY ZEKA (EDGE AI): MOBILENET

- **Tasarım Felsefesi:** Maksimum doğruluk yerine, **"Maksimum Donanım Verimliliği"**.
- **Devrimsel Matematik: Ayrıştırılmış Konvolüsyon (Depthwise Separable Convolution)**. Geleneksel ağır filtreleme işlemi, iki hafif adıma bölünür.
- **Müthiş Optimizasyon:** VGG-16'nın **~%3'ü** kadar parametreyle (sadece 4.2 Milyon) benzer doğruluk oranlarına ulaşır.
- **Donanım Çıktısı:** İşlem yükü (FLOPs) ve bellek (RAM) ihtiyacı drastik şekilde düşer; modeller otonom araçlarda, sensörlerde ve gömülü sistemlerde gerçek zamanlı çalışabilir hale gelir.

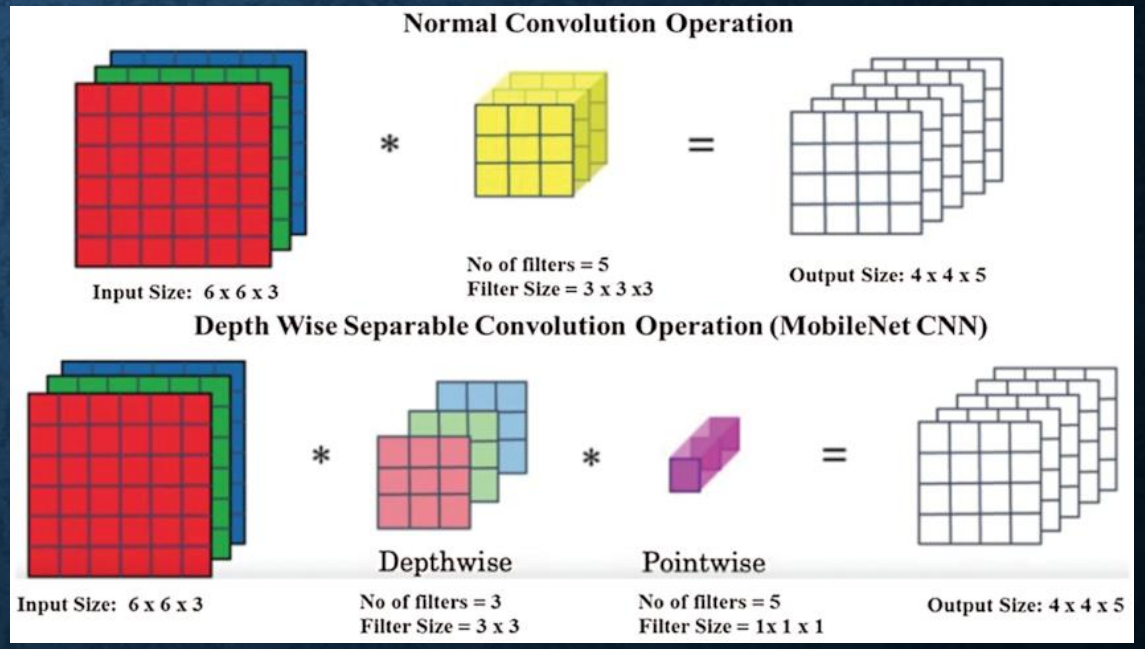

EFFICIENTNET – OPTIMIZASYONUN MATEMATIKSEL DENGE NOKTASI

- **Geleneksel Hata:** Katmanları (derinlik), kanalları (genişlik) veya görüntüyü (çözünürlük) rastgele artırmak verimsizdir.

- **EfficientNet Vizyonu:** Başarı için bu üç parametrenin birbirine bağlı bir katsayı ile ölçeklenmesi gerekir.

- **Compound Scaling:** Derinlik × Genişlik × Çözünürlük = Maksimum Verim.

EFFICIENTNET – OPTIMIZASYONUN MATEMATIKSEL DENGE NOKTASI

- **Bileşik Ölçekleme:** Derinlik (d), Genişlik (w) ve Çözünürlük (r) değişkenlerini, sabit bir (ϕ) katsayısı ile birbirine bağlıyoruz.
- **Denge Mekanizması:** * Daha büyük bir girdi görüntüsü için: Daha fazla genişlik (yeni pikselleri yakalamak) ve daha fazla derinlik (daha karmaşık şekilleri işlemek) gerekir.
- **Sonuç:** Donanım bütçesi (FLOPs) sabitken, verimliliği %10'lara varan oranda artıran bir mimari.

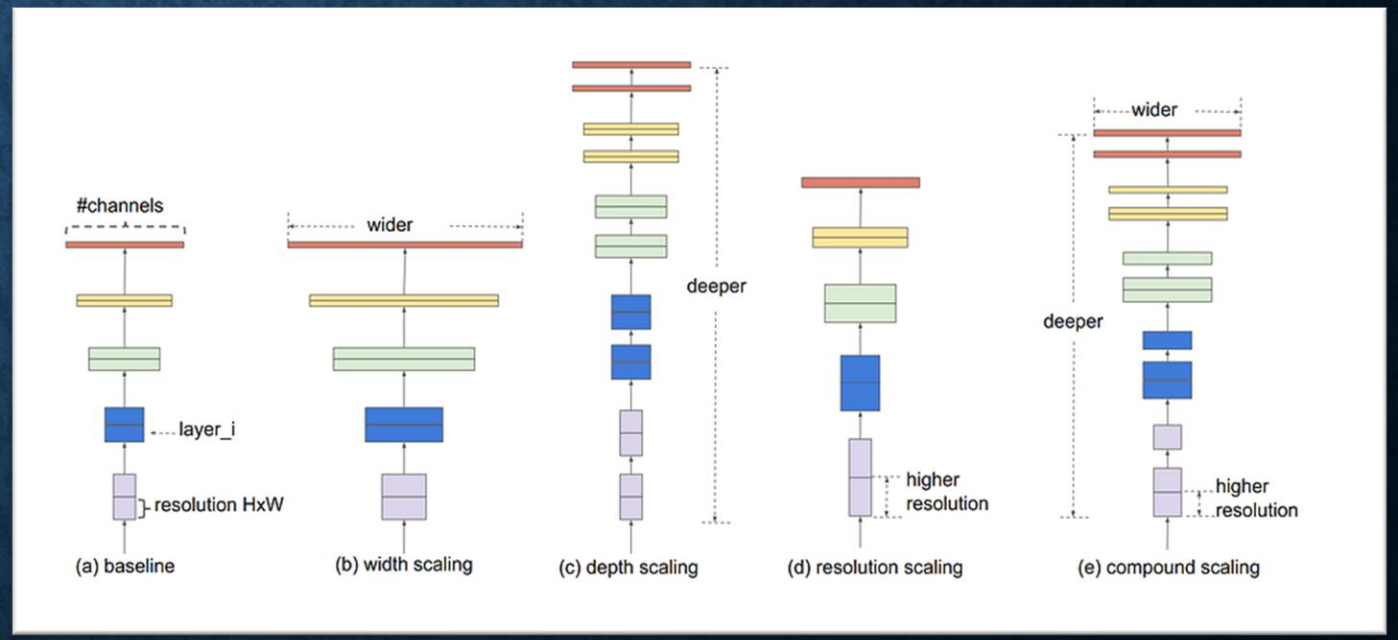

UYGULAMALI MODEL KARŞILAŞTIRMASI: VGG-16 VS. MOBILENETV2

- **Amaç:** Geleneksel ve modern CNN'lerin gerçek donanım üzerindeki performans farkını incelemek.
- **Test Ortamı:** 30 adet kedi köpek ve kuş görselleri bilgisayarın standart işlemcisi kullanılarak analiz edildi.
- **Ölçülen Metrikler:** Her bir görsel için tahmin süresi (Hız) ve Tahmin güven skoru (Doğruluk)
- **Temel Hedef:** Kısıtlı donanımda "hız ve doğruluk dengesinin" (trade-off) nasıl değiştiğini deneysel olarak kanıtlamak.

MINI PROJE
UYGULAMALI MODEL KARŞILAŞTIRMASI: VGG-16 VS. MOBILENETV2

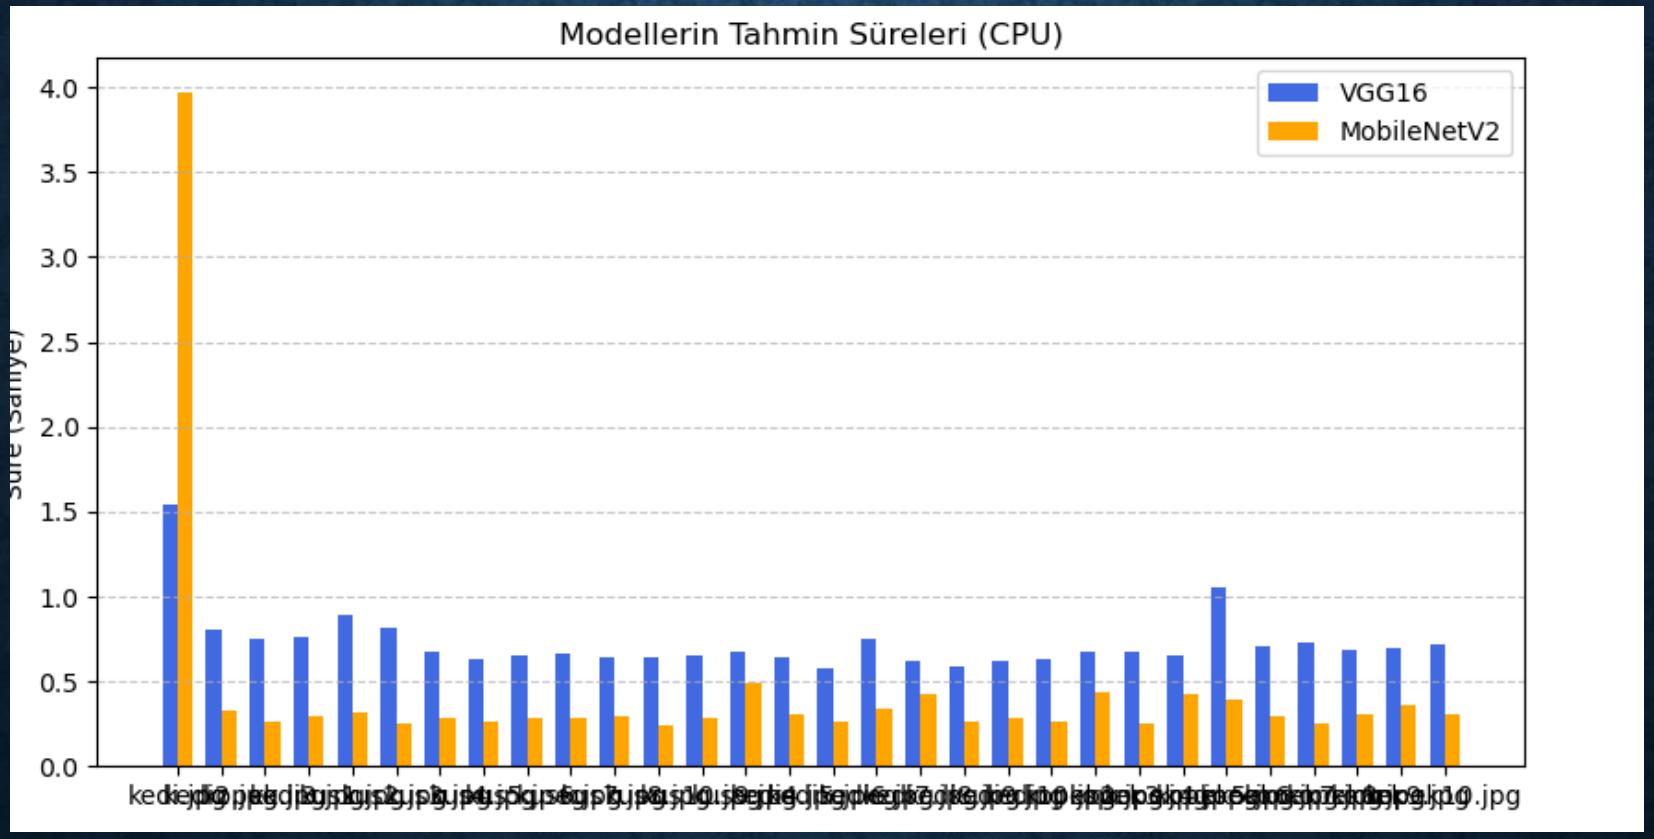

Tahmin Süresi: "Kaba Kuvvet" vs. "Hız"

MINI PROJE
UYGULAMALI MODEL KARŞILAŞTIRMASI: VGG-16 VS. MOBILENETV2

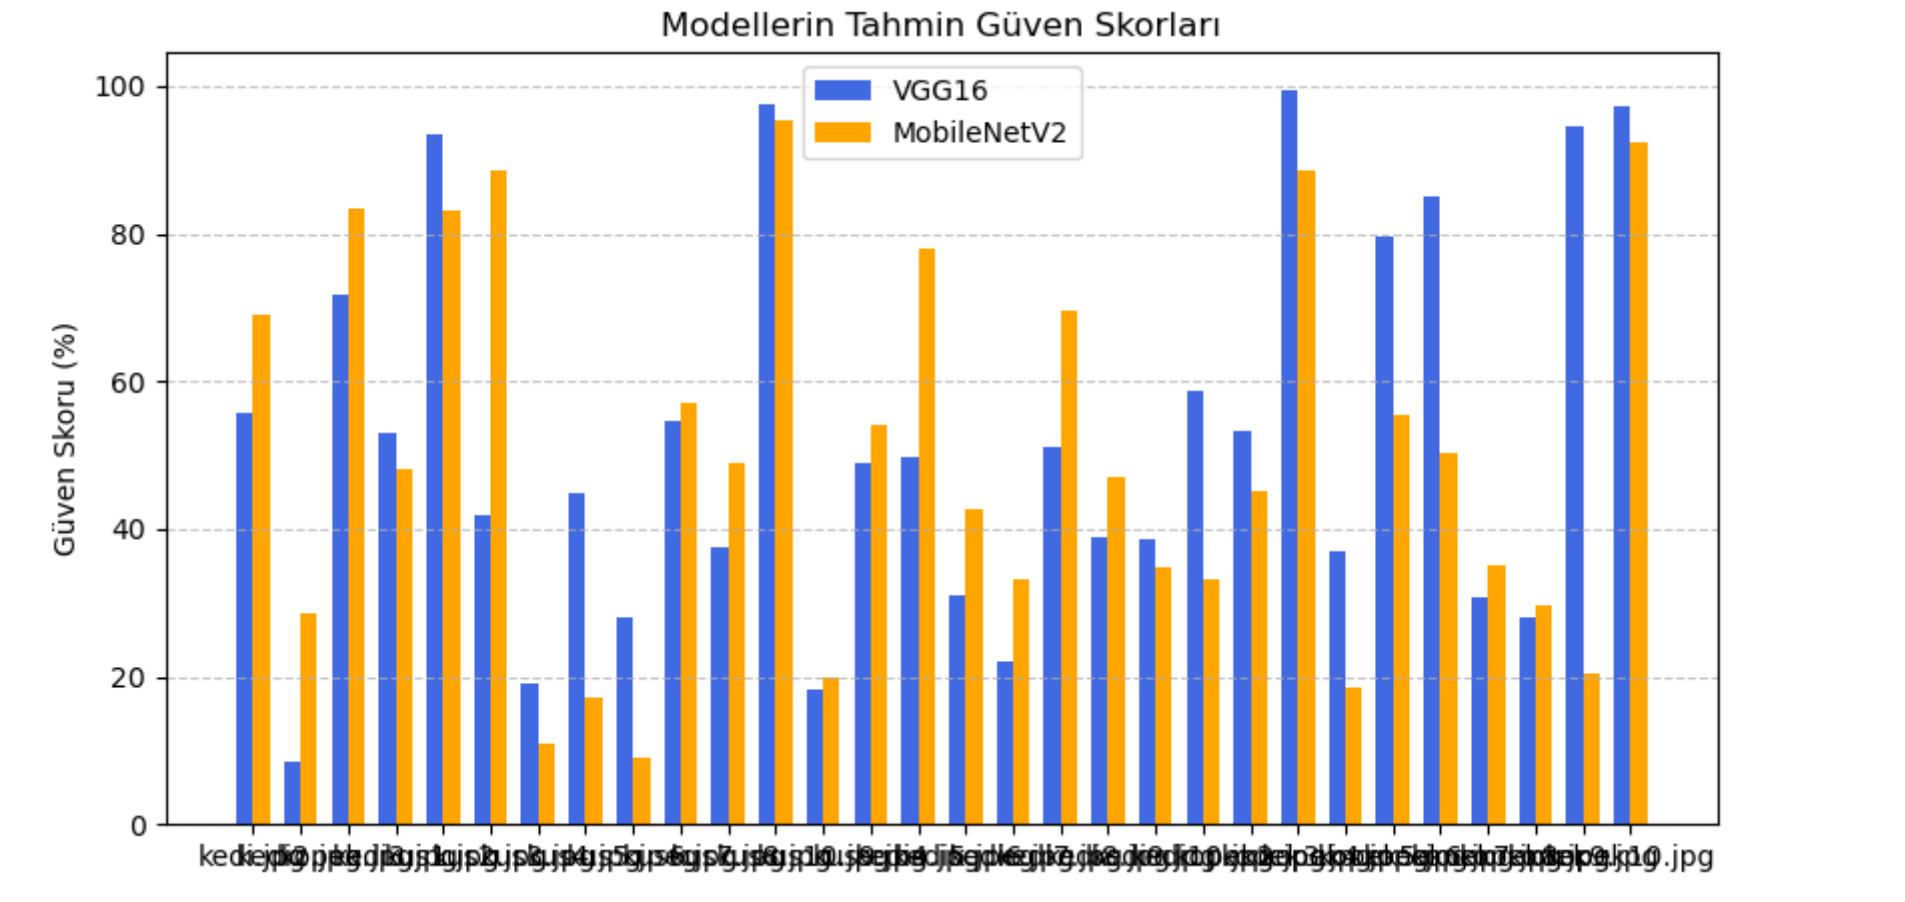

Tahmin Doğruluğu: "Verimlilik Dengesi"

Beni Dinlediğiniz için teşekkürler