

Makine Öğrenmesi Dersi Proje Raporu: Semantik Bölütleme (Semantic Segmentation) ve U-Net Mimarisi

1. Giriş

Bilgisayarlı görü (Computer Vision) alanında, bir görüntüyü anlamlandırmak için geliştirilen yöntemler yıllar içinde büyük bir evrim geçirmiştir. Başlangıçta sadece görüntünün bütününe bir etiket atayan "Sınıflandırma" (Classification) algoritmaları kullanılırken, daha sonra nesnelerin konumunu sınır kutuları (Bounding Box) ile belirten "Nesne Tespiti" (Object Detection) yöntemleri geliştirilmiştir. Ancak otonom araçlar, robotik ve tıbbi görüntüleme gibi kritik alanlarda nesnelerin sadece yaklaşık konumu değil, piksel bazındaki kesin sınırları hayati önem taşır.

Bu raporun ve yapılan çalışmanın amacı, görüntüdeki her bir pikselin ait olduğu sınıfı belirleyerek nesnelerin milimetrik sınırlarını çıkaran "Semantik Bölütleme" (Semantic Segmentation) problemini incelemektir. Konunun temel mantığı, bu işlemi gerçekleştirmek için kullanılan Encoder-Decoder mimarilerinin çalışma prensipleri ve özellikle bu alanda altın standart kabul edilen U-Net modelinin yapısı detaylı bir şekilde ele alınacaktır. Ayrıca raporun son bölümünde, teorik bilgilerin pratiğe döküldüğü mini bir kodlama projesi ve elde edilen sonuçlar sunulacaktır.

2. Temel Kavramlar

Semantik bölütleme algoritmalarının anlaşılabilmesi için bazı temel bilgisayarlı görü ve makine öğrenmesi kavramlarının bilinmesi gerekmektedir.

- Piksel Bazlı Sınıflandırma (Pixel-wise Classification):** Görüntüyü tek bir nesne olarak ele almak yerine, matrisi oluşturan (örneğin $256 * 256$ boyutlarındaki) her bir pikselin teker teker sınıflandırma işlemine tabi tutulmasıdır. Çıktı, girdi görüntüsüyle aynı boyutta olan bir "Olasılık Haritası"dır.
- Aşırı Uyum (Overfitting):** Modelin eğitim verisini ezberleyip, daha önce hiç görmediği test verilerinde başarısız olması durumudur. Bölütleme mimarilerinde bunu önlemek için "Dropout" gibi teknikler kullanılır.

- **Değerlendirme Metrikleri (IoU - Intersection over Union):** Sınıflandırma problemlerinde kullanılan standart "Doğruluk" (Accuracy) metriği, piksellerin çoğunun arka plan olduğu durumlarda yanıltıcıdır. Bu nedenle bölütlemeye Jaccard Endeksi olarak da bilinen IoU kullanılır. Formülü şu şekildedir:

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

Burada A gerçek maskeyi (Ground Truth), B ise modelin tahmin ettiği maskeyi temsil eder. Hedef bu oranın 1.0'a (yani %100 örtüşmeye) yaklaşmasıdır.

3. Yöntem / Model Açıklaması

Geleneksel Evrişimli Sinir Ağları (CNN), ortak özellikleri çıkarmak için havuzlama (Pooling) işlemleriyle görüntünün mekansal boyutunu sürekli küçültür. Bu durum, boyutun orijinal görüntüyle aynı olması gereken bölütleme işlemleri için uygun değildir. Bu uzamsal kayıp problemini çözmek amacıyla **Encoder-Decoder (Kodlayıcı-Kod Çözücü)** mimarileri geliştirilmiştir.

Algoritmanın Çalışma Mantığı (Adım Adım):

1. **Encoder (Kodlayıcı):** Görüntü, evrişim (Convolution) ve havuzlama (Max Pooling) katmanlarından geçirilerek adım adım küçültülür. Bu aşamada kanal sayısı artarken, ağ resimdeki şekillerin, dokuların ve nesnelerin ne olduğunu (bağlam bilgisini) öğrenir.
2. **Bottleneck (Darboğaz):** Boyutun en küçük, anlamsal özelliklerin en yoğun olduğu geçiş noktasıdır.
3. **Decoder (Kod Çözücü):** Öğrenilen bağlam bilgisini alarak, Transpose Convolution (Deconvolution) adı verilen öğrenilebilir bir işlemle matrisi tekrar orijinal boyutuna büyütür. Normal büyütme algoritmalarının aksine, Transpose Convolution eğitim sırasında pikseller arasındaki boşlukları en optimum değerlerle doldurmayı öğrenir.

(Buraya word dosyasında Encoder-Decoder veya Transpose Convolution şeması ekleyiniz ve altına "Şekil 1: Encoder-Decoder Genel Mimarisi" yazınız)

U-Net ve Atlama Bağlantıları (Skip Connections):

U-Net, bu mimarinin en gelişmiş hallerinden biridir. Görüntü küçültülüp tekrar büyütüldüğünde nesnelerin hassas kenar çizgileri kaybolur. U-Net, bu bilgi kaybını önlemek için kodlayıcı kısmındaki yüksek çözünürlüklü özellik haritalarını kopyalar ve kod çözücü kısmındaki karşılık gelen katmanlarla birleştirir (Concatenation). Bu "Atlama Bağlantıları" sayesinde ağ, hem piksellerin ne olduğunu hem de tam konumlarını hatırlayarak yüksek hassasiyetli bir maske üretir.

4. Uygulama Alanları

Semantik bölütleme, günümüzde yapay zekanın gerçek dünyada en aktif ve en kritik şekilde kullanıldığı teknolojilerden biridir:

- **Otonom Araçlar ve Sürüş Asistanları:** Aracın yönlendirilmesi için sürülebilir yol alanının, şeritlerin ve yayaların milimetrik sınırlarının gerçek zamanlı olarak tespit edilmesi.
- **Tıbbi Görüntüleme:** MR veya X-Ray görüntülerinde doktorların gözden kaçırabileceği tümörlerin, kanserli hücrelerin veya kan damarlarının sınırlarının çizilerek teşhise yardımcı olunması (U-Net'in çıkış noktasıdır).
- **Uydu Görüntüsü Analizi:** Tarım arazilerinin verimlilik haritalarının çıkarılması, orman yangını sonrası hasar tespiti veya şehir planlaması için binaların tespiti.

5. Yapılan Mini Proje Açıklaması

Bu projenin uygulama aşamasında, teorik olarak incelenen U-Net mimarisi Python programlama dili ve TensorFlow/Keras kütüphaneleri kullanılarak sıfırdan oluşturulmuştur.

- Kullanılan Veri Seti: Modelin çalışma mantığını net, hızlı ve hatasız bir şekilde gösterebilmek amacıyla sentetik bir veri seti üretilmiştir. Python kodları ile siyah arka plan üzerine rastgele boyut ve konumlarda beyaz daireler çizilmiş, modele zorluk katmak amacıyla görüntüye yapay gürültü (noise) eklenmiştir. Modelin hedefi bu gürültülü görüntünün içindeki dairenin kesin sınırlarını (Ground Truth) bulmaktır. 500 eğitim ve 50 test verisi üretilmiştir.
- Kullanılan Yöntem ve Ön İşleme: Görüntüler ve maskeler ağı işleyebilmesi için 128×128 piksel boyutunda tek kanallı (siyah-beyaz) matrisler olarak tanımlanmış ve 0 ile 1 aralığına normalize edilmiştir.
- Kullanılan Kodlamalar: Proje, Jupyter Notebook ortamında geliştirilmiştir. Orijinal U-Net makalesine sadık kalınarak minyatür bir versiyon kodlanmıştır. Kodlayıcı kısmında özellik çıkarımı için Conv2D ve MaxPooling2D katmanları kullanılmıştır. Kod çözücü kısmında ise resmi orijinal boyutuna ulaştırmak için Conv2DTranspose (Transpose Convolution) işlemi uygulanmış ve sınır kaybını önlemek için Concatenate fonksiyonu ile Atlama Bağlantıları (Skip Connections) kodlanmıştır.
- Eğitim Süreci: Model, ikili bölütleme problemine uygun olan binary_crossentropy kayıp fonksiyonu ve Adam optimizasyon algoritması kullanılarak 5 epok boyunca eğitilmiştir.
- Elde Edilen Sonuçlar: Eğitilen model, daha önce hiç görmediği test verileri üzerinde denenmiştir. Jupyter Notebook üzerinde matplotlib ile çizdirilen sonuçlara göre; U-Net modelinin görüntüdeki gürültüleri filtreleyerek nesnenin tam geometrik sınırlarını başarıyla yakaladığı ve gerçek maskeye (Ground Truth) neredeyse %100 oranında benzeyen olasılık haritaları ürettiği kanıtlanmıştır.

6. Sonuç

Bu çalışma kapsamında, Makine Öğrenmesi alanındaki en güçlü yaklaşımlardan biri olan Semantik Bölütleme ve Encoder-Decoder mimarileri incelenmiştir. Geleneksel sınıflandırma ağlarının konumsal bilgi kaybı (uzamsal çözünürlüğün yok olması) problemi anlaşılmış ve bu problemin Transpose Convolution işlemleriyle nasıl çözüldüğü görülmüştür.

Özellikle U-Net mimarisindeki atlama bağlantılarının (Skip Connections), yapay zekanın nesne sınırlarını hatırlamasındaki kritik rolü uygulamalı olarak test edilmiştir. Mini proje aşamasında yapılan kodlama ve model eğitimleri sonucunda; görüntü işleme algoritmalarının, uygun veri ön işleme ve doğru ağ mimarisi ile çok detaylı ve milimetrik tahminler yapabileceği uygulamalı olarak öğrenilmiştir.

7. Kaynakça

[1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Cham: Springer International Publishing, 2015, pp. 234–241.