



ISPARTA **UYGULAMALI BİLİMLER** **ÜNİVERSİTESİ**

Ulaş Arıcı

2412705044

Makina Öğrenmesine Giriş

Makine öğrenmesinde modelin önceden belirlenmiş sabit sınıfları (örneğin kedi, köpek, kuş) ezberlemek yerine, veriler arasındaki benzerlik veya farklılık derecesini (mesafeyi) hesaplamayı öğrenmesidir. Amacı; aynı kişiye ait fotoğrafları matematiksel uzayda birbirine yaklaştırırken, farklı kişilerin fotoğraflarını birbirinden olabildiğince uzaklaştıran bir fonksiyon bulmaktır. Standart sınıflandırma algoritmalarıyla bir şirketin yüz tanıma sistemini yaparsan, model çıkışında çalışan sayısı kadar sınıf (örneğin 1000 kişi) olması gerekir. Şirkete yeni bir çalışan alındığında tüm yapay zeka modelini baştan eğitmen gerekir. Bu imkansızdır. Klasik derin öğrenme modellerinin bir nesneyi tanıması için binlerce örneğe ihtiyacı vardır. Ancak metrik öğrenme sayesinde, sisteme sadece tek bir fotoğraf (örneğin telefonuna yüzünü ilk kaydettiğin an) vererek sistemin seni ömür boyu, farklı ışıklarda ve açılarda tanımasını sağlayabilirsin.

TEMEL KAVRAMLAR

One-shot Learning (Tek Seferlik Öğrenme) : makine öğrenmesinde insan zihnine en çok yaklaşan konseptlerden biridir. Geleneksel derin öğrenme algoritmalarının bir elmayı tanıması için on binlerce elma fotoğrafı görmesi gerekirken; küçük bir çocuk hayatında tek bir elma görüp, ertesi gün başka bir elmayı kolayca tanıyabilir. İşte One-shot Learning, yapay zekaya bu "tek örnekten genelleme yapma" yeteneğini kazandırır. Yüz tanıma sistemleri bunun en popüler örneğidir. Sisteme parmak izinizi veya yüzünüzü sadece bir kez (one-shot) tanıtırsınız ve sistem sizi bir daha unutmaz.

Siamese Networks (Siyam Ağları) : İsmi "Siyam ikizlerinden" (yapışık ikizler) alır. Çünkü bu mimaride iki ayrı sinir ağı varmış gibi görünse de, aslında aynı "beyni" (ağırlıkları ve parametreleri) paylaşan tek bir ağ vardır. Elektronik ve sinyal işleme dünyasından bir analogi yapmak gerekirse: Elinde tamamen aynı frekans tepkisine ve devre elemanlarına sahip iki adet filtre (filter) olduğunu düşün. İki farklı sinyali bu iki ayrı filtreye aynı anda sokarsın. Filtreler birebir aynı olduğu için, eğer giriş sinyalleri birbirine benziyorsa çıkışlar da çok benzeyecektir. Siyam ağlarının mantığı tam olarak budur.

Triplet Loss (üçlü kayıp) : Algoritma, eğitim iterasyonları sırasında veri setinden seçilen üçlü veri grupları (triplets) üzerinden çalışır. Bir üçlü küme şu elemanlardan oluşur: Algoritma, eğitim iterasyonları sırasında veri setinden seçilen üçlü veri grupları (triplets) üzerinden çalışır. Bir üçlü küme şu elemanlardan oluşur: X_a (Anchor): Referans veri noktası. X_p (Positive): Anchor ile aynı sınıfa ait veri noktası. X_n (Negative): Anchor'dan farklı bir sınıfa ait veri noktası.

$L(X_a, X_p, X_n) = \max(0, D(f(X_a), f(X_p)) - D(f(X_a), f(X_n)) + a)$ formülüyle hesaplanır.

Embedding (gömmme) mantığı, en temel haliyle karmaşık ve yüksek boyutlu bir veriyi (örneğin milyonlarca pikselden oluşan bir yüz fotoğrafını veya uzun bir metni), makinenin kolayca kıyaslayabileceği anlamlı ve düşük boyutlu bir sayı dizisine (vektöre) dönüştürme işlemidir.

YÖNTEM VE MODEL AÇIKLAMASI

Yüz tanıma sistemlerinde standart bir sınıflandırma modeli (örneğin resme bakıp "bu kedi", "bu köpek" diyen modeller) kullanılmaz. Bunun yerine Metrik Öğrenme (Metric Learning) yöntemi ve model mimarisi olarak Siyam Ağları (Siamese Networks) kullanılır. Modelin Yapısı: Siyam ağları, birbirinin tamamen aynısı olan (aynı ağırlıklara ve katmanlara sahip) iki paralel Evrişimli Sinir Ağı (CNN) yapısından oluşur. Yöntemin Amacı: Model, kişilerin kim olduğunu ezberlemez. Bunun yerine, "İki fotoğraf aynı kişiye mi ait, yoksa farklı kişilere mi?" sorusuna cevap verecek genel bir benzerlik / uzaklık fonksiyonu öğrenir.

Uygulama Alanları

Biyometrik Cihaz Güvenliği (FaceID ve Akıllı Kilitler) : En bilinen ve en başarılı örnektir. Günlük hayatta kendi tabletinin veya akıllı telefonunun ekran kilidini açarken arka planda tam olarak anlattığımız Siyam Ağları ve One-Shot Learning çalışır.

Akıllı Gözetim ve Geçiş Kontrol Sistemleri : Havaalanları, sınır kapıları veya modern şirket plazaları artık kartlı geçişi bırakıp tamamen yüz tanımayı kullanıyor.

Dijital Bankacılık ve KYC (Müşterini Tanı) Süreçleri : Günümüzde banka şubesine gitmeden hesap açarken uygulama senden kimlik kartının fotoğrafını, ardından da yüzünün bir selfiesini (hatta bazen sağa sola dönmeni) ister. Sistem, kimliğin üzerindeki yıllar önce çekilmiş, düşük çözünürlüklü ve iki boyutlu fotoğraf ile o anki üç boyutlu yüzünün özellik vektörlerini çıkarır

Yapılan Mini Proje Açıklaması

Bir Siyam Ağının (Siamese Network) ürettiği varsayılan özellik vektörleri (embeddings) ele alınmış ve bu vektörler arasındaki matematiksel açısal yakınlık, temel lineer cebir işlemleriyle hesaplanmıştır. Amaç, sistemin "aynı kişi" ile "farklı kişi" ayrımını yaparken arka planda çalıştırdığı matematiği şeffaf bir şekilde kanıtlamaktır.

Çalışmada devasa bir yüz fotoğrafı veri seti (örneğin LFW veya CelebA) yerine, sistemin mantığını göstermek amacıyla Sentetik (Temsili) Özellik Vektörleri Veri Seti kullanılmıştır. Gerçek bir senaryoda bir CNN'den çıkacak olan 128 boyutlu matrisler, anlaşılabilir olması adına 4 boyutlu (1×4) öznitelik dizilerine indirgenmiştir.

Benzerlik ölçümü için Kosinüs Benzerliği (Cosine Similarity) yöntemi kullanılmıştır. Bu yöntem, vektörlerin uzaydaki uzunluklarına (magnitude) değil, aralarındaki açığa odaklandığı için yüz tanımda parlaklık veya kontrast değişimlerine karşı Öklid mesafesine göre daha dirençlidir.

```
import numpy as np
```

```
from numpy.linalg import norm
```

```
# 1. Veri Seti (Temsili Vektörler)
```

```
yuz_A = np.array([4.0, 2.0, 7.0, 1.0])
```

```
yuz_B = np.array([3.5, 2.5, 6.5, 1.5])
```

```
yuz_C = np.array([-4.0, -2.0, 1.0, -5.0])
```

```
# 2. Kosinüs Benzerliği Fonksiyonu
```

```
def cosine_benzerlik(v1, v2):
```

```
    nokta_carpimi = np.dot(v1, v2)
```

```
    buyukluk_v1 = norm(v1)
```

```
    buyukluk_v2 = norm(v2)
```

```
    return nokta_carpimi / (buyukluk_v1 * buyukluk_v2)
```

```
# 3. Hesaplamalar
```

```
benzerlik_AB = cosine_benzerlik(yuz_A, yuz_B)
```

```
benzerlik_AC = cosine_benzerlik(yuz_A, yuz_C)
```

```
# 4. Çıktıların Yazdırılması
```

```
print(f'Aynı kişinin iki fotoğrafı (A ve B) arasındaki benzerlik: {benzerlik_AB:.4f}')
```

```
print(f'Farklı kişilerin fotoğrafları (A ve C) arasındaki benzerlik: {benzerlik_AC:.4f}')
```

Aynı kişinin iki fotoğrafı (A ve B) arasındaki benzerlik: 0.9855

Farklı kişilerin fotoğrafları (A ve C) arasındaki benzerlik: -0.2198

SONUÇ

Bu çalışmada, modern yapay zekanın en zorlu problemlerinden biri olan "sınırsız ve sürekli değişen sınıfları tanıma" (Face Recognition) probleminin, standart sınıflandırma algoritmalarıyla çözölemeyeceğı görölmüştür. Geleneksel modeller ezberle dayalı çalışırken, Metrik Öğrenme (Metric Learning) yaklaşımının sisteme "kıyaslama yapma ve benzerlik kurma" yeteneğı kazandırdığı tespit edilmiştir. Siyam Ağları (Siamese Networks) mimarisi ve Triplet Loss optimizasyonu sayesinde, yüksek boyutlu görsel verilerin (piksellerin), çok daha düşük boyutlu ve anlamlı matematiksel vektörlere (Embedding) başarıyla dönüştürölebildiğı anlaşılmıştır. Geliştirilen mini proje uygulamasında da göröldüğü üzere, sinir ağlarının eğittiğı bu özellik vektörleri arasındaki Kosinüs Benzerliğı, sistemin kimlik doğrulama kararını (eşik değeri üzerinden) milisaniyeler içinde ve yüksek doğrulukla verebilmesini sağlamaktadır. Sonuç olarak yüz tanıma; bir resmi ezberleme işi değil, uzaydaki iki nokta arasındaki mesafeyi ölçme işidir.

Sınıflandırmadan Uzaklık Ölçümüne Geçiş: Makine öğrenmesinde her problemin sınıflandırma (Classification) olmadığı; özellikle kişi tanıma gibi sistemlerde veriyi ezberlemek yerine "aralarındaki farkı (mesafeyi) ölçmeyi" öğrenmenin (Metrik Öğrenme) zorunlu olduğu kavranmıştır.

One-Shot Learning'in Gücü: Akıllı telefonların yüz kilidi gibi sistemlerde modelin baştan eğitilmesine gerek kalmadan, sadece tek bir referans fotoğrafla (Anchor) sistemin nasıl yeni bir insanı tanıyabildiğı anlaşılmıştır.

Triplet Loss ve Uzak Geometrisi: Ağın sadece doğruları birbirine çekmekle kalmayıp, yanlışları da belirli bir güvenlik marjı (Margin / α) kadar uzağı itmesi gerektiğı öğrenilmiştir. Bu sayede özellik uzayında (Latent Space) kusursuz kümeler oluştuğı görölmüştür.

Pikselden Anlama (Embedding Matrisleri): Bilgisayarlı görünün (Computer Vision) nihai amacının, ışık veya açıdan bağımsız olarak, insan yüzünü temsil eden 128 veya 512 boyutlu ayırt edici "sayısal kimlik kartları" (Embedding) üretmek olduğu görölmüştür.

Matematiğın Koda Dönüşümü: Sadece teorik bir konsept olan "vektörel benzerlik" mantığının, Python ve lineer cebir (NumPy) kullanılarak adım adım nasıl hesaplandığı ve bir donanım/yazılım sisteminde (kapı kilidi/eşik değeri) karar motoruna nasıl dönüştüğü pratikte tecrübe edilmiştir.

KAYNAKÇA

1. Schroff, F., Kalenichenko, D., & Philbin, J. (2015). FaceNet: A unified embedding for face recognition and clustering. *In Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 815-823).
2. Koch, G., Zemel, R., & Salakhutdinov, R. (2015). Siamese neural networks for one-shot image recognition. *In ICML deep learning workshop* (Vol. 2, No. 1, p. 0).
3. Bellet, A., Habrard, A., & Sebban, M. (2013). A survey on metric learning for feature vectors and structured data. *arXiv preprint arXiv:1306.6709*.
4. Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585(7825), 357-362.
5. Taigman, Y., Yang, M., Ranzato, M. A., & Wolf, L. (2014). DeepFace: Closing the gap to human-level performance in face verification. *In Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1701-1708).
6. Parkhi, O. M., Vedaldi, A., & Zisserman, A. (2015). Deep face recognition. *In British Machine Vision Conference (BMVC)*.
7. Deng, J., Guo, J., Xue, N., & Zafeiriou, S. (2019). ArcFace: Additive angular margin loss for deep face recognition. *In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 4690-4699).