




Makine Öğrenmesine Giriş

Tekrarlayan Sinir Ağları: GRU, LSTM, Bidirectional RNN ve Deep RNN

YUNUS EMRE GÜLER — 2322705047

GRU (Gated Recurrent Unit)

GRU, sıralı verilerdeki zamansal bağımlılıkları öğrenmek için tasarlanmış, LSTM'in daha sade bir alternatifidir. Bilgiyi ne kadar süreyle saklayacağına iki temel kapı mekanizmasıyla karar verir.

Güncelleme Kapısı (Update Gate)

Geçmişteki bilgilerin ne kadarının bir sonraki adıma aktarılacağını belirler. Uzun vadeli bağımlılıkları korumayı sağlar.

Sıfırlama Kapısı (Reset Gate)

Geçmiş bilginin ne kadarının göz ardı edileceğini kontrol eder; kısa vadeli örüntüleri öğrenmede kritik rol oynar.

GRU'nun Avantajı

LSTM'e kıyasla daha az parametreye sahip olan GRU, eğitim sürecini hızlandırır ve daha küçük veri setlerinde bile rekabetçi sonuçlar üretebilir. Hesaplama verimliliği gerektiren uygulamalar için ideal bir tercihtir.



GRU, LSTM'in üç kapısını iki kapıya indirger — bu da modeli hem daha hızlı hem de daha az karmaşık kılar.

GRU Mimarisi


Şemada görüldüğü üzere, giriş her iki kapıya (Reset Gate ve Update Gate) aynı anda iletilmekte; iki kapının çıktıları birleştirilerek nihai çıktı üretilmektedir.

What are GRUs?

A type of RNN for sequential data

Uses 2 gates: update and reset

Faster and simpler than LSTM



LSTM (Long Short-Term Memory)

LSTM, uzun veri dizilerindeki kritik bilgileri kaybetmeden saklayabilen gelişmiş bir RNN mimarisidir. Doğal dil işleme, borsa tahmini ve ses tanıma gibi alanlarda geçmiş bilginin önem taşıdığı durumlarda tercih edilir.

1

Hücre Durumu (Cell State)

LSTM'in kalbidir. Bilginin aktığı bir "taşıma bandı" işlevi görür; kapılar aracılığıyla bu banttaki bilgi eklenir ya da silinir.

2

Forget Gate

Hangi bilginin hücre durumundan atılacağına karar veren sigmoid tabanlı kapıdır.

3

Input Gate

Hangi yeni bilginin hücre durumuna yazılacağını belirler; tanh aktivasyonu ile aday değerler oluşturulur.

4

Output Gate

Hücre durumunun hangi kısmının bir sonraki gizli duruma (hidden state) aktarılacağını seçer.

Cell State: Bilgi Taşıyıcı Bant

Hücre durumu, bir fabrikadaki taşıyıcı bant gibi çalışır.

Bilgi, bu bant üzerinde uzun diziler boyunca yavaş ve düzenli biçimde ilerler. Böylece önemli detaylar kaybolmadan korunabilir.

Kapılar ise birer valf gibi davranır: hangi yeni bilginin ekleneceğine ve hangi eski bilginin çıkarılacağına karar verir.

Fabrika

Bilginin işlendiği sistem.

Taşıyıcı Bant

Bilgiyi adım adım taşıyan hücre durumu.

Kapılar / Valfler

Bilgiyi ekler, seçer veya siler.


Sigmoid Fonksiyonu: 0 ile 1 Arasında Karar

Sigmoid fonksiyonu, bir değeri **0 ile 1** arasına sıkıştırır.

Bu yüzden ağ, bir bilginin **unutulup unutulmayacağına** ya da **geçirilip geçirilmeyeceğine** bu oranla karar verir.


0 "tamamen unut", **1** ise "tamamen geçir" anlamına gelir. $\sigma(x) = \frac{1}{1+e^{-x}}$

Örnek olarak **0.2** düşük geçişi, **0.5** orta kararı, **0.8** ise güçlü geçişi temsil eder.



$\sigma(x) = \frac{1}{1 + e^{-x}}$

LSTM ve GRU: Mimari Karşılaştırma



Temel Farklar

- **LSTM:** 3 kapı (forget, input, output) + ayrı hücre durumu — daha güçlü hafıza kapasitesi
- **GRU:** 2 kapı (reset, update) + birleşik gizli durum — daha hızlı eğitim

❏ Karmaşık ve uzun bağımlılıklar için LSTM; hız ve verimlilik öncelikliyse GRU tercih edilir.

Bidirectional RNN (Çift Yönlü RNN)

Bidirectional RNN (BiRNN), bir diziye yalnızca soldan sağa değil, aynı zamanda sağdan sola da işleyerek bağlamı iki yönden öğrenen bir sinir ağı yapısıdır. Bu yaklaşımda İleri yönlü (Forward) katman diziye baştan sona okurken, geri yönlü (Backward) katman aynı diziye sondan başa işler. Her zaman adımında iki katmandan gelen bilgiler birleştirilir ve böylece model, hem önceki hem de sonraki öğelerin etkisini birlikte değerlendirerek daha zengin bir temsil üretir.

Bu birleşik bağlam sayesinde çıktı y, tek yönlü bir RNN'e göre daha kapsamlı olur ve özellikle cümlelerin tamamını anlamının önemli olduğu görevlerde daha başarılı sonuçlar verir.

İleri Yön

Diziye soldan sağa işler ve önceki bilgileri taşır.

Geri Yön


Diziye sağdan sola işler ve sonraki bilgileri yakalar.

Kullanım Alanı

Makine çevirisi, konuşma tanıma ve duygu analizi gibi bağlamın önemli olduğu görevler.



İki Yönlü Tekrarlayan Sinir Ağı (Bi-RNN) Nasıl Çalışır?



Temel Prensipte: Bi-RNN'ler, her zaman adımında hem geçmişteki hem de gelecekteki bağlamı kullanarak daha doğru sonuçlar elde ettiler.


BiRNN'nin Önemli Kısıtlaması

BiRNN yalnızca **geçmiş** ve **gelecek** verisi tamamen hazır olduğunda kullanılabilir.

Bu yüzden kitap çevirisi gibi, tüm dizinin önceden bilindiği görevlerde uygundur.

Canlı uygulamalarda ise kullanılamaz: ses tanıma ve anlık borsa tahmini gibi senaryolarda **gelecekteki veri** henüz mevcut değildir.

İki Yönlü RNN (BiRNN)



Canlı Senaryolar İçin Uygun Değildir



Deep RNN (Derin RNN)



Katmanlı Soyutlama

Deep RNN; birden fazla RNN, LSTM veya GRU katmanının üst üste istiflenmesiyle oluşturulur. Her katman verinin farklı bir soyutlama seviyesini öğrenir:

- **Alt katmanlar:** Kısa vadeli ve temel örüntüler (küçük dalgalanmalar)
- **Üst katmanlar:** Uzun vadeli ve karmaşık kalıplar

⚠ Katman sayısı arttıkça model kapasitesi büyür; ancak eğitim süresi uzar ve daha fazla hesaplama gücü gerekir.

Deep RNN'nin Pratik Sınırlaması


Katmanları üst üste eklemek modelin kapasitesini artırır.

Ancak bu yapı, **overfitting** riskini de yükseltir.

Bu yüzden pratikte genellikle **2-3 katmanlı** derin RNN'ler tercih edilir.

Görüntü işlemedeki **100 katmanlı** modellere kıyasla, RNN'lerde daha dikkatli bir denge gerekir.

DERİN RNN PERFORMANSI PERFORMANS TAKASI



RNN ve LSTM Karşılaştırma Tablosu

Tablo; mimari yapı, hafıza süresi, gradyan problemi, hesaplama maliyeti, veri ilişkileri ve yaygın kullanım açısından RNN ile LSTM arasındaki temel farkları özetlemektedir. **Basit ve hızlı çözümler için RNN, uzun vadeli bağımlılıklar için LSTM** tercih edilmelidir.

Özellik	RNN (Recurrent Neural Network)	LSTM (Long Short-Term Memory)
Mimari Yapısı	Oldukça basittir; genellikle tek tanh katmanından oluşur.	Karmaşıktır; bilgi akışını kontrol eden 3 farklı kapı (gate) düzeneği içerir.
Hafıza Süresi	Sadece kısa süreli hafızaya sahiptir; eski veriler çabuk unutulur.	Uzun süreli hafızaya sahiptir; önemli bilgileri daha uzun süre tutabilir.
Gradyan Problemi	"Kaybolan Gradyan" (Vanishing Gradient) sorunu nedeniyle uzun dizilerde eğitilmesi zordur.	Çok katı yapısı sayesinde gradyan akışını daha iyi korur ve uzun dizilerde daha başarılı eğitim sağlar.
Hesaplama Maliyeti	Daha az parametre (çerçeki) içerdiği için daha az güç tüketir.	Daha fazla parametre ve işlem gerektirdiği için daha yüksek hesaplama maliyeti vardır.
Veri İlişkileri	Yakın geçmişteki veriler arasındaki uzun vadeli ilişkileri yakalamakta başarısızdır.	Veriler arasındaki uzun vadeli ilişkileri yakalamakta daha başarılıdır; karmaşık bağımlılıkları öğrenebilir.
Yaygın Kullanım	Yakın geçmişteki veriler ve basit ilişkiler için kullanılır; cumle yapıları çoğunlukla yoktur.	Veriler arasındaki uzun vadeli ilişkileri öğrenmek için tercih edilir; borsa tahmini ve dil işleme gibi alanlarda kullanılır.



ÖZET

Gelişmiş RNN Mimarileri

RNN'in sınırlarını aşan bu mimariler, farklı sıralı veri problemleri için daha güçlü çözümler sunar.



GRU

Az parametreyle hızlı ve etkili öğrenme; uzun bağımlılıkları iyi yönetir.



Bidirectional RNN

Geçmiş ve gelecek bağlamını birlikte kullanır.



LSTM

Hücre durumu ve kapılarla uzun süreli bilgiyi korur.



Deep RNN

Birden çok katmanla daha derin örüntüler öğrenir.

Her mimarinin kendi avantajları vardır; seçim, probleminizin doğasına bağlıdır.

Dinlediğiniz için teşekkür ederim

İlginiz ve zamanınız için teşekkürler.

