

WORD EMBEDDINGS

SUNUM 14

HAZIRLAYAN: ALİ TURAN ÇETİN 2222705028

Word embeddings nedir, niçin kullanılır?

- Kelimelerin, sayısal vektörlerle yüksek boyutlu bir uzayda birbirleriyle olan ilişkilerini görselleştirmek ve analiz etmektir.
- Metin analizi, dil modelleme ve bilgi alma gibi birçok alanda makine öğrenme algoritmalarının daha etkili bir şekilde çalışmasını sağlar.

Word Embeddings Teknikleri

- One Hot Encoding
- Word2Vec
- GloVe
- Cosine Similarity
- Contextual Embeddings

One-Hot Encoding

Her kelimeye bir index numarası verilir ve her kelime sözlük boyutu kadar uzunlukta bir vektör ile temsil edilir. Bu vektörlerde sadece ele aldığımız kelimelerin kendi dizinine denk gelen yerler '1' , diğerleri '0' değerini alır.

Örnek:

- Köpek su içti
- Maymun muz yedi
- Köpek muz yedi



[Köpek, su, içti, maymun, muz, yedi]



Sözlük boyutu (v)=6

Köpek [1,0,0,0,0,0]

Su [0,1,0,0,0,0]

Muz [0,0,0,0,1,0]

One-Hot vs Modern Embedding

One-Hot Yapısı

- Seyrek bir yapıdadır.
- Vektörlerin büyük çoğunluğu sıfırlardan oluşur.
- Anlamsal yakınlık yoktur.

Modern Embedding

- Yoğun bir yapıdadır.
- Boyut sayısı sabittir.(100, 300 veya 768)
- Sınırlı sayıdaki bu boyutun her biri '0' değil anlam taşıyan ondalıklı sayılarla doludur.
- Anlamsal yakınlık vardır.

Örnek: Güneş, Yıldız, Tornavida

Güneş [1,0,0]
Yıldız [0,1,0]
Tornavida [0,0,1]



Bu vektörleri koordinat sistemine yerleştirdiğimizde hepsinin birbiriyle arasındaki açı 90 derece yani diktir. Aralarında hiçbir benzerlik yoktur.

One-hot encoding yapısı

	UZAY	ALET
Güneş	[0.98 , -0.92]	
Yıldız	[0.94 , -0.88]	
Tornavida	[-0.95 , 0.96]	



Modern modeller devasa metin yığınlarını okur. Modelin tek kuralı "Aynı cümlelerde birbirine yakın duran kelimelerin vektörlerini (sayısal değerlerini) birbirine yaklaştır." dır.

Modern embedding yapısı

Word2Vec


Kelimeleri yanındaki komşularına bakarak tanıyan algoritmalarıdır.

- CBOW (Continuous Bag of Words)
- Skip-Gram

CBOW (Continuous Bag of Words)

Etraftaki (komşu) kelimelere bakarak ortadaki kelimeyi tahmin eder.

Ali sabahları^(sıcak) kahve içer.




Pencere boyutu: 2
İki sağa iki sola bak

t konumundaki merkez kelimenin solundaki ve sağındaki kelimeleri input alıp yapay sinir ağlarıyla **vektörel ortalamasını** alır ve output olarak 'sıcak' kelimesini tahmin eder

SKIP-GRAM

Ortadaki kelimeye bakarak etraftaki (komşu) kelimeleri tahmin eder.

... **sıcak**



Pencere boyutu:2

İki sağdaki iki soldaki kelimeyi tahmin et

t konumundaki merkez kelimeyi input olarak alır
yapay sinir ağlarıyla bu kelimenin bağlamında geçme
ihtimali en yüksek olan komşu kelimeleri output olarak
tahmin eder

GloVe (Global Vektors for Word Representation)


- GloVe kelime tahmin ederken Word2Vec gibi cümledeki o anki pencereye değil, tüm corpuslara bakar.
- Kelimelerin sadece yan yana gelme olasılıklarını değil bu olasılıkları da kendi arasında kıyaslar.

Kelimeler Arasındaki Anlamsal Mesafeleri Ölçen Model

Algoritma cinsiyet veya unvan gibi kavramları kural olarak ezberlemez. Uzayda matematiksel bir yön ve mesafe olarak kendisi keşfeder.

Yapay zeka, kelimelerle tıpkı sayılar gibi toplama-çıkarma yapabilir.

$$V(\text{Kral}) - V(\text{Adam}) + V(\text{Kadın}) = V(\text{Kraliçe})$$



COSINE SIMILARITY

Sayısal vektörler halinde uzay alanına yerleştirdiğimiz kelimelerin birbiri arasındaki ilişkileri kosinüs benzerliğiyle hesaplanır.

Cosinus değeri -1 ile 1 arasındadır.

- $\text{Cos}(0)=1$ değeri  İki vektör üst üste (çakışık)tır.
Kelimeler tamamen aynıdır.
- $\text{Cos}(90)=0$ değeri  İki vektör birbirine diktir.
Aralarında hiçbir benzerlik yoktur.
- $\text{Cos}(180)=-1$ değeri  İki vektör birbirine zıttır.
Anlamca tamamen karşıt kutuptadır.


$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$$

İki vektörün skaler çarpımlarının, uzunluklarının çarpımına oranı

CONSTEXUAL EMBEDDINGS

Constexual Embeddings'te kelimelerin önceden belirli bir kimliği yoktur. Vektörler kelime cümleye girdikten sonra kimlik kazanır. Yani elde edilen vektörlerin sayısal değeri kelimenin kendisine değil, cümledeki kullanımına aittir.

Örnek: (eşsesli kelimeler)



- Word2vec ve GloVe bu üç anlamı birbirinden ayıramaz, metinlerdeki kullanımların ortalamasını alır ve ortaya bulanık bir vektör ortaya çıkar
- Constexual Embedding, cümleyi bir bütün olarak okuduğu için 'Denizde yüz', 'Güzel yüz' gibi farklı vektörler atar.

KAYNAKÇA

- <https://nlp.stanford.edu>
- <https://www.geeksforgeeks.org>
- <https://www-lyzr-ai.translate.goog/glossaries/contextual-embeddings>
- https://www.youtube.com/@Sadievrenseker_BK/featured