

1. Giriş

1.1. Konunun Tanımı

Büyük Dil Modelleri, yani **LLM (Large Language Models)**, çok büyük miktarda metin verisiyle eğitilen ve insan dilini anlayıp metin üretebilen yapay zekâ modelleridir.

Bu modeller; soru cevaplama, metin özetleme, çeviri yapma, kod yazma, metin sınıflandırma ve sohbet botları gibi birçok alanda kullanılmaktadır.

Bu raporda LLM kavramı, pretraining ve fine-tuning süreçleri, prompt engineering, Hugging Face kullanımı, LoRA yöntemi ve inference teknikleri açıklanmıştır. Ayrıca prompt engineering mantığını göstermek için küçük ölçekli bir mini proje yapılmıştır.

1.2. Konunun Neden Önemli Olduğu

Günümüzde yapay zekâ sistemleri birçok alanda kullanılmaktadır. Özellikle büyük dil modelleri, insanların bilgiye ulaşmasını, metin üretmesini ve karmaşık problemleri daha kolay çözmesini sağlamaktadır.

LLM'lerin doğru ve etkili kullanılması için yalnızca modelin kendisini bilmek yeterli değildir. Aynı zamanda modele nasıl komut verileceği, modelin nasıl eğitildiği ve cevap üretirken hangi yöntemleri kullandığı da bilinmelidir.

Bu nedenle **prompt engineering, fine-tuning, LoRA ve inference teknikleri** gibi kavramlar LLM kullanımında önemli bir yere sahiptir.

2. Temel Kavramlar

2.1. LLM Nedir?

LLM, büyük miktarda metin verisiyle eğitilmiş yapay zekâ dil modelidir. Bu modeller kelimeler ve cümleler arasındaki ilişkileri öğrenerek verilen girdiye uygun cevap üretir.

LLM'ler insan gibi bilinçli değildir. Cevap üretirken daha önce öğrendiği dil kalıplarına ve verilen bağlama göre en uygun kelime veya cümleyi tahmin eder.

2.2. Pretraining Nedir?

Pretraining, modelin ilk ve genel eğitim aşamasıdır. Bu aşamada model çok büyük veri kümeleriyle eğitilir.

Model bu süreçte:

- Dil yapısını öğrenir.
- Kelimeler arasındaki ilişkileri öğrenir.
- Genel bilgi kazanır.
- Temel cevap üretme yeteneği kazanır.

Pretraining, modelin genel bilgi temelini oluşturur.

2.3. Fine-tuning Nedir?

Fine-tuning, önceden eğitilmiş bir modelin belirli bir alan veya görev için özel verilerle yeniden eğitilmesidir.

Örneğin genel bilgiye sahip bir LLM, sağlık, hukuk, eğitim veya müşteri hizmetleri verileriyle fine-tuning yapılarak o alanda daha başarılı hale getirilebilir.

Özellik	Pretraining	Fine-tuning
Amaç	Modele genel bilgi kazandırmak	Modeli özel bir göreve uyarlamak
Veri miktarı	Çok büyük veri	Daha küçük ve özel veri
Kapsam	Genel	Belirli alan veya görev
Sonuç	Temel model	Uzmanlaşmış model

2.5. Prompt Engineering Nedir?

Prompt Engineering, yapay zekâ modeline verilen komutun doğru, açık ve etkili şekilde hazırlanmasıdır.

Amaç, modelden daha doğru, net ve istenilen formatta cevap almaktır.

İyi bir prompt genellikle şu bileşenlerden oluşur:

- **Context (Bağlam):** Konunun ne olduğunu belirtir.
- **Task (Görev):** Modelin ne yapacağını açıklar.
- **Instruction (Talimat):** Cevabın nasıl verilmesi gerektiğini belirtir.
- **Clarify (Açıklama):** Ek bilgi sağlar.
- **Refine (İyileştirme):** Daha iyi sonuç için promptu geliştirir.

2.6. Hugging Face Nedir?

Hugging Face, yapay zekâ modellerinin paylaşılabildiği ve kullanılabildiği bir platformdur.

Bu platform üzerinden:

- Hazır yapay zekâ modelleri bulunabilir.
- Modeller indirilebilir.
- Veri setlerine ulaşılabilir.
- Modeller Python ile projelere entegre edilebilir.
- Kendi modelimiz paylaşılabılır.

Hugging Face, yapay zekâ modelleri için bir model kütüphanesi gibi düşünülebilir.

2.7. Fine-tuning ve LoRA

LoRA (Low-Rank Adaptation), büyük modelleri tamamen yeniden eğitmeden küçük ek katmanlar üzerinden özelleştirme yöntemidir.

LoRA sayesinde:

- Daha az bellek kullanılır.
- Eğitim maliyeti azalır.
- Eğitim süresi kısalmır.
- Büyük modeller daha verimli şekilde özel görevlere uyarlanabilir.

LoRA, özellikle büyük dil modellerinde fine-tuning maliyetini azaltmak için kullanılır.

2.8. Inference Nedir?

Inference, eğitilmiş modelin yeni bir girdiye cevap üretme sürecidir.

Model bu aşamada artık eğitim yapmaz. Öğrendiği bilgileri kullanarak verilen soruya veya metne uygun çıktı üretir.

2.9. Yaygın Inference Teknikleri

Temperature

Temperature, modelin cevap üretirken ne kadar yaratıcı veya rastgele davranacağını belirler.

Düşük temperature değeri daha tutarlı ve tahmin edilebilir cevaplar üretir.

Yüksek temperature değeri ise daha yaratıcı ve çeşitli cevaplar üretir.

Top-k Sampling

Top-k sampling yönteminde model, sadece en yüksek olasılığa sahip belirli sayıdaki kelime arasından seçim yapar.

Örneğin $k = 5$ ise model yalnızca en olası 5 kelimeyi değerlendirir.

Top-p Sampling

Top-p sampling yönteminde model, toplam olasılığı belirli bir p değerine ulaşan kelime grubundan seçim yapar.

Örneğin $p = 0.9$ ise model toplam olasılığı %90'a ulaşan kelime adayları arasından seçim yapar.

3. Yöntem / Model Açıklaması

3.1. LLM'lerin Genel Çalışma Mantığı

Büyük dil modelleri, verilen metni parçalara ayırarak işler. Bu parçalara **token** denir. Model, tokenlar arasındaki ilişkileri öğrenir ve bir sonraki en uygun tokenı tahmin ederek cevap üretir.

Genel çalışma akışı şu şekildedir:

Veri → Eğitim → Dil Kalıplarını Öğrenme → Kullanıcı Sorusu → Cevap Üretme

3.2. Eğitim Süreci

LLM’lerde eğitim süreci genellikle iki temel aşamada incelenebilir:

1. **Pretraining:** Modelin büyük ve genel veriyle ilk eğitimi yapılır.
2. **Fine-tuning:** Model özel bir alan veya göreve göre yeniden ayarlanır.

Bu sayede model hem genel dil bilgisini öğrenir hem de belirli görevlerde daha başarılı hale gelir.

3.3. Prompt Engineering Süreci

Prompt engineering sürecinde amaç, modele verilen komutu daha anlaşılır ve yönlendirici hale getirmektir.

İyi bir prompt hazırlama süreci şu şekilde gösterilebilir:

Bağlam → Görev → Talimat → Açıklama → İyileştirme

Örnek:

Kötü prompt:

“LLM anlat.”

İyi prompt:

“LLM nedir? Lise öğrencisinin anlayacağı şekilde kısa, sade ve örnekli açıkla.”

Bu örnekte ikinci prompt daha açık olduğu için modelden daha kaliteli cevap alınabilir.

3.4. Inference Süreci

Inference sırasında model, verilen girdiyi analiz eder ve en uygun cevabı üretir. Cevap üretirken kelime seçiminde farklı teknikler kullanılabilir.

Bu teknikler modelin cevabının:

- Daha yaratıcı,
- Daha tutarlı,
- Daha kontrollü,
- Daha çeşitli

olmasını sağlayabilir.

4. Uygulama Alanları

4.1. Eğitim

LLM’ler öğrencilere konu anlatımı, soru çözümü, özet çıkarma ve çalışma planı hazırlama gibi alanlarda yardımcı olabilir.

4.2. Müşteri Hizmetleri

Firmalar, müşteri sorularını hızlı cevaplamak için LLM tabanlı sohbet botları kullanabilir.

4.3. Sağlık ve Hukuk

Özel alan verileriyle fine-tuning yapılan modeller, sağlık veya hukuk alanında destekleyici bilgi sistemleri olarak kullanılabilir.

4.4. Yazılım ve Kodlama

LLM'ler kod yazma, hata bulma, kod açıklama ve algoritma geliştirme gibi görevlerde kullanılabilir.

4.5. Metin İşleme

Metin özetleme, çeviri, duygu analizi, metin sınıflandırma ve içerik üretme işlemlerinde kullanılabilir.

4.6. İçerik Üretimi

Blog yazısı, sosyal medya metni, reklam metni, rapor ve sunum içerikleri oluşturmak için kullanılabilir.

5. Yapılan Mini Proje Açıklaması

5.1. Projenin Amacı

Bu mini projede LLM ve prompt engineering kavramı küçük ölçekli bir deney üzerinden gösterilmiştir. Tam ölçekli bir LLM eğitmek yüksek donanım ve büyük veri gerektirdiği için projede LLM mantığını temsil eden küçük bir metin sınıflandırma modeli kurulmuştur. Model Türkçe yorumları **olumlu**, **olumsuz** ve **nötr** olarak sınıflandırmıştır. Daha sonra aynı metinler farklı prompt biçimleriyle modele verilerek prompt yapısının sonuçlara etkisi incelenmiştir.

5.2. Kullanılan Veri Seti

Projede küçük bir Türkçe duygu analizi veri seti kullanılmıştır.

Veri setinde iki sütun bulunmaktadır:

Sütun	Açıklama
-------	----------

text	Yorum metni
------	-------------

label	Yorumun sınıfı
-------	----------------

Veri setinde üç sınıf vardır:

- olumlu
- olumsuz
- nötr

Toplam veri sayısı 60'tır.

Sınıf Örnek Sayısı

olumlu 20

olumsuz 20

nötr 20

5.3. Kullanılan Kütüphaneler

Projede kullanılan başlıca Python kütüphaneleri şunlardır:

- **pandas:** Veri setini tablo olarak yönetmek için
- **numpy:** Sayısal işlemler için
- **matplotlib:** Grafik çizmek için
- **scikit-learn:** Model kurma, eğitim ve değerlendirme işlemleri için

5.4. Kullanılan Yöntem

Mini projede klasik bir makine öğrenmesi modeli kullanılmıştır.

Kullanılan yöntem:

1. Veri seti oluşturuldu.
2. Veri CSV formatında kaydedildi.
3. Veri tekrar okunarak yüklendi.
4. Metinler ön işlemden geçirildi.
5. Eğitim ve test verisi ayrıldı.
6. TF-IDF ile metinler sayısal verilere dönüştürüldü.
7. Logistic Regression modeli kuruldu.
8. Model eğitildi.
9. Model test edildi.
10. Farklı prompt türleriyle deney yapıldı.

5.5. Veri Ön İşleme

Veri ön işleme aşamasında metinler modelin anlayabileceği hale getirilmiştir.

Yapılan işlemler:

- Tüm harfler küçük harfe çevrildi.
- Noktalama işaretleri temizlendi.

- Fazla boşluklar kaldırıldı.
- Bazı gereksiz kelimeler çıkarıldı.
- Temizlenmiş metinler yeni bir sütunda saklandı.

5.6. Model Kurulumu

Model iki temel parçadan oluşmaktadır:

1. **TF-IDF Vectorizer:** Metinleri sayısal özelliklere dönüştürür.
2. **Logistic Regression:** Sayısal özelliklere göre sınıflandırma yapar.

Bu model tam bir LLM değildir. Ancak metinlerden anlam çıkarma ve sınıflandırma mantığını küçük ölçekte göstermek için uygundur.

5.7. Eğitim ve Test Süreci

Veri seti eğitim ve test olarak ikiye ayrılmıştır.

Veri Bölümü Örnek Sayısı

Eğitim verisi 42

Test verisi 18

Model, eğitim verileriyle eğitilmiş ve test verileriyle değerlendirilmiştir.

Kullanılan prompt türleri:

Prompt Türü	Açıklama
-------------	----------

Basit Prompt	Sadece sınıflandırma isteği verir.
--------------	------------------------------------

Uzman Rol Promptu	Modele duygu analizi uzmanı rolü verir.
-------------------	---

Few-shot Prompt	Modele önce birkaç örnek gösterir.
-----------------	------------------------------------

Zayıf Prompt	Eksik ve belirsiz yönlendirme içerir.
--------------	---------------------------------------

Amaç, prompt biçiminin model tahminlerini değiştirip değiştirmediğini gözlemlemektir.

5.9. Elde Edilen Sonuçlar

Modelin test doğruluk oranı:

Test doğruluk oranı: 0.333

Bu sonuç yaklaşık olarak **%33,3 doğruluk** anlamına gelmektedir.

Sınıflandırma raporundan bazı sonuçlar:

Sınıf Precision Recall F1-score

nötr	0.62	0.83	0.71
olumlu	0.25	0.17	0.20
olumsuz	0.00	0.00	0.00

Bu sonuçlara göre model özellikle nötr sınıfında daha başarılı olurken, olumsuz sınıfında düşük performans göstermiştir.

5.10. Prompt Sonuçlarının Yorumlanması

Prompt engineering deneyinde farklı prompt türleri denenmiştir. Ancak kullanılan model klasik bir metin sınıflandırma modeli olduğu ve veri seti küçük olduğu için prompt türleri arasında büyük bir başarı farkı oluşmamıştır.

Buna rağmen deney, prompt yapısının modele verilen girdiyi değiştirdiğini ve özellikle büyük dil modellerinde daha etkili sonuçlar oluşturabileceğini göstermektedir.

5.11. Program Çıktıları

Projede elde edilen temel program çıktıları şunlardır:

Kütüphaneler başarıyla yüklendi.

Veri seti başarıyla yüklendi.

Veri boyutu: (60, 2)

Veri ön işleme tamamlandı.

Eğitim veri sayısı: 42

Test veri sayısı: 18

Model başarıyla kuruldu.

Model eğitimi tamamlandı.

Modelin öğrendiği sınıflar: ['nötr', 'olumlu', 'olumsuz']

Test doğruluk oranı: 0.333

6. Sonuç

6.1. Genel Değerlendirme

Bu raporda Büyük Dil Modelleri ve prompt engineering konusu temel düzeyde incelenmiştir. LLM'lerin nasıl çalıştığı, pretraining ve fine-tuning süreçleri, Hugging Face platformu, LoRA yöntemi ve inference teknikleri açıklanmıştır.

Yapılan mini projede ise küçük bir Türkçe metin sınıflandırma modeli kurulmuş ve farklı prompt türlerinin sonuçlara etkisi gözlemlenmiştir.

Modelin doğruluk oranı düşük çıkmıştır. Bunun temel nedeni veri setinin küçük olması ve kullanılan modelin tam ölçekli bir LLM olmamasıdır. Ancak proje, prompt engineering mantığını göstermek açısından başarılı bir örnek olmuştur.

6.2. Öğrenilenler

Bu çalışma sonucunda:

- LLM’lerin büyük metin verileriyle eğitildiği öğrenilmiştir.
- Pretraining ve fine-tuning arasındaki fark anlaşılmıştır.
- Prompt engineering ile modelden daha iyi cevap alınabileceği görülmüştür.
- Hugging Face’in hazır modelleri kullanmak için önemli bir platform olduğu öğrenilmiştir.
- LoRA yönteminin büyük modelleri daha az maliyetle özelleştirmeye yaradığı anlaşılmıştır.
- Inference tekniklerinin modelin cevap üretme şeklini etkilediği görülmüştür.
- Mini proje ile metin sınıflandırma süreci uygulamalı olarak gösterilmiştir.

Sonuç olarak, Büyük Dil Modelleri günümüzde yapay zekânın en önemli alanlarından biridir. Bu modellerin etkili kullanılabilmesi için yalnızca modelin ne olduğu değil, nasıl eğitildiği, nasıl yönlendirildiği ve nasıl çıktı ürettiği de bilinmelidir.

Prompt engineering, fine-tuning, LoRA ve inference teknikleri LLM kullanımında daha doğru, verimli ve kontrollü sonuçlar elde etmeyi sağlar.

KAYNAKÇA

[1] Y. Yao, J. Duan, K. Xu, Y. Cai, Z. Sun, and Y. Zhang, “A survey on large language model (LLM) security and privacy: The good, the bad, and the ugly,” *High-Confidence Computing*, vol. 4, no. 2, p. 100211, 2024.

[2] E. C. Too, L. Yujian, S. Njuki, and L. Yingchun, “A comparative study of fine-tuning deep learning models for plant disease identification,” *Computers and Electronics in Agriculture*, vol. 161, pp. 272–279, 2019.

[3] Q. Ye, M. Ahmed, R. Pryzant, and F. Khani, “Prompt engineering a prompt engineer,” in *Findings of the Association for Computational Linguistics: ACL 2024*, Aug. 2024, pp. 355–385.

[4] F. Avcioğlu, “B y k dil modelleri ile metinlerde duygu analizi,” 2026.

[5] R. Shuttleworth, J. Andreas, A. Torralba, and P. Sharma, “Lora vs full fine-tuning: An illusion of equivalence,” *Advances in Neural Information Processing Systems*, vol. 38, pp. 174627–174662, 2026.