



ISPARTA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

ELEKTTRİK ELEKTRONİK MÜHENDİSLİĞİ

RAG NEDİR SÜREÇLERİ NELERDİR?

MAKİNE ÖĞRENMESİNE GİRİŞ

HAZIRLAYAN

Veysel ASLANTAŞ - 2322705046

Ders Sorumlusu: Ali ŞENTÜRK

1. Giriş

Konunun Tanımı:

RAG (Retrieval-Augmented Generation - Geri Getirmeyle Zenginleştirilmiş Üretim), büyük dil modellerinin (LLM) bilgi üretme süreçlerini, dışarıdan sağlanan güvenilir bilgi kaynaklarıyla (vektör veritabanları) destekleyen melez bir yapay zeka mimarisidir. Bu yaklaşım, modelin sadece kendi eğitim verilerine dayanarak cevap üretmesi yerine, spesifik bir dokümandan veya veritabanından en ilgili bilgiyi "geri getirerek" (retrieval) cevabını bu bilgi üzerine inşa etmesini (generation) sağlar.

Konunun Neden Önemli Olduğu:

Günümüzde yapay zeka modellerinin en büyük handikaplarından biri "halüsinasyon" (gerçekte olmayan bilgileri doğruymuş gibi sunma) problemidir. Ayrıca modellerin kapalı yapısı, güncel veya kuruma özel (gizli) bilgilere erişimlerini engeller. RAG mimarisi;

- Modelin halüsinasyon görmesini büyük ölçüde engeller.
- Veriler değiştiğinde modelin yüksek maliyetlerle yeniden eğitilmesi (Fine-Tuning) zorunluluğunu ortadan kaldırır.
- "Açık kitap sınavı" mantığıyla çalıştığı için bilginin kaynağının doğrulanabilmesini (traceability) sağlar.

Bu nedenlerle RAG, modern yapay zeka uygulamalarında endüstri standardı haline gelmiştir.

2. Temel Kavramlar

Büyük Dil Modelleri (LLM): İnsan dilini anlamak ve üretmek üzere devasa metin verileriyle eğitilmiş derin öğrenme modelleridir.

Halüsinasyon (Hallucination): Yapay zeka modelinin, bilmediği bir konuda ikna edici fakat tamamen yanlış veya uydurma cevaplar üretmesi durumudur.

Vektörel Gömme (Embedding): Metinlerin, kelimelerin veya cümlelerin bilgisayarlar tarafından işlenebilmesi için n-boyutlu sayısal dizilere (vektörlere) dönüştürülmesi işlemidir. Anlamca birbirine yakın olan metinlerin vektörleri, uzayda birbirine yakın konumlanır.

Vektör Veritabanı (Vector Database): Geleneksel veritabanlarından farklı olarak, verileri vektör formatında saklayan ve "anlamsal benzerlik" (semantic search) araması yapabilen sistemlerdir.

Kosinüs Benzerliği (Cosine Similarity) Formülü:

Vektör uzayındaki iki metnin anlamsal olarak ne kadar benzer olduğunu ölçmek için kullanılan en yaygın matematiksel yöntemdir. İki vektör arasındaki açının kosinüsünü hesaplar. Değer 1'e yaklaştıkça anlamsal benzerlik artar.

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

(Burada A ve B, karşılaştırılan iki cümlelerin sayısal vektör dizilerini temsil eder.)

3. Yöntem / Model Açıklaması

Algoritma ve Modelin Çalışma Mantığı: RAG mimarisi temel olarak üç aşamada çalışır. Modelin çalışma mantığı geleneksel Fine-Tuning işleminden tamamen farklıdır. Bilgiyi modelin parametrelerine kazımak yerine, bilgi dışarıdan bir okuma parçası olarak modele sunulur.

Adım Adım Açıklama:

- 1. Veri Hazırlama ve Embedding:** Kuruma ait dokümanlar küçük parçalara (chunk) ayrılır ve bir Embedding modeli ile sayısal vektörlere dönüştürülüp Vektör Veritabanına kaydedilir.
- 2. Retrieval (Geri Getirme):** Kullanıcı bir soru sorduğunda, bu soru da anında vektöre çevrilir. Veritabanında Kosinüs Benzerliği (Cosine Similarity) formülü kullanılarak soruya en yakın (en benzer) doküman parçaları bulunur ve getirilir.
- 3. Generation (Üretim):** Bulunan bu bağlamsal bilgi, kullanıcının sorusuyla birleştirilerek Büyük Dil Modeline (LLM) iletilir. LLM, sadece bu sağlanan bilgiyi kullanarak nihai cevabı üretir.

4. Uygulama Alanları

RAG mimarisinin günümüzde kullanıldığı başlıca gerçek dünya örnekleri şunlardır:

- **Kurumsal Müşteri Hizmetleri Botları:** Şirketlerin kendi iade koşulları, ürün katalogları veya kullanım kılavuzları üzerinden sıfır hata ile müşterilere cevap veren asistanlar.
- **Hukuk ve Mevzuat Analizi:** Binlerce sayfalık kanun metinleri ve içtihatlar arasından, avukatların sorduğu spesifik bir davanın emsallerini saniyeler içinde bulan sistemler.
- **Akademik ve Tıbbi Araştırmalar:** Doktorların veya araştırmacıların, en güncel tıbbi makaleler havuzunda anlamsal arama yaparak spesifik bir hastalığın güncel tedavi yöntemlerini özetletmesi.

5. Yapılan Mini Proje Açıklaması

Yapılan Çalışmanın Açıklaması: Bu projede, RAG mimarisinin en kritik aşaması olan "Retrieval" (Geri getirme) adımının temelini oluşturan **Embedding (Vektörel Gömme) ve Anlamsal Benzerlik** kavramları uygulamalı olarak test edilmiştir. Modelin, içinde ortak kelime geçmese bile aynı konudan bahseden cümleleri matematiksel olarak nasıl eşleştirdiği incelenmiştir.

Kullanılan Veri Seti: Test için 4 adet spesifik cümle oluşturulmuştur. 1. ve 2. cümleler farklı kelimeler barındırmasına rağmen aynı yazılım disiplini (bit düzeyinde işlemler) temsil ederken; 3. ve 4. cümleler sırasıyla otomotiv ve elektrik disiplinlerinden seçilerek alakasız verileri (noise) oluşturmuştur.

1. *"C programlamada spesifik bir biti 1 yapmak (Set) için bit masking teknikleri kullanılır."*
2. *"Mikrodenetleyici kodlarında istediğimiz bitin durumunu değiştirmek amacıyla operatörler tercih edilir."*
3. *"Polo classic araçlarda düz 1.6 motor seçenekleri piyasada çok tutuluyor."*
4. *"Paralel bağlı kollardaki gerilim değerleri her zaman birbirine eşittir."*

Kullanılan Yöntem ve Araçlar:

- **Embedding Modeli:** HuggingFace altyapısından çok dilli paraphrase-multilingual-MiniLM-L12-v2 modeli kullanılmıştır.
- **Benzerlik Ölçümü:** Scikit-Learn kütüphanesi ile cosine_similarity kullanılmıştır.
- **Görselleştirme:** Seaborn ve Matplotlib kullanılarak elde edilen matematiksel matris, Isı Haritası (Heatmap) formatına dönüştürülmüştür.

Kullanılan Kodlamalar: Proje Python dilinde, Jupyter Notebook (.ipynb) formatında yazılmıştır. Temel vektörizasyon kod bloğu aşağıdadır:

```
Python
from sentence_transformers import SentenceTransformer
from sklearn.metrics.pairwise import cosine_similarity
import seaborn as sns
import matplotlib.pyplot as plt

# Modelin yüklenmesi ve verilerin vektörlere
dönüştürülmesi
model = SentenceTransformer('paraphrase-multilingual-
MiniLM-L12-v2')
vektorler = model.encode(cumleler)

# Kosinüs Benzerliğinin hesaplanması ve ısı haritasının
çizdirilmesi

benzerlik_matrisi = cosine_similarity(vektorler)
```

Elde Edilen Sonuçlar ve Program Çıktıları: Geliştirilen kodun çalıştırılması sonucunda, cümlelerin uzaydaki matematiksel yakınlıklarını gösteren bir Isı Haritası elde edilmiştir. Sonuçlar incelendiğinde; anlamsal olarak yazılım konusunu işleyen Cümle 1 ve Cümle 2 arasındaki benzerlik skoru yüksek (0.40) çıkarken, otomotiv ve elektrik gibi alakasız cümleler ile olan benzerlik skorları 0'a yakın (0.12, 0.13, -0.05) çıkmıştır. Bu çıktı, RAG sistemlerinin kelime tabanlı değil, tamamen "anlam tabanlı" matematiksel bir arama yaptığını kanıtlamaktadır.

6. Sonuç

Genel Değerlendirme: RAG mimarisi, yapay zekanın sadece bir kelime tahmin motoru olmaktan çıkıp, doğrulanabilir bir bilgi asistanına dönüşmesini sağlayan devrimsel bir yaklaşımdır. Yapılan mini projede elde edilen sayısal veriler, bu mimarinin temel taşı olan Vektörel Gömme (Embedding) teknolojisinin gücünü kanıtlamıştır.

Öğrenilenler: Bu çalışma sonucunda; bilgisayarların insan dilini sayılar (vektörler) üzerinden okuduğu, kelimeler değişse bile cümlelerin anlamsal koordinatlarının aynı bölgede kaldığı ve Fine-Tuning gibi yüksek maliyetli eğitimler yerine RAG kullanarak çok daha esnek, ucuz ve güvenilir yapay zeka uygulamaları geliştirilebileceği uygulamalı olarak öğrenilmiştir.

7. Kaynakça

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459-9474, 2020. [2] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, Hong Kong, China, 2019, pp. 3982-3992. [3] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011. [4] J. Devlin, M. W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, 2019.