

RAG (Retrieval-Augmented Generation) ile Dinamik Yapay Zeka Sistemleri

14.Hafta Makine Öğrenmesi Sunumu

Öğrenci adı: Veysel Aslantaş

Öğrenci No: 2322705046

İsparta Uygulamaları Bilimler Üniversitesi

Büyük Dil Modellerinin (LLM) Sınırları



- Eğitim verisi tarihinden sonraki güncel olayları bilmezler.
- Özel veya kurumsal verilere (şirket belgeleri vb.) erişimleri yoktur.
- Cevabı bilmediklerinde mantıklı görünen yalanlar uydurma (**Halüsinasyon**) eğilimindedirler.

Rag Mimarisi nedir?

- Yapay zekanın ezberden uydurmak yerine, kendi belgelerinizi (PDF vb.) okuyarak **kanıta dayalı ve kesin** cevaplar üretmesidir."


RAG = Önce bilgi ara, sonra cevap üret.



Embedding (Kelimeleri Matematikçe Çevirmek)

- Bilgisayarlar kelimeleri değil, yüksek boyutlu matrisleri ve sayıları anlar.
- **Embedding (Gömme İşlemi):** Metinlerin, uzaydaki matematiksel koordinatlara (vektörlere) dönüştürülmesi.


Kelimeleri, cümleleri veya verileri sayılardan oluşan vektörlere dönüştürme işlemidir.



Benzer anlamlara sahip kelimeler, vektör uzayında birbirine yakın konumlanır. Bu sayede bilgisayarlar, anlam ilişkilerini matematiksel olarak anlayabilir.


Vector Database

- Embedding'den oluşan vektör verilerini saklayan ve benzer verileri bulan veritabanıdır bi nevi depo gibidir



Retrieval Süreci

- Vector database içindeki en ilgili verilerin bulunup geri getirilme sürecidir.



Fine-Tuning

- Mevcut bir yapay zeka modelini, kendi özel verilerimizle **yeniden eğitme** işlemidir.
- Uzun sürer ve Donanım maliyeti yüksektir



FINE-TUNING

Modeli kendi verilerinizle yeniden eğitirsiniz.

1. VERİ



Özel verileriniz

2. EĞİTİM



Model bu verilerle yeniden eğitilir.

3. YENİ MODEL



Artık model bu bilgiyi "biliyor".

4. SORU → CEVAP



Soru sorulur, model cevap verir.



Model güncellenir.



Bilgi modele gömülüdür.



Eğitim maliyetli ve zaman alır.



Bilgi güncellemek zordur.

RAG

Modeli eğitmezsiz, bilgiyi dışarıdan getirirsiniz.

1. SORU



Kullanıcı soru sorar

2. RETRIEVAL



Vector veritabanından en ilgili bilgiler bulunur

3. LLM + BİLGİ



Model, getirilen bilgilerle cevap üretir

4. CEVAP



Cevap kullanıcıya sunulur



Model değişmez.



Bilgi veritabanına eklenir.



Daha hızlı, esnek ve günceldir.



Bilgi güncellemek kolaydır.

Genel Değerlendirme ve Özet

Güvenilirlik: Yapay zekanın uydurmasını (halüsinasyon) engeller, kanıta dayalı konuşur.

Esneklik: Yeni bir bilgi eklemek için modeli yeniden eğitmeye gerek yoktur, sadece veritabanına bir PDF eklemek yeterlidir.

Maliyet: Fine-tuning gibi devasa işlemci gücü ve bütçe gerektirmez, öğrenci dostudur.

SORULARINIZ?

Dinlediğiniz için teşekkür ederim.