

MAKİNE ÖĞRENMESİNE GİRİŞ

SUNUM 18: RAG RAPORU

AYŞE HİLAL AKAR

2412705003

RAG (Retrieval-Augmented Generation) kavramını anlamak için önce iki temel yapıya bakmak gerekiyor. Bunlardan biri Retrieval modelleri, diğeri ise Generative modellerdir.

Retrieval modelleri, kısaca bir arama sistemi gibi çalışır. Yani elinde büyük bir veri kaynağı vardır ve kullanıcı bir soru sorduğunda, bu soru ile en alakalı bilgileri bulup getirir. Mesela bir veritabanı, doküman ya da internet sayfaları içinde arama yapar ve en uygun metinleri seçmeye çalışır. Yani burada amaç yeni bir şey üretmek değil, var olan doğru bilgiyi bulmaktır.

Generative modeller ise tam tersi şekilde çalışır. Bunlar ChatGPT gibi modellerdir ve verilen bir prompta göre yeni bir metin üretir. Yani sadece bilgi çekmek değil, o bilgileri kullanarak anlamlı ve akıcı cevaplar yazmak üzerine kuruludur. Ancak bazen yanlış bilgi verebilir, güncel olmayabilir ya da tamamen uydurma cevaplar üretebilir.

İşte RAG sistemi tam olarak bu iki yaklaşımı birleştirir. Yani önce retrieval kısmı devreye girer ve soruyla ilgili en doğru bilgiler dış kaynaklardan çekilir. Sonra generative model bu bilgileri kullanarak daha doğru ve bağlama uygun bir cevap üretir.

RAG'ın en büyük avantajlarından biri güncel bilgi kullanabilmesidir. Modeli baştan eğitmeye gerek kalmaz, sadece veri güncellenir ve sistem yeni bilgileri kullanabilir. Ayrıca yanlış veya uydurma cevap verme ihtimalini ciddi şekilde azaltır. Çünkü model kafasına göre cevap üretmek yerine, elindeki gerçek kaynaklara dayanarak konuşur. Bu da güvenilirliği artırır.

Bir diğerk önemli avantajı ise maliyet ve verimlilik konusudur. Normalde büyük bir dil modeline çok fazla veri vermek hem pahalıdır hem de sistemi yavaşlatır. Çünkü model çok büyük bir metni aynı anda işlemek zorunda kalır. Ama RAG sisteminde bu yapılmaz. Bunun yerine dokümanlar küçük parçalara bölünür, bu parçalar embedding yöntemiyle sayısal vektörlere dönüştürölür ve bir vektör veritabanında saklanır.

Embedding aslında kelimeleri ya da metinleri matematiksel olarak temsil etme yöntemidir. Yani kelimeler sayılara çevrilir ve benzer anlamlı kelimeler birbirine yakın olacak şekilde konumlandırılır. Böylece bilgisayar sadece kelimeye değil, anlama göre işlem yapabilir.

Vektör veritabanı ise bu embedding'leri saklayan ve aralarında benzerlik araması yapan özel bir veritabanıdır. Normal veritabanları birebir eşleşme ararken, vektör veritabanları anlam benzerliğine göre arama yapar. Bu da özellikle yapay zekâ sistemlerinde çok daha akıllı sonuçlar elde edilmesini sağlar.

Sonuç olarak RAG sistemi, büyük dil modellerinin eksik kaldığı noktaları tamamlar. Hem daha doğru hem daha güncel hem de daha verimli bir sistem ortaya çıkar. Bu yüzden günümüzde birçok yapay zekâ uygulamasında RAG yaklaşımı kullanılmaktadır.

YAPILAN MİNİ PROJENİN AÇIKLANMASI

Bu projede PDF dosyaları üzerinde çalışan bir yapay zekâ destekli soru-cevap sistemi geliştirilmiştir. Sistem, kullanıcı tarafından yüklenen PDF dosyasını okuyarak içerisindeki metinleri analiz etmektedir. Daha sonra kullanıcı tarafından sorulan sorulara, PDF içeriğine göre uygun cevap üretmektedir.

Projede amaç; büyük dokümanlar içerisindeki bilgiye hızlı erişim sağlamak ve kullanıcıya belgeyi tamamen okumadan gerekli bilgileri sunabilen bir sistem geliştirmektir.

Sistem şu adımlarla çalışmaktadır:

1. PDF dosyası sisteme yüklenir.

2. PDF içerisindeki metinler okunur.
3. Uzun metin küçük parçalara ayrılır.
4. Metinler sayısal vektörlere dönüştürülür.
5. Kullanıcının sorusu ile en alakalı metin bölümü bulunur.
6. Yapay zekâ modeli kullanılarak cevap üretilir.

Kullanılan Veri Seti

Projede veri seti olarak kullanıcı tarafından yüklenen PDF dosyaları kullanılmıştır.

Kullanılan Yöntem

Projede doğal dil işleme (NLP - Natural Language Processing) yöntemleri kullanılmıştır.

Kullanılan temel yöntemler:

- PDF içerisinden metin çıkarılması
- Metnin küçük parçalara ayrılması (Text Splitting)
- Embedding yöntemi ile metinlerin sayısal vektörlere dönüştürülmesi
- FAISS kullanılarak benzer metin arama işlemi
- Transformer tabanlı dil modeli ile cevap oluşturulması

Sistemde Retrieval-Augmented Generation (RAG) mantığı kullanılmıştır. Bu yöntemde önce dokümandan ilgili bilgiler bulunmakta, daha sonra yapay zekâ modeli cevap üretmektedir.

Kullanılan Kodlamalar

Projede Python programlama dili kullanılmıştır.

Kullanılan temel kütüphaneler:

- PyPDF2
PDF dosyasını okumak için kullanılmıştır.
- LangChain
Metin parçalama işlemleri için kullanılmıştır.
- Sentence Transformers
Metin embedding işlemleri için kullanılmıştır.
- FAISS
Benzer metinleri hızlı şekilde bulmak için kullanılmıştır.
- Transformers
Yapay zekâ tabanlı soru-cevap sistemi oluşturmak için kullanılmıştır.

Elde Edilen Sonuçlar ve Program Çıktıları

Yapılan testlerde sistemin PDF içerisindeki bilgileri başarılı şekilde okuyabildiği gözlemlenmiştir.

Kullanıcı tarafından sorulan sorulara:

- doküman içeriğine uygun,
- anlamlı,
- kısa sürede
cevaplar üretilebilmiştir.

RAG KULLANIM ÖRNEKLERİ

RAG, incelikli anlayış ve kesin bilgi çıkarma gerektiren görevlerde mükemmeldir. İlgili belgeleri geri getirerek, RAG sadece kısa ve öz değil, aynı zamanda son derece doğru özetler oluşturabilir. Özellikle aşağıdakiler için değerlidir:

- **Hukuki belge analizi:** Önemli ayrıntıları koruyarak uzun hukuki metinleri özetleme
- **Araştırma makalesi özetleme:** Karmaşık akademik makaleleri araştırmacılar ve öğrenciler için anlaşılır özetlere dönüştürme
- **Haber özeti:** Son dakika haberleri hakkında kısa özetler sunarak okuyucuların önemli bilgileri hızlı bir şekilde almasını sağlar
- **Tıbbi bilgi erişimi:** RAG destekli sistemler, tıp uzmanlarının en son araştırmalara, klinik kılavuzlara ve hasta kayıtlarına erişmesine ve bunları özetlemesine yardımcı olarak hasta bakımını iyileştirir

- **Finansal analiz:** Kapsamlı finansal raporları ve haber makalelerini analiz ederek özetler ve içgörüler sağlama
- **Müşteri desteği:** Bilgi tabanlarından, SSS'lerden ve ürün kılavuzlarından bilgi alarak karmaşık müşteri sorgularını yanıtlama

RAG teknolojisini kullanan şirketlerin gerçek hayattan örnekleri

Birçok teknoloji devi ve hizmet sağlayıcı, performansı artırmak için RAG'yi platformlarına entegre etmiştir.

- **Google:** Google, iş verilerine uyarlanmış Google kalitesinde sonuçlar sunan arama çözümleri oluşturmaya yardımcı olmak için [Vertex AI Search'ü](#) geliştirmiştir.
- **Amazon:** Alexa, RAG'yi kullanarak gerçek zamanlı ürün verilerini alır ve kişiselleştirilmiş sesli yanıtlar sunar.
- **Spotify:** Spotify, RAG'yi kullanarak kullanıcının dinleme geçmişine göre özel çalma listeleri oluşturur.
- **Meta:** RAG, kullanıcıların etkileşimlerinden veya harici kaynaklardan harici verileri çekerek kişiselleştirilmiş içerik ve önerileri iyileştirmeye yardımcı olur.

KAYNAKÇA

- ❖ <https://blog.openzeka.com/ai/rag-retrieval-augmented-generation-nedir/>
- ❖ <https://ekolsoft.com/tr/b/rag-sistemi-nedir-retrieval-augmented-generation-rehberi>
- ❖ <https://clickup.com/tr/blog/436233/pacavra-kullanim-oernekleri>
- ❖ <https://www.sap.com/turkey/resources/what-is-a-vector-database>
- ❖ <https://www.komtas.com/glossary/embedding-nedir>
- ❖